HW2 多元線性回歸分析報告

Red Wine Quality：以理化特徵預測紅酒品質

- 學號：7115056106
- 分析流程：CRISP-DM
- 模型：多元線性回歸、Lasso 特徵選擇後線性回歸
- 資料來源：Kaggle Red Wine Quality
- 完成日期：2026-10-08

摘要

本研究使用 Kaggle 公開的 Red Wine Quality 資料，分析 1,599 筆葡萄牙 Vinho Verde 紅酒紀錄，以 11 個理化特徵預測專家感官品質分數 `quality`。資料沒有缺失值，但有 240 筆超過第一筆的完全重複紀錄。由於無法判定它們是不同酒樣得到相同測量，或是重複匯入，本研究保留全部紀錄，並以完整列分組切分，避免相同特徵與答案同時進入訓練集和測試集。

11 特徵基準 OLS 在固定測試集得到 MAE 0.503214、RMSE 0.657947、R^2 0.341849。Lasso 搭配訓練集內分層群組交叉驗證及 one-standard-error 規則選出 `volatile acidity`、`total sulfur dioxide`、`sulphates`、`alcohol` 四項特徵；精簡 OLS 的 MAE 0.511868、RMSE 0.664149、R^2 0.329384。精簡模型減少 63.64% 特徵，RMSE 僅增加 0.94%，但不能宣稱準確度提升。精簡模型的 95% 個別新觀測預測區間涵蓋測試資料 94.64%，惟殘差常態性及等變異性檢定均未通過，區間應視為基於 OLS 假設的近似結果。

1. Business Understanding

1.1 問題背景

葡萄酒品質傳統上仰賴專家感官評分。若能以容易取得的理化測量建立預測模型，可作為品質檢查及專家複核的輔助工具。本作業的目標不是取代品酒專家，而是檢視多元線性回歸能否從理化特徵建立可解釋的品質基準模型。

1.2 研究問題

1. 11 個理化特徵能在未見資料上多準確地預測 `quality`？
2. Lasso 能否找出較精簡的特徵子集，並維持接近基準模型的表現？
3. 線性模型的殘差假設與 95% 預測區間在此離散順序目標上有何限制？

1.3 成功標準

- 使用獨立測試集計算 MAE、RMSE、R^2。
- Feature Selection 只能使用訓練資料及訓練 fold。
- 相同完整列不得跨越訓練集與測試集。
- 預測圖必須包含明確標示的 95% prediction interval。
- 結果、表格及圖形均由程式實際產生。

2. Data Understanding

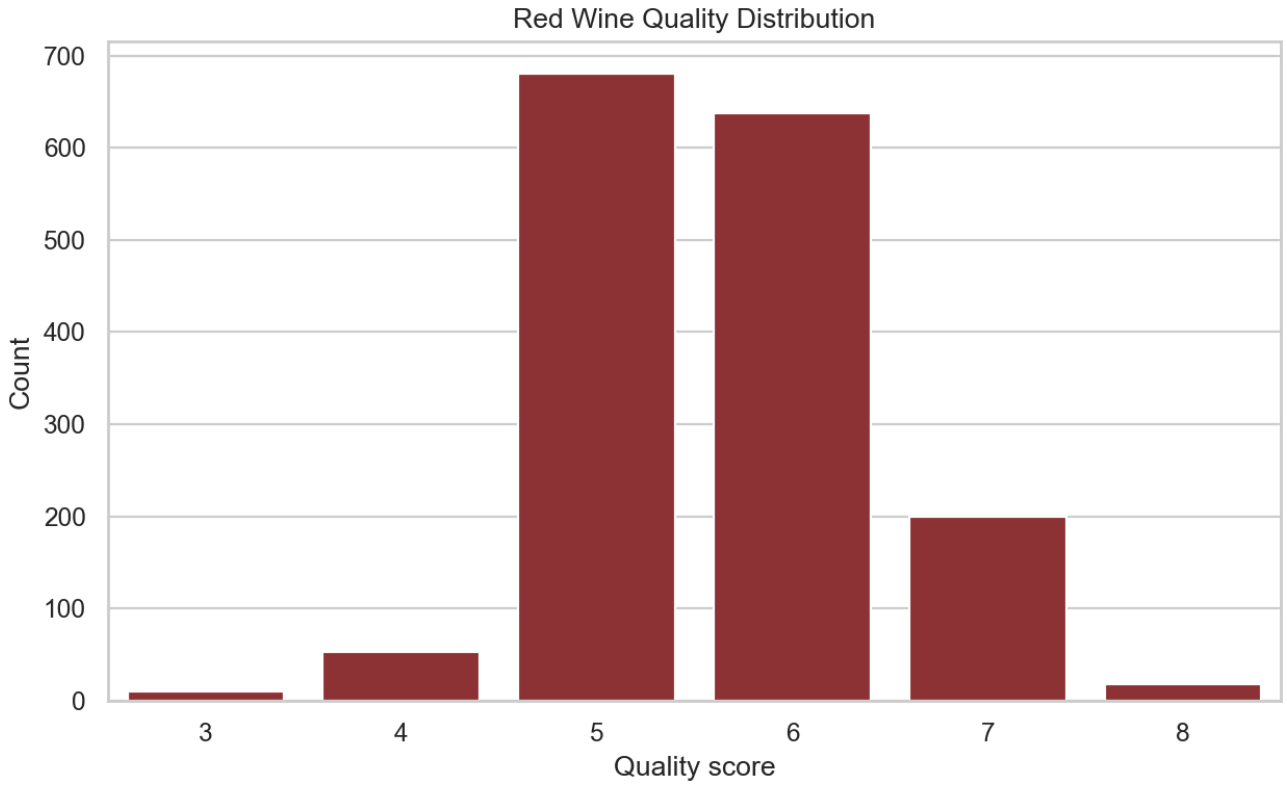
2.1 資料來源與欄位

- 資料集：Red Wine Quality
- Kaggle：https://www.kaggle.com/datasets/uciml/red-wine-quality-cortez-et-al-2009
- 原始研究資料庫：https://archive.ics.uci.edu/ml/datasets/wine%20quality
- 目標欄位：`quality`
- 資料筆數：1,599
- 輸入特徵數：11

類型	欄位
酸度	fixed acidity、volatile acidity、citric acid、pH
糖與鹽類	residual sugar、chlorides、sulphates
二氧化硫	free sulfur dioxide、total sulfur dioxide
物理與酒精	density、alcohol
目標	quality

2.2 資料品質

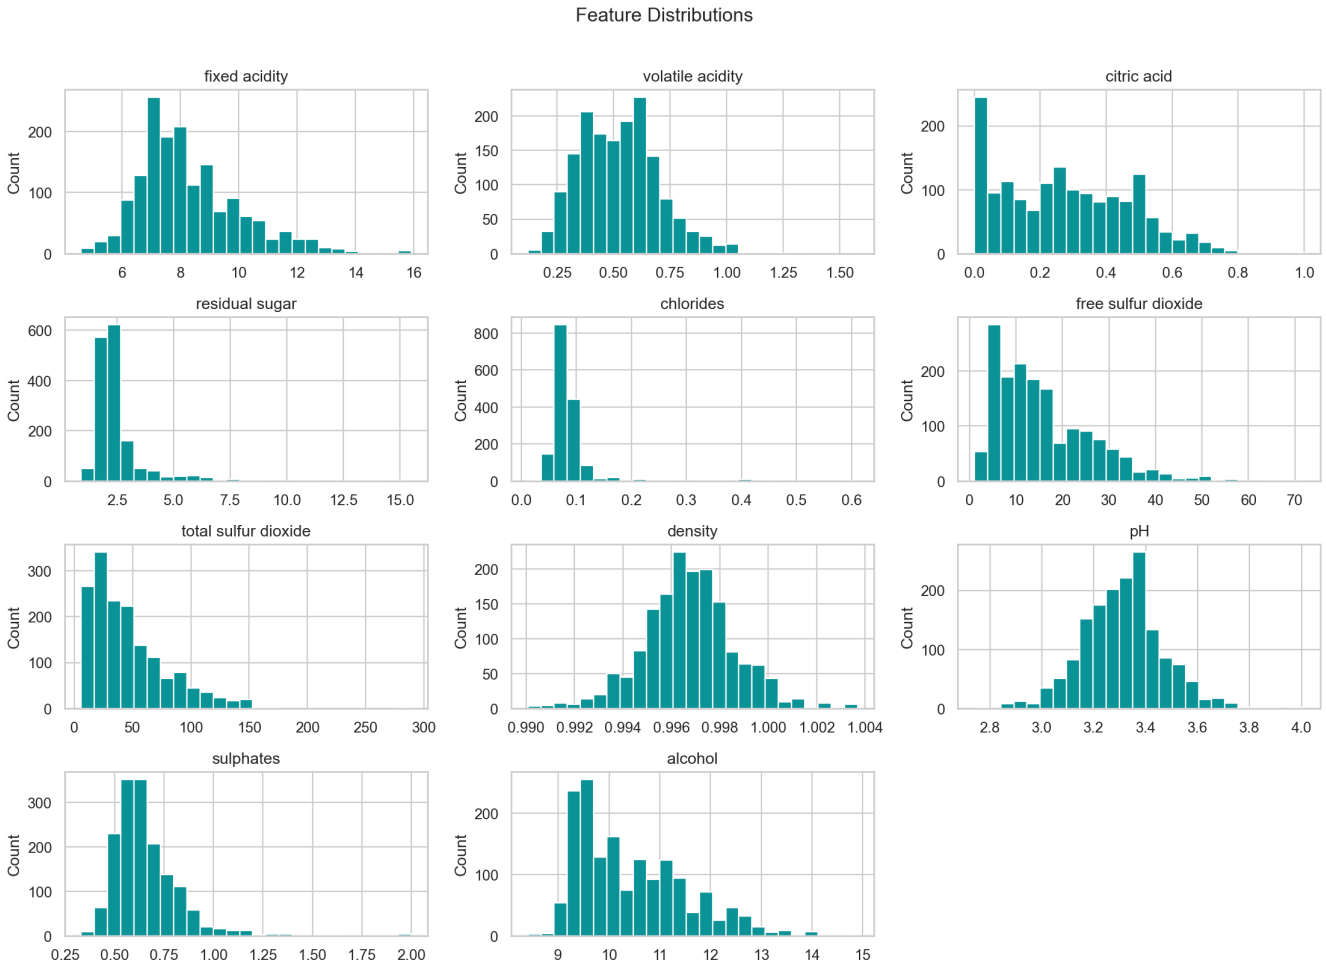
所有輸入特徵為 `float64`，目標為 `int64`；缺失值總數為 0。資料有 1,359 種不同完整列，另外 240 筆為超過第一筆的完全重複紀錄。品質分數實際範圍為 3–8，平均 5.6360，中位數 6；5 分有 681 筆、6 分有 638 筆，兩者合計占大多數，品質兩端樣本很少。



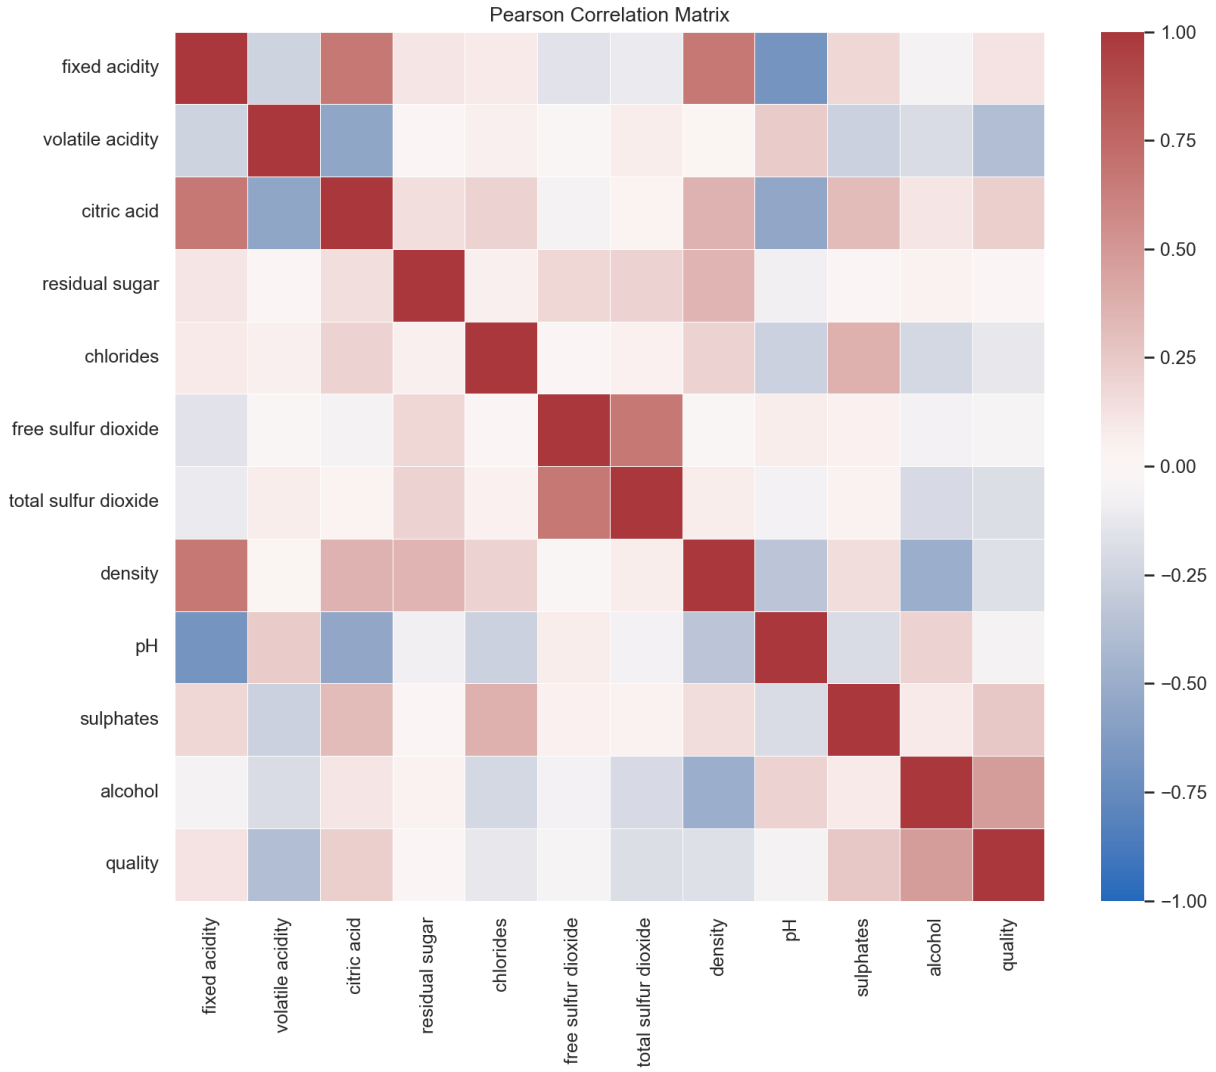
圖：品質分布

2.3 特徵分布與相關性

多個特徵呈右偏並含少數極端觀測，尤其是 residual sugar、chlorides、free sulfur dioxide 及 total sulfur dioxide。這些數值未被證明是資料錯誤，因此不因圖形外觀而直接刪除。


Feature Distributions
fixed acidity
volatile acidity
citric acid
residual sugar
chlorides
free sulfur dioxide
total sulfur dioxide
density
pH
sulphates
alcohol
Count

圖：特徵分布



圖：Pearson 相關矩陣

3. Data Preparation

3.1 缺失值、格式與異常值

- 缺失值為 0，不執行插補。
- 11 個特徵皆為數值，不需要 one-hot encoding。
- 保留偏態及極端觀測，於 Evaluation 以殘差與 Cook's distance 檢查影響。
- 基準 OLS 不需標準化；Lasso 的 `StandardScaler` 放在 Pipeline 中，只在每個訓練 fold fit。

3.2 重複列處理

完全重複列可能是不同酒樣的相同測量，也可能是重複匯入，僅憑資料無法判定。本研究不直接刪除，而以「11 個特徵加 quality 全部相同」定義群組，確保同一群組只出現在訓練集或測試集其中一邊。此作法保留原始分布，也避免測試集出現模型已看過的相同特徵與答案。

3.3 訓練 / 測試切分

使用固定 `random_state=42` 的 5-fold `StratifiedGroupKFold` 產生候選，選擇測試列數最接近 20% 且品質比例最接近整體的 fold。

項目	訓練集	測試集
筆數	1,282	317
完整列群組	1,087	272
缺失值	0	0

實際測試比例為 19.8249%，訓練 / 測試群組交集為 0；品質 3–8 均存在於兩邊。因群組大小不同，無法同時保證筆數恰為 20% 且每個品質比例完全一致。

4. Modeling

4.1 基準模型

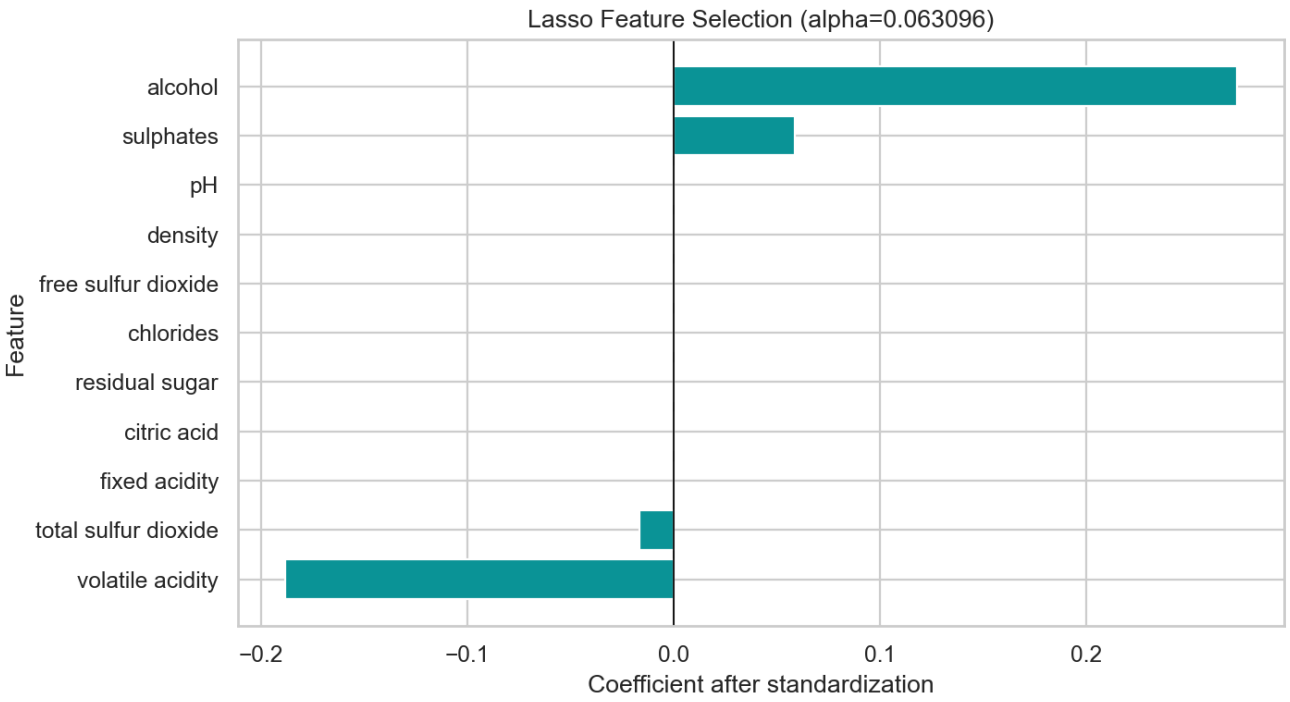
基準模型為含截距的普通最小平方法 `LinearRegression`，使用全部 11 個特徵及 1,282 筆訓練資料。模型成功對 317 筆測試資料產生預測，範圍為 4.647604–7.505878。

4.2 Lasso Feature Selection

特徵選擇只使用訓練集。Pipeline 包含 `StandardScaler` 與 `Lasso`，交叉驗證採固定種子的 5-fold `StratifiedGroupKFold`。搜尋 81 個 alpha（10^{-4} 至 1），再採 one-standard-error 規則：選擇平均 CV RMSE 位於最佳值一個標準誤內的最大 alpha，以較少特徵換取接近最佳的預測能力。

- 最小 CV RMSE：0.650300
- one-SE 上限：0.663908
- 選定 alpha：0.0630957
- 選定 alpha 平均 CV RMSE：0.663722
- 特徵數：11 → 4

入選特徵為：`volatile acidity`、`total sulfur dioxide`、`sulphates`、`alcohol`。入選只表示在目前資料、網格及選擇規則下係數非零，不代表因果關係。


Lasso Feature Selection (alpha=0.063096)
alcohol
sulphates
pH
density
free sulfur dioxide
chlorides
residual sugar
citric acid
fixed acidity
total sulfur dioxide
volatile acidity
Feature
−0.2
−0.1
0.0
0.1
0.2
Coefficient after standardization

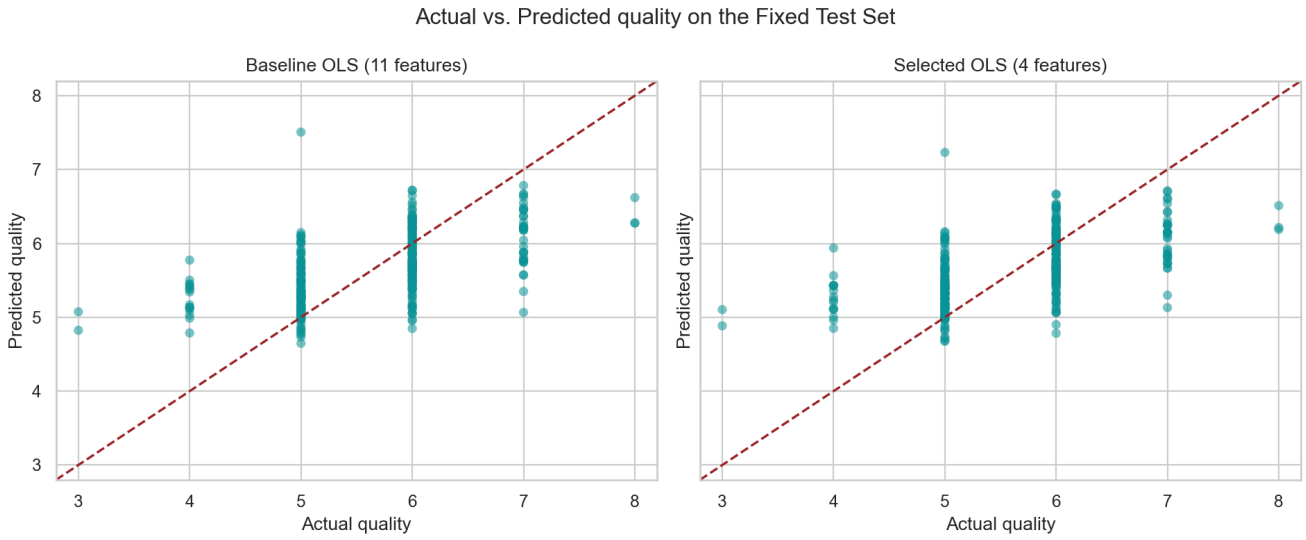
圖：Lasso 特徵選擇

5. Evaluation

5.1 固定測試集指標

模型	特徵數	MAE	RMSE	R^2
基準 OLS	11	0.503214	0.657947	0.341849
精簡 OLS	4	0.511868	0.664149	0.329384

基準模型三項測試指標均略佳。精簡模型減少 63.64% 特徵，代價為 MAE 增加 1.72%、RMSE 增加 0.94%。因此若優先追求本次測試準確度，應選基準模型；若量測成本、簡潔性及解釋性較重要，四特徵模型是合理折衷。



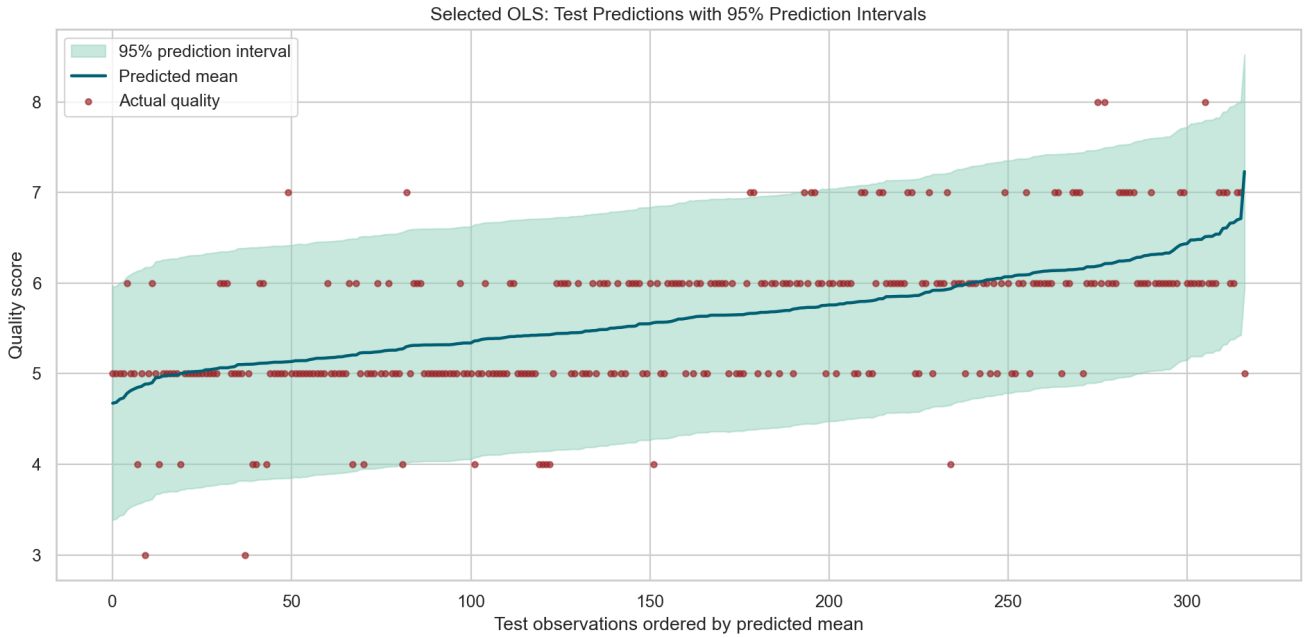
圖：實際值與預測值

兩模型預測皆明顯向平均品質收縮：低品質容易被高估，高品質容易被低估。這與品質兩端樣本少、線性模型表達能力有限有關。

5.2 95% 預測區間

使用四特徵精簡 OLS，以訓練集 fit statsmodels OLS，再對測試特徵計算 95% 個別新觀測 prediction interval。此區間描述在相同特徵條件下，一筆未來個別品質觀測可能落入的範圍，不是平均品質的 confidence interval。

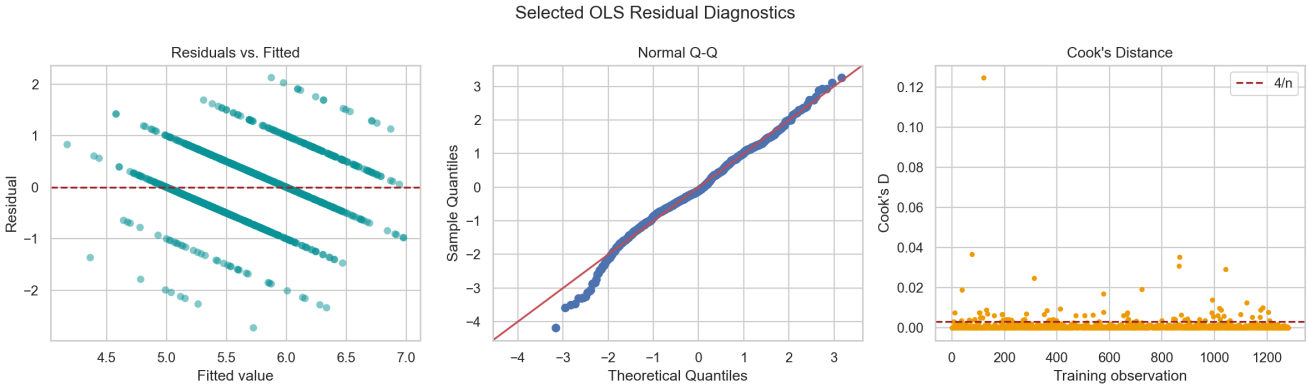
- 測試集區間涵蓋率：94.6372%
- 平均區間寬度：2.566784 品質分數



圖：95% 個別預測區間

5.3 殘差與模型假設

- Jarque–Bera p = 1.11×10^{-8}：拒絕殘差常態性。
- Breusch–Pagan LM p = 8.25×10^{-6}：存在異質變異證據。
- Cook's D 大於 4/n：78 筆；最大值 0.124842。
- Durbin–Watson = 1.688651；資料沒有明確時間順序，因此僅作描述。



圖：精簡模型殘差診斷

殘差圖的斜帶結構也反映目標只有離散整數等級。由於常態及等變異假設未完全成立，傳統 OLS 推論與 95% 預測區間應視為近似。影響觀測沒有資料錯誤證據，因此不為改善指標而任意刪除。

6. Deployment

本作業的 Deployment 是可重現的批次分析流程，而非公開線上服務。執行 `7115056106_hw2.py` 會從固定原始 CSV 重新產生資料摘要、分組切分、基準模型、Lasso 特徵選擇、精簡模型、測試指標、圖表及 95% 預測區間。

建議部署原則：

1. 保存原始 CSV SHA-256 與固定 random state。
2. 新資料必須具有完全相同的 11 個欄位、單位及格式。

3. 若採精簡模型，只需四個入選理化測量，但必須監控輸入範圍與品質分布漂移。

4. 模型輸出是連續近似值，不應自動當成正式品質認證。

5. 定期以新增專家評分資料重做獨立驗證；若需要原生有序輸出，可比較 cumulative ordinal regression。

GPT 輔助內容

本作業使用 GPT coding agent 協助規劃 CRISP-DM 流程、撰寫 Python 程式、設計無洩漏切分與 Lasso Pipeline、產生圖表、執行測試及整理報告。所有資料筆數、模型指標、圖形及檢定結果均來自實際程式執行；資料集選擇、學號、NotebookLM 內容及最終繳交由學生確認。真實 GPT 對話已由使用者匯出為 8 頁 PDF，將在檔案整理階段作為附件納入，不以虛構對話取代。

NotebookLM 摘要

本研究探討以多元線性回歸預測葡萄牙 Vinho Verde 紅酒品質的適用性。UCI 資料說明指出此資料包含 11 個理化輸入，品質為 0–10 分的感官評分；類別具有順序且分布不平衡，因此可視為回歸或分類問題，也適合研究特徵選擇。原始研究以多元回歸、神經網路及支持向量機比較，結果顯示在其驗證設計與容忍度指標下，SVM 優於多元回歸，但需要較高計算成本。Lasso 與逐步回歸的模擬研究則顯示，Lasso 的樣本外預測較一致，而較強的收縮可提高精簡度與穩定性；該研究來自心理資料情境，不能直接當成紅酒資料的實證結論。品質分數是有序類別，ordinal cumulative model 會直接建模各等級的累積機率與門檻，因此在統計形式上比把分數當等距連續值更貼近資料性質。本作業仍依題目使用 OLS，並以 MAE、RMSE、R^2、殘差診斷及 95% 個別預測區間呈現其效果與限制。

主流或較佳解法比較

方法	優點	限制與本作業定位
11 特徵 OLS	本作業測試指標最佳、容易解釋	無法原生限制輸出等級；模型假設未完全成立
4 特徵 OLS	特徵少 63.64%，表現只小幅下降	沒有改善測試準確度
SVM regression	原始酒品質研究中優於 multiple regression	較耗計算、較難解釋；不同驗證及指標不能直接比較
Cumulative ordinal regression	直接建模有序等級及門檻	需檢查 proportional-odds；本作業未實測
Ordinal classifier pooling	可結合現代分類器並利用順序	2026 預印本；未在本作業資料實測

結論與限制

本作業完成無明顯資料洩漏的多元線性回歸流程。11 特徵基準模型在固定測試集略優於四特徵模型；Lasso 的主要收益是精簡性，而非本次準確度改善。R^2 約 0.34，表示理化特徵只能解釋部分感官品質差異；評分主觀性、未觀測因素、類別不平衡及線性限制都可能造成剩餘誤差。95% 預測區間涵蓋率接近名目值，但因殘差常態與等變異假設未通過，不宜過度解讀。未來可在完全相同的群組切分下比較 SVM、robust regression 與 ordinal regression，再以相同指標判斷是否真正改善。

參考資料

1. Cortez, P., Cerdeira, A., Almeida, F., Matos, T., & Reis, J. (2009). Modeling wine preferences by data mining from physicochemical properties. https://doi.org/10.1016/j.dss.2009.05.016
2. UCI Machine Learning Repository. Wine Quality. https://doi.org/10.24432/C56S3T
3. Zhou, D. J., Chahal, R., Gotlib, I. H., & Liu, S. (2024). Comparison of Lasso and Stepwise Regression in Psychological Data. https://doi.org/10.5964/meth.11523
4. Gambarota, F., & Altoè, G. (2024). Ordinal regression models made easy. https://doi.org/10.1002/ijop.13243
5. Lang, K. M. Regression Assumptions & Diagnostics. https://www.kylemlang.com/fundamentals/wk5/lecture/assumptions.pdf
6. Rotenberg, N. H., Faria, A. V., & Caffo, B. (2026). Classifier Pooling for Modern Ordinal Classification. https://arxiv.org/abs/2603.17278

附錄：重現方式

```
MPLCONFIGDIR=/tmp/aiot_hw2_matplotlib \
PYTHONPYCACHEPREFIX=/tmp/aiot_hw2_pycache \
python3 7115056106_hw2.py
```

主要程式：7115056106_hw2.py。原始資料：data/raw/winequality-red.csv。管理及測試證據：TODO.md、PROJECT_LOG.md。