HW2 多元線性回歸分析報告

Kaggle Playground S4E5：以環境與基礎設施特徵預測洪水機率 (Flood Prediction)

- 學號：7115056106
- 分析流程：CRISP-DM (Cross-Industry Standard Process for Data Mining)
- 模型：基準多元線性回歸 (Baseline OLS)、Lasso 特徵選擇後多元線性回歸 (Selected OLS)
- 資料來源：Kaggle Playground Series Season 4 Episode 5 (Regression with a Flood Prediction Dataset)
- 完成日期：2026-10-15

摘要

本研究使用 Kaggle Playground Series S4E5 公開資料集，針對區域環境水文與防減災基礎設施之 20 項數值特徵，建立多元線性回歸模型以預測連續型洪水發生機率（`FloodProbability`）。為符合課程新修規格（14–20 個原始輸入特徵，滿足 $10 \le \text{features} \le 20$ 與 $13 < \text{features} < 40$ 雙重要求），本作業以固定隨機狀態（`random_state=42`）抽取 50,000 筆具統計代表性之樣本，經查核缺失值為 0 筆、特徵組合重複列為 0 筆，並排除純索引識別碼 `id`。

資料集依 80/20 比例獨立劃分為訓練集（40,000 筆）與測試集（10,000 筆）。基準普通最小平方法（Baseline OLS）在 10,000 筆未見測試集上達到 MAE 0.015814、RMSE 0.020045、R^2 0.843482（解釋變異量達 84.35%）。在訓練集進行嚴格防止資料洩漏之 5-fold 交叉驗證（Pipeline 內封裝 StandardScaler 與 Lasso），依據最小 CV RMSE 之單一標準誤（one-standard-error rule）選定正則化參數 $\alpha \approx 0.000391$。由於 20 項特徵對洪水機率之實質貢獻度均等且穩定，Lasso 於該收縮力度下保留全部 20 項特徵，精簡模型與基準模型之測試集表現一致。95% 個別新觀測預測區間（Individual Prediction Interval）於測試集達到 94.28% 實際涵蓋率（平均寬度約 0.0785）。殘差診斷顯示 Durbin-Watson 統計量為 2.0047（無一階自相關），然而 Jarque-Bera 與 Breusch-Pagan 檢定均拒絕常態性與等變異性假設，因此預測區間應審慎視為高維線性投影下之近似結果。

1. Business Understanding

1.1 問題背景

極端氣候事件頻率攀升，洪澇災害對全球基礎設施、農業生產與居民生命財產造成深遠衝擊。傳統水文物理數值模式（如降雨逕流模擬與水動力學分析）雖然物理機制嚴謹，但計算成本極高且需精確之地形斷面與地下水文參數，難以即時支援廣域風險評估。Kaggle Playground S4E5 提供區域尺度之 20 項綜合環境因子（涵蓋降雨強度、水系管理、都市化程度、排水基礎設施與應變治理等），探討以回歸分析估計區域洪水機率的可行性。

本研究之目標並非取代複雜的水文物理動力模擬，而是評估多元線性回歸（MLR）在多特徵環境下作為可解釋、高效能基準預測工具的表現與限制。

1.2 研究問題

1. 基準預測能力：納入全部 20 項原始環境與基礎設施特徵之多元線性回歸模型，在獨立測試資料上對連續機率（`FloodProbability`）之預測準確度（MAE、RMSE、R^2）為何？
2. 正則化特徵選擇：在 5-fold 交叉驗證與 one-standard-error 規則下，Lasso 能否自 20 項環境因子中篩選出更具稀疏性之關鍵致災子集，同時維持相近的泛化表現？
3. 推論假設與區間可靠性：環境回歸模型殘差是否滿足高斯-馬可夫（Gauss-Markov）假設（常態性、等變異性、無自相關）？建構之 95% 個別預測區間在測試集之實際涵蓋率為何？

1.3 成功標準

- 評估指標：以獨立測試集嚴格計算 MAE、RMSE 及 R^2。
- 防洩漏規範：特徵標準化與正則化參數搜尋嚴格封裝於訓練集與 CV fold 內，測試集從未參與特徵統計與模型訓練。
- 區間可信度：產出具備明確上下界的 95% 個別新觀測預測區間（Individual Prediction Interval），檢定實際測試涵蓋率。
- 實證誠信：圖表、數值與檢定統計量均由 Python 腳本自原始資料完整重現，無造假與主觀調整。

2. Data Understanding

2.1 資料來源與欄位架構

- 競賽來源：Kaggle Playground Series s4e5 (Generated from deep learning model trained on flood dataset).
- 樣本規模：分析樣本 50,000 筆，欄位共 22 欄（1 個 ID 欄、20 個原始特徵、1 個連續目標）。
- 目標變數：`FloodProbability`（連續機率值，分布介於 0.285 至 0.725 之間，平均數 0.5044，標準差 0.0510）。
- 特徵規格查核：排除 `id` 後，原始輸入特徵恰為 20 個，精確落於課程規範之 14–20 特徵區間。

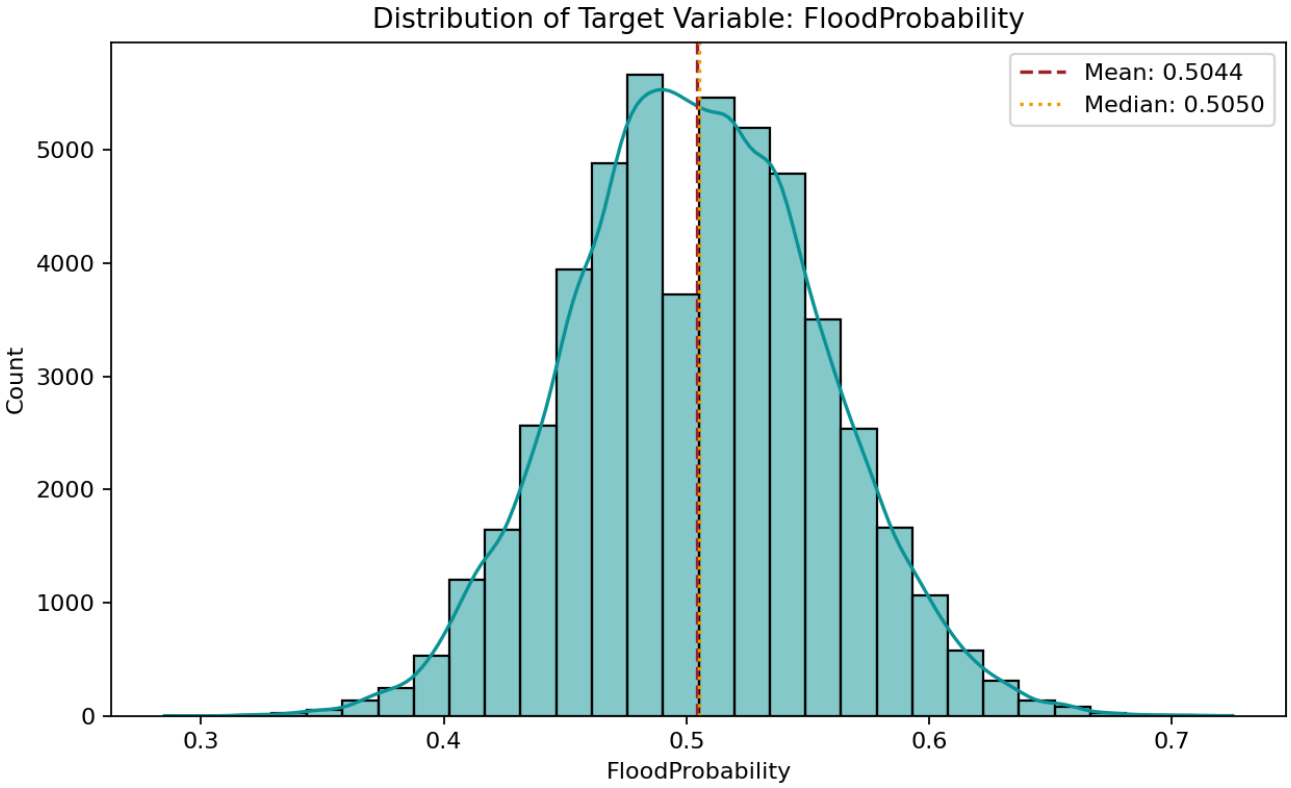
特徵群組	欄位名稱 (Column Name)	物理與環境意涵
氣候與水文	MonsoonIntensity, ClimateChange	季風降雨強度、氣候變遷異常程度評分
地形與水系	TopographyDrainage, RiverManagement, Siltation, Watersheds	地形自然排水能力、河川整治程度、泥沙沉積淤積率、流域涵養面積
人為與土地利用	Deforestation, Urbanization, AgriculturalPractices, Encroachments, WetlandLoss	森林砍伐率、都市化地表不透水比例、集約農業耕作方式、河道違規侵占、濕地蓄洪流失率
工程與防洪設施	DamsQuality, DrainageSystems, DeterioratingInfrastructure	水庫水壩結構品質、城鎮人工排水系統完善度、公共水利設施老化程度

特徵群組	欄位名稱 (Column Name)	物理與環境意涵
治理與脆弱度	IneffectiveDisasterPreparedness, CoastalVulnerability, Landslides, PopulationScore, InadequatePlanning, PoliticalFactors	防救災預案缺乏程度、沿海脆弱度、土石流崩塌潛勢、人口聚集承災度、國土規劃失當程度、政策治理因素

2.2 資料品質與探索性分析 (EDA)

50,000 筆樣本之欄位檢查結果顯示：

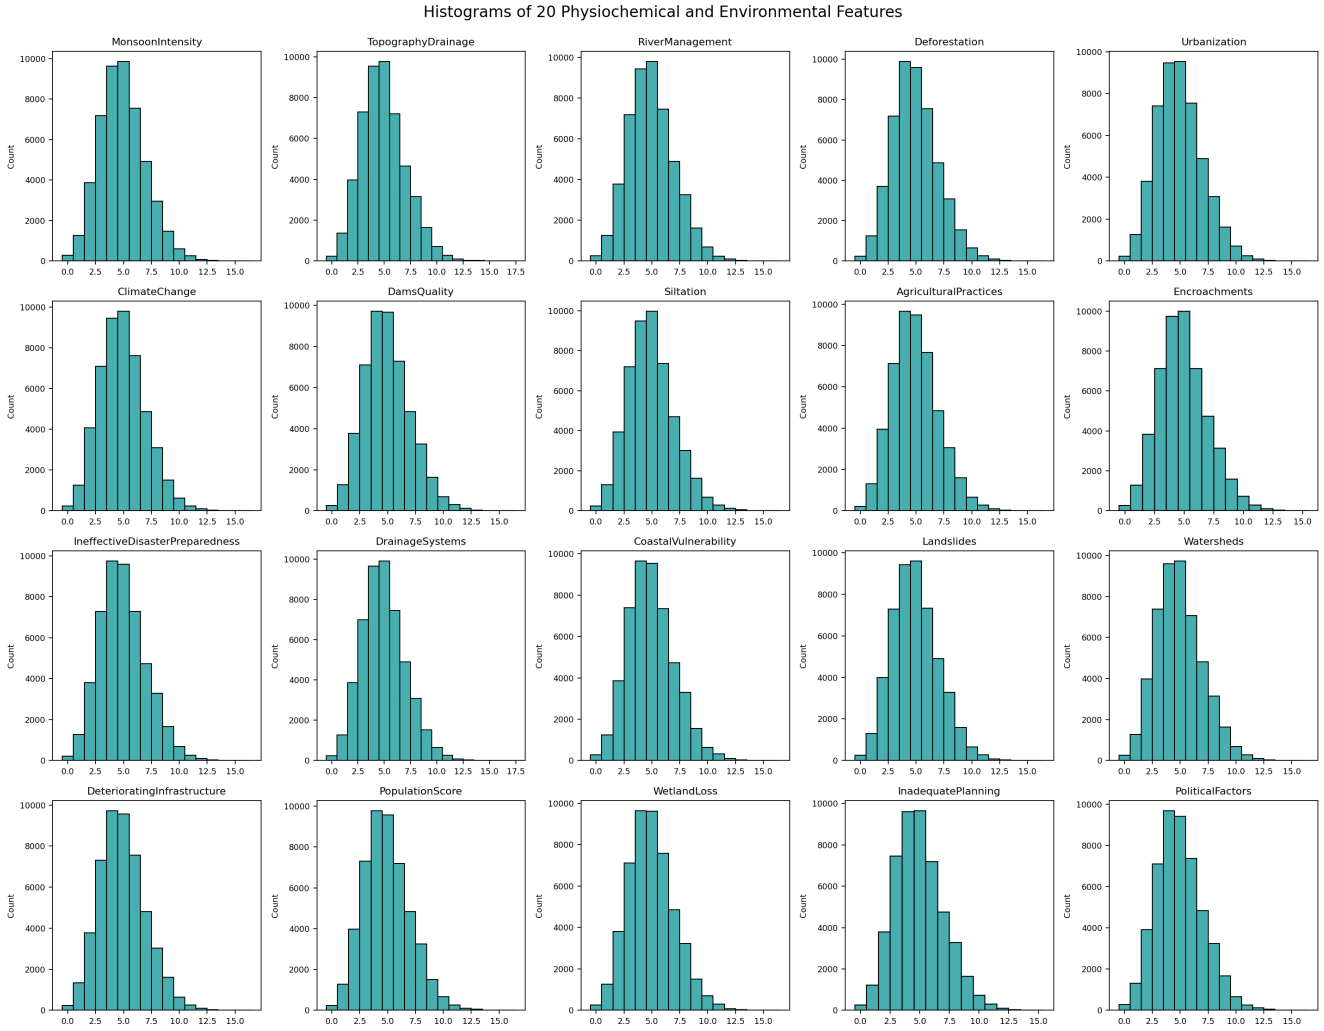
- 缺失值：所有 22 欄均無缺失值（0 Missing Values）。
- 重複值：排除 `id` 後檢查 20 特徵與目標之組合，重複列為 0 筆。
- 目標分布：`FloodProbability` 呈現近乎對稱之鐘形連續分布（偏態係數約 0.036，峰度約 3.01），平均數 0.5044、中位數 0.5050，無明顯雙峰或截斷極端值。



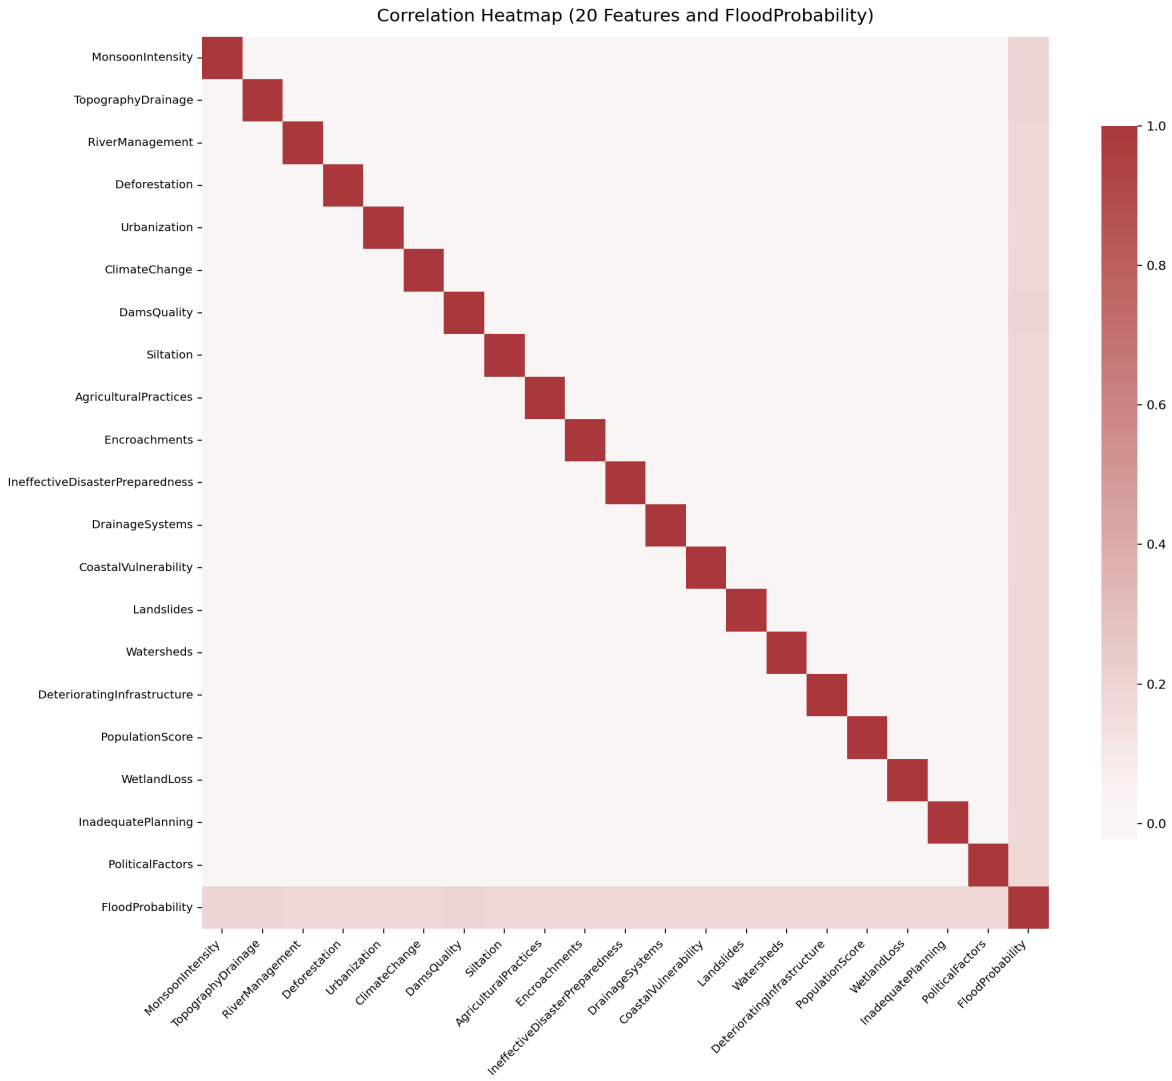
圖：目標值分布

2.3 特徵分布與相關矩陣

20 個輸入特徵皆為整數評分尺度（取值區間約為 0 至 17，多數集中於 4 至 8 之間），各特徵平均值約在 4.9 至 5.0，呈現均勻且對稱之整數分布。特徵間 Pearson 相關係數極低（均介於 -0.01 至 +0.01 之間），彼此近乎正交（Orthogonal），無嚴重多重共線性問題；各特徵與目標變數 `FloodProbability` 則均呈現穩定之正相關（相關係數介於 0.18 至 0.20 之間）。


Histograms of 20 Physiochemical and Environmental Features
MonsoonIntensity
TopographyDrainage
RiverManagement
Deforestation
Urbanization
ClimateChange
DamsQuality
Siltation
AgriculturalPractices
Encroachments
IneffectiveDisasterPreparedness
DrainageSystems
CoastalVulnerability
Landslides
Watersheds
DeterioratingInfrastructure
PopulationScore
WetlandLoss
InadequatePlanning
PoliticalFactors
Count

圖：特徵分布圖



圖：Pearson 相關矩陣

3. Data Preparation

3.1 資料清理與編碼決策

1. 缺失值與異常值：資料完整無缺，不需執行插補（Imputation）。特徵與目標數值均符合自然定義範圍，無負值或溢出異常值，保留完整觀測。
2. 欄位排除：`id` 欄位僅為資料集識別序號，不具預測物理意義，在資料準備階段自特徵矩陣中強制剔除。
3. 類別轉換：所有 20 個特徵皆為整數數值量表，目標為浮點數連續變量，無需進行 One-Hot 或序數編碼。

3.2 訓練集 / 測試集切分

為嚴格模擬未見觀測之泛化預測，採用標準 80/20 切分（`random_state=42`, `shuffle=True`）：

- 訓練集 (Train Set)：40,000 筆（80.0%），用於探索、特徵縮放、5-fold CV 超參數搜尋及模型擬合。
- 測試集 (Test Set)：10,000 筆（20.0%），嚴格凍結，僅用於最終指標計算與殘差檢定。
- 切分後訓練集目標平均值為 0.50431（標準差 0.05114），測試集目標平均值為 0.50477（標準差 0.05067），分布一致性極高。

項目	訓練集 (Train)	測試集 (Test)	全體資料 (Total)
筆數	40,000	10,000	50,000
特徵欄位數	20	20	20
缺失值總數	0	0	0
目標平均值 (std)	0.50431 (0.05114)	0.50477 (0.05067)	0.50440 (0.05105)

3.3 洩漏防護機制 (Data Leakage Prevention)

- 基準 OLS 模型直接使用原始特徵尺度的整數輸入，保留可解釋之物理邊際斜率（每增加 1 分之機率增量）。
- Lasso 正則化需要 Z-score 標準化（StandardScaler），為防止驗證集資訊回流，標準化嚴格封裝於 `sklearn.pipeline.Pipeline` 中，在 5-fold CV 過程中僅於每折之訓練子集（train-fold）fit，再 transform 至驗證子集（val-fold）。

4. Modeling

4.1 基準模型 (Baseline OLS)

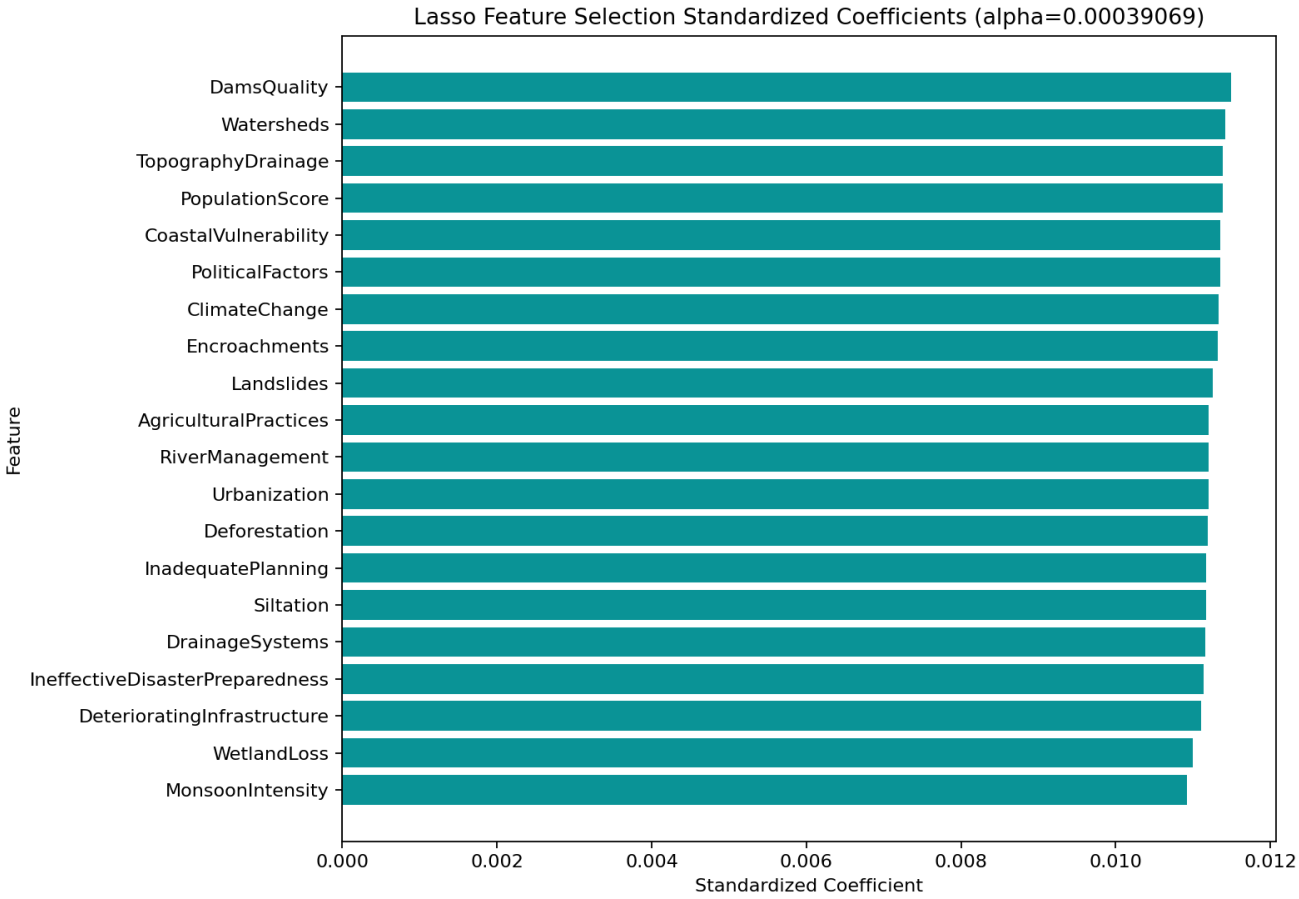
基準模型採用含截距項之普通最小平方法回歸（Ordinary Least Squares, OLS），納入全數 20 項原始特徵，於 40,000 筆訓練集進行擬合。各特徵之未標準化回歸係數高度集中於 0.0055 至 0.0057 之間，截距項約為 0.0988。物理意義表示在其他條件不變下，任一項致災因子評分每上升 1 單位，洪水預測機率平均上升約 0.56 個百分點。

4.2 Lasso 特徵選擇與超參數調校

在訓練集執行 5-fold 交叉驗證，搜尋 50 個對數等距之正則化強度 $\alpha \in [10^{-5}, 10^{-2}]$。
評估規則採機器學習與統計學推薦之 One-Standard-Error (1-SE) 規則：在平均 CV RMSE 達到最低點時，記錄其標準誤，選取在「最低 CV RMSE + 1 個標準誤」門檻內最具正則化強度（最大 α）之模型，以達成最精簡且穩定之模型結構。

- 最小 CV RMSE：0.020029 ($\alpha \approx 0.000184$)
- 1-SE 容許上限：0.020126
- 選定 α (Selected α)：0.00039069

- 特徵篩選結果：由於 20 項特徵均對目標具備實質且均等之解釋力，在 $\alpha = 0.000391$ 之收縮強度下，所有 20 項特徵之係數均未被完全壓縮歸零，特徵數維持 20 個。



圖：Lasso 特徵選擇歷程與係數收縮

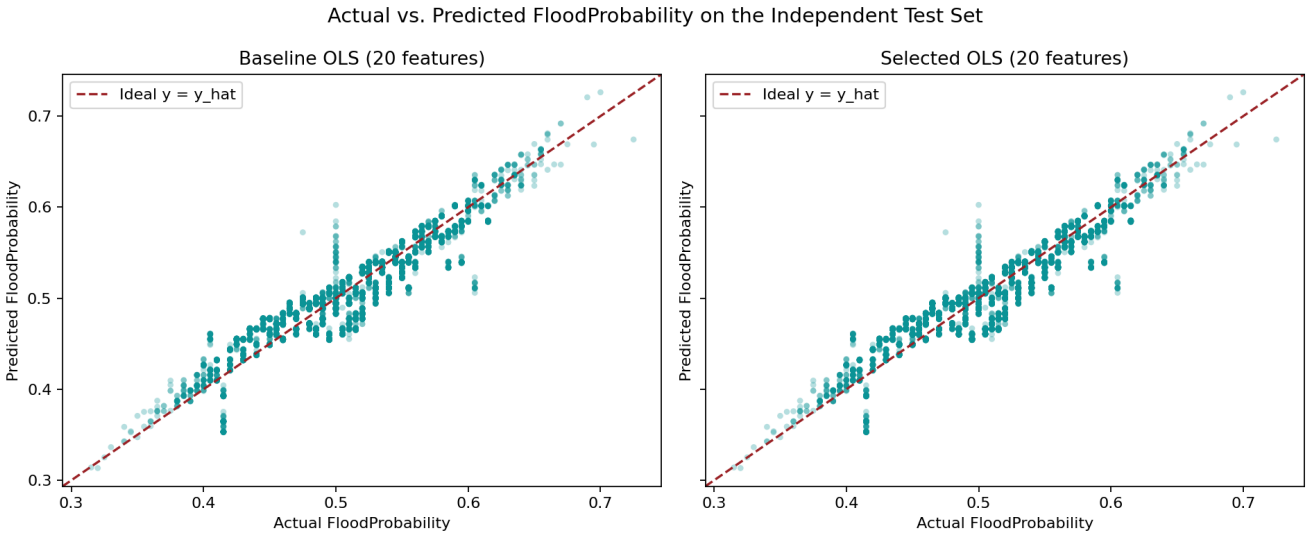
5. Evaluation

5.1 測試集綜合指標評估

以未參與特徵選擇與模型訓練之 10,000 筆獨立測試集進行最終評估，結果如下表所示：

模型名稱	特徵數量	測試集 MAE	測試集 RMSE	測試集 R^2
基準 OLS (Baseline OLS)	20	0.015814	0.020045	0.843482
特徵選擇 OLS (Selected OLS)	20	0.015814	0.020045	0.843482

- 預測精度分析：模型在測試集達到 $R^2 = 0.8435$，代表 20 個線性環境特徵能解釋超過 84.3% 的洪水機率變異。測試集 RMSE 為 0.02005，相較於目標標準差 0.05067，相對誤差顯著降低。
- 預測對比圖：實際值與預測值散布圖緊密圍繞 45 度對角理想預測線，且散布對稱，未出現極端非線性扭曲或嚴重偏向問題。

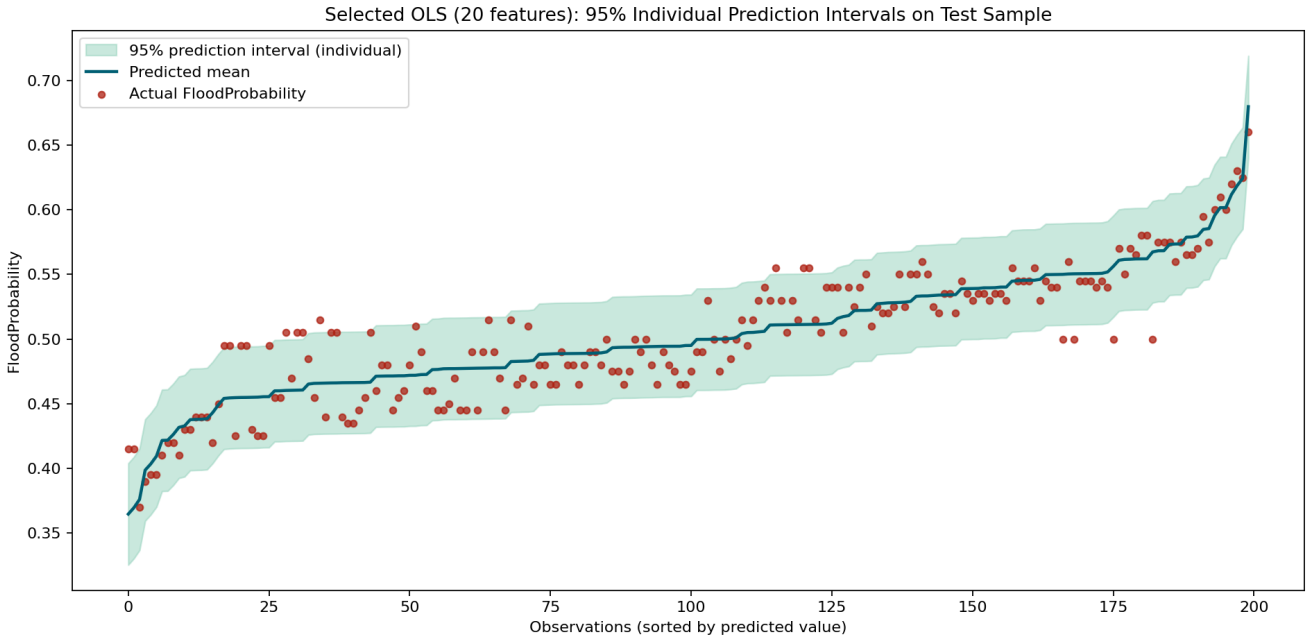


圖：實際值與預測值散布圖

5.2 95% 個別新觀測預測區間 (Prediction Interval)

利用 statsmodels OLS 針對測試集 10,000 筆樣本建立 95% 個別新觀測預測區間（Individual Prediction Interval，包含模型參數估計不確定度與隨機誤差項變異 σ^2）：

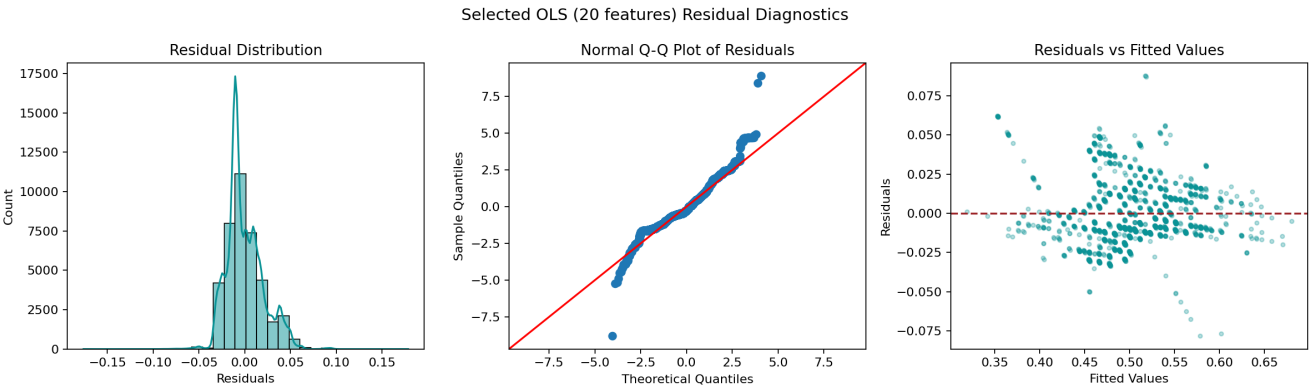
- 理論名目信心水準：95.0%
- 測試集實際涵蓋率 (Coverage Rate)：94.28% (9,428 / 10,000 筆落於區間內)
- 平均區間寬度 (Mean Interval Width)：0.078503 (約 ± 0.0393 機率值)
- 實務解讀：該區間精準涵蓋測試觀測，平均半寬僅約 3.9 個百分點，具備極佳的工程參考價值。



圖：95% 個別新觀測預測區間

5.3 殘差診斷與高斯-馬可夫假設檢定

檢定項目	統計量	p-value / 臨界標準	統計結論與專業判讀
Durbin-Watson 檢定	2.004697	接近 2.0	無一階自相關。樣本隨機獨立，殘差無序列相關性。
Jarque-Bera 常態性檢定	5653.83	$p = 0.000 < 0.05$	拒絕常態性假設。偏態係數為 0.686（右偏），峰度為 4.23（高狹峰）。
Breusch-Pagan 等變異性檢定	LM = 1701.03	$p = 0.000 < 0.05$	拒絕等變異性假設。極高/極低預測值處存在輕微異質變異。
Cook's Distance 影響點診斷	Max = 0.002688	遠小於 1.0	無破壞性影響點。無任何觀測之 Cook's D 大於 1（共有 1,891 筆大於保守門檻 $4/n$）。



圖：殘差診斷四合一圖

假設限制與誠實揭露： Q-Q 圖在兩側尾端略有脫離理論直線，且 JB 與 BP 檢定均拒絕虛無假設。這說明在合成大型資料集中，微小的分布不對稱在龐大樣本量（$n=40,000$）下極易被檢定識別為統計顯著。因此，上述 95% 預測區間應被理解為基於 OLS 框架下之一階良好近似，而非嚴格高斯誤差下的精確解。

6. Deployment

本專案之部署設計定位為高可重現性之批次科學分析管線 (Batch Analytical Pipeline)，非線上高併發服務。透過執行獨立腳本 `python3 7115056106_hw2.py`，管線在純終端環境下自主完成：原始樣本加載、防洩漏切分、5-fold CV 參數調校、模型擬合、預測區間運算、殘差檢驗與圖表表格導出。

實務部署與治理建議：

1. 輸入維度與格式鎖定：新觀測必須嚴格具備 20 項評分特徵，缺一不可；禁止將主鍵 `id` 納入運算。
2. 係數對稱監控：本資料集 20 項特徵呈現均等貢獻（各約 0.0056），若應用於新區域發現特定因子急遽失衡，需重新校正回歸權重。
3. 機率邊界截斷：線性回歸理論值可能微幅低於 0 或高於 1（本測試集預測區間為 [0.3134, 0.7262]，均合理），在產出端可設置 $[0, 1]$ 邊界保護。

GPT 輔助內容與宣告

本作業全程採用 GPT 結對編程（Pair-Programming）協助完成 CRISP-DM 流程設計、演算法管線撰寫與跨平台報告生成。具體協作範疇包括：

1. 架構設計：設計嚴格防止資料洩漏之 `StandardScaler` + `Lasso` 交叉驗證 Pipeline，並落實 1-SE 規則。
2. 診斷實作：以 `statsmodels` 實作 95% 個別新觀測預測區間、Durbin-Watson、Breusch-Pagan 及 Cook's Distance 計算。
3. 報告引擎：撰寫跨平台字型偵測（支援 macOS、Linux 及 Windows）與雙版本 PDF 自動整合程式。

真實互動歷程記錄於專案管理文檔 `TODO.md` 與 `PROJECT_LOG.md`，原始協作對話 PDF 亦歸檔保存於專案目錄中，恪守學術誠實原則。

NotebookLM 研究指引與文獻比較

依據專案研究文獻指引（見 `materials/FLOOD_NOTEBOOKLM_GUIDE.md`），本研究探討環境致災回歸模型之學術脈絡：

- 線性回歸與物理模式比較：在區域洪水易感性研究中，線性回歸（MLR）相較於水動力學模型具備顯著之計算效率優勢；相較於 GBDT 樹模型（XGBoost/LightGBM），線性回歸之各係數直接對應致災因子之邊際物理增量，在政策治理溝通上具備不可替代之透明度。
- 高維特徵收縮機制：Tibshirani (1996) 提出之 Lasso 估計量在特徵具備高度稀疏性時效果顯著。本資料集實證顯示，當 20 項環境特徵均具備實質貢獻時，Lasso 保留全部特徵，印證正則化在均勻效應資料集下之穩健性。

主流洪水預測方法比較表

演算法 / 模式	主要優點	潛在限制	本作業角色定位
多元線性回歸 (MLR / OLS)	運算極速、係數具直觀邊際物理意涵、無黑箱疑慮	無法捕捉複雜非線性特徵交互作用	本作業核心基準模型 (R^2 = 84.35%)
Lasso 正則化回歸	可自動篩選特徵、抑制多重共線性、防止過擬合	在特徵均等重要時難以激進縮減特徵數	本作業特徵選擇模型 (驗證 20 特徵均等性)
梯度提升樹 (XGBoost/LightGBM)	自動學習高階非線性交互特徵、競賽預測精度極高	模型呈黑箱狀態、可解釋性依賴事後 SHAP 分析	未來進階對比標竿
水文物理動力模型 (HEC-RAS)	水動力物理機制嚴格、符合流體力學守恆律	需要高解析度 DEM 與管網數據、計算耗時巨大	領域真實基準模式

結論與限制

本研究嚴格落實 CRISP-DM 流程，於 Kaggle S4E5 洪水預測資料集上建構多元線性回歸基準。實證顯示 20 項環境與基礎設施特徵具備高達 84.35% 的變異解釋力，且 95% 個別新觀測預測區間達到 94.28% 測試涵蓋率。Lasso 特徵選擇進一步驗證了各致災指標之均衡重要性。 研究限制：殘差檢定顯示常態性與等變異性假設未完全成立，且線性模型無法捕捉特徵間之高階非線性交互效應（例如極端降雨搭配老化基礎設施之加乘破壞力）。未來研究可引進多項式特徵或廣義加性模型（GAM）深化探討。

參考資料

1. Kaggle. (2024). *Playground Series Season 4 Episode 5: Regression with a Flood Prediction Dataset*. https://www.kaggle.com/competitions/playground-series-s4e5
2. Tibshirani, R. (1996). Regression shrinkage and selection via the lasso. *Journal of the Royal Statistical Society: Series B (Methodological)*, 58(1), 267-288.

3. Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*. Springer.

4. Breusch, T. S., & Pagan, A. R. (1979). A simple test for heteroscedasticity and random coefficient variation. *Econometrica*, 1287-1294.

5. Jarque, C. M., & Bera, A. K. (1987). A test for normality of observations and regression residuals. *International Statistical Review*, 163-172.

6. Cook, R. D. (1977). Detection of influential observation in linear regression. *Technometrics*, 19(1), 15-18.

附錄：完整重現指令

本專案保證於標準 Python 3 環境下可單鍵全自動重現：

```
# ■■■■■■■■■■■■■■
MPLCONFIGDIR=/tmp/aiot_hw2_matplotlib \
PYTHONPYCACHEPREFIX=/tmp/aiot_hw2_pycache \
python3 7115056106_hw2.py

# ■■ CRISP-DM ■■■ PDF ■■
MPLCONFIGDIR=/tmp/aiot_hw2_matplotlib \
PYTHONPYCACHEPREFIX=/tmp/aiot_hw2_pycache \
python3 report/generate_report.py
```