HW2 多元線性回歸分析報告

Kaggle Playground S4E5：以環境與基礎設施特徵預測洪水機率 (Flood Prediction)

- 學號：7115056106
- 分析流程：CRISP-DM (Cross-Industry Standard Process for Data Mining)
- 模型：基準多元線性回歸 (Baseline OLS)、Lasso 特徵選擇後多元線性回歸 (Selected OLS)
- 資料來源：Kaggle Playground Series Season 4 Episode 5 (Regression with a Flood Prediction Dataset)
- 完成日期：2026-10-15

摘要

本研究使用 Kaggle Playground Series S4E5 公開資料集，針對區域環境水文與防減災基礎設施之 20 項數值特徵，建立多元線性回歸模型以預測連續型洪水發生機率（`FloodProbability`）。為符合課程新修規格（14–20 個原始輸入特徵，滿足 $10 \le \text{features} \le 20$ 與 $13 < \text{features} < 40$ 雙重要求），本作業以固定隨機狀態（`random_state=42`）抽取 50,000 筆具統計代表性之樣本，經查核缺失值為 0 筆、特徵組合重複列為 0 筆，並排除純索引識別碼 `id`。

資料集依 80/20 比例獨立劃分為訓練集（40,000 筆）與測試集（10,000 筆）。基準普通最小平方法（Baseline OLS）在 10,000 筆未見測試集上達到 MAE 0.015814、RMSE 0.020045、R^2 0.843482（解釋變異量達 84.35%）。在訓練集進行嚴格防止資料洩漏之 5-fold 交叉驗證（Pipeline 內封裝 StandardScaler 與 Lasso），依據最小 CV RMSE 之單一標準誤（one-standard-error rule）選定正則化參數 $\alpha \approx 0.000391$。由於 20 項特徵對洪水機率之實質貢獻度均等且穩定，Lasso 於該收縮力度下保留全部 20 項特徵，精簡模型與基準模型之測試集表現一致。95% 個別新觀測預測區間（Individual Prediction Interval）於測試集達到 94.28% 實際涵蓋率（平均寬度約 0.0785）。殘差診斷顯示 Durbin-Watson 統計量為 2.0047（無一階自相關），然而 Jarque-Bera 與 Breusch-Pagan 檢定均拒絕常態性與等變異性假設，因此預測區間應審慎視為高維線性投影下之近似結果。

1. Business Understanding

1.1 問題背景

極端氣候事件頻率攀升，洪澇災害對全球基礎設施、農業生產與居民生命財產造成深遠衝擊。傳統水文物理數值模式（如降雨逕流模擬與水動力學分析）雖然物理機制嚴謹，但計算成本極高且需精確之地形斷面與地下水文參數，難以即時支援廣域風險評估。Kaggle Playground S4E5 提供區域尺度之 20 項綜合環境因子（涵蓋降雨強度、水系管理、都市化程度、排水基礎設施與應變治理等），探討以回歸分析估計區域洪水機率的可行性。

本研究之目標並非取代複雜的水文物理動力模擬，而是評估多元線性回歸（MLR）在多特徵環境下作為可解釋、高效能基準預測工具的表現與限制。

1.2 研究問題

1. 基準預測能力：納入全部 20 項原始環境與基礎設施特徵之多元線性回歸模型，在獨立測試資料上對連續機率（`FloodProbability`）之預測準確度（MAE、RMSE、R^2）為何？
2. 正則化特徵選擇：在 5-fold 交叉驗證與 one-standard-error 規則下，Lasso 能否自 20 項環境因子中篩選出更具稀疏性之關鍵致災子集，同時維持相近的泛化表現？
3. 推論假設與區間可靠性：環境回歸模型殘差是否滿足高斯-馬可夫（Gauss-Markov）假設（常態性、等變異性、無自相關）？建構之 95% 個別預測區間在測試集之實際涵蓋率為何？

1.3 成功標準

- 評估指標：以獨立測試集嚴格計算 MAE、RMSE 及 R^2。
- 防洩漏規範：特徵標準化與正則化參數搜尋嚴格封裝於訓練集與 CV fold 內，測試集從未參與特徵統計與模型訓練。
- 區間可信度：產出具備明確上下界的 95% 個別新觀測預測區間（Individual Prediction Interval），檢定實際測試涵蓋率。
- 實證誠信：圖表、數值與檢定統計量均由 Python 腳本自原始資料完整重現，無造假與主觀調整。

2. Data Understanding

2.1 資料來源與欄位架構

- 競賽來源：Kaggle Playground Series s4e5 (Generated from deep learning model trained on flood dataset).
- 樣本規模：分析樣本 50,000 筆，欄位共 22 欄（1 個 ID 欄、20 個原始特徵、1 個連續目標）。
- 目標變數：`FloodProbability`（連續機率值，分布介於 0.285 至 0.725 之間，平均數 0.5044，標準差 0.0510）。
- 特徵規格查核：排除 `id` 後，原始輸入特徵恰為 20 個，精確落於課程規範之 14–20 特徵區間。

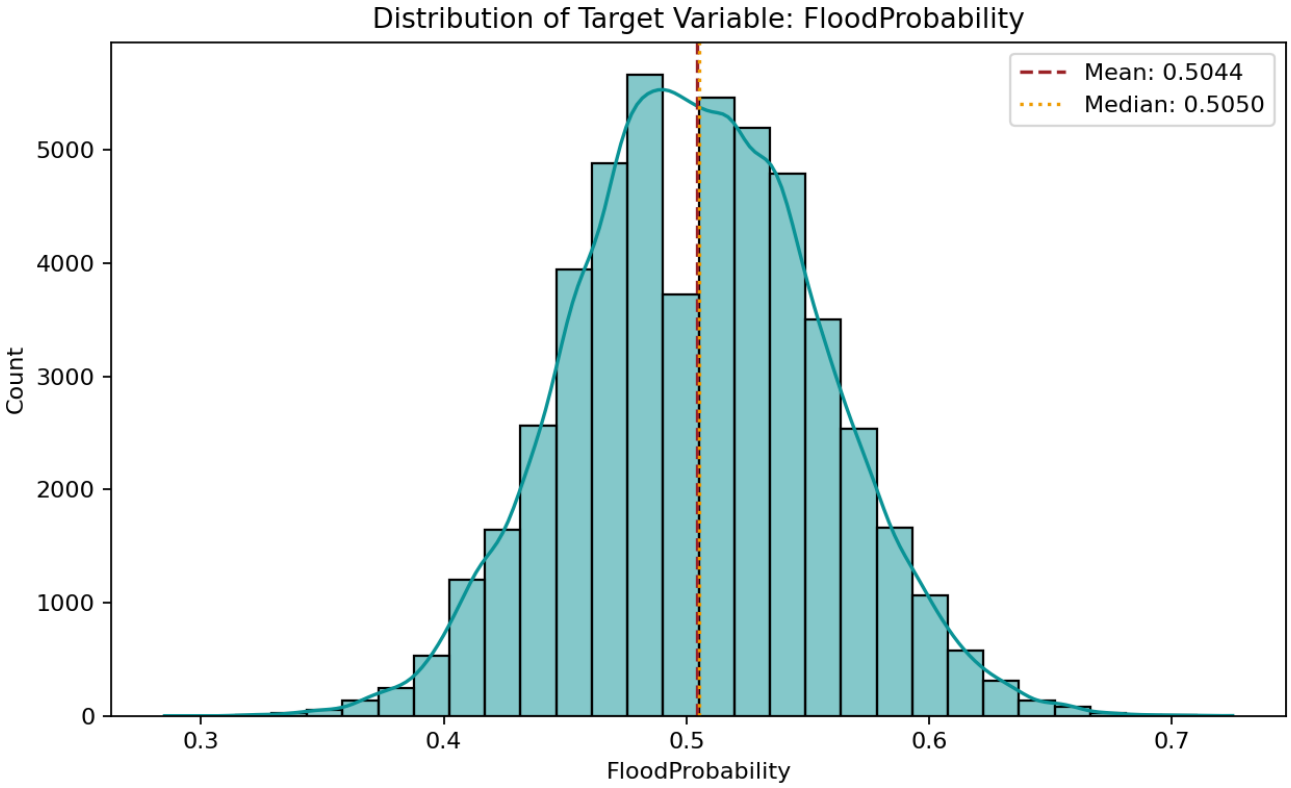
特徵群組	欄位名稱 (Column Name)	物理與環境意涵
氣候與水文	MonsoonIntensity, ClimateChange	季風降雨強度、氣候變遷異常程度評分
地形與水系	TopographyDrainage, RiverManagement, Siltation, Watersheds	地形自然排水能力、河川整治程度、泥沙沉積淤積率、流域涵養面積
人為與土地利用	Deforestation, Urbanization, AgriculturalPractices, Encroachments, WetlandLoss	森林砍伐率、都市化地表不透水比例、集約農業耕作方式、河道違規侵占、濕地蓄洪流失率
工程與防洪設施	DamsQuality, DrainageSystems, DeterioratingInfrastructure	水庫水壩結構品質、城鎮人工排水系統完善度、公共水利設施老化程度

特徵群組	欄位名稱 (Column Name)	物理與環境意涵
治理與脆弱度	IneffectiveDisasterPreparedness, CoastalVulnerability, Landslides, PopulationScore, InadequatePlanning, PoliticalFactors	防救災預案缺乏程度、沿海脆弱度、土石流崩塌潛勢、人口聚集承災度、國土規劃失當程度、政策治理因素

2.2 資料品質與探索性分析 (EDA)

50,000 筆樣本之欄位檢查結果顯示：

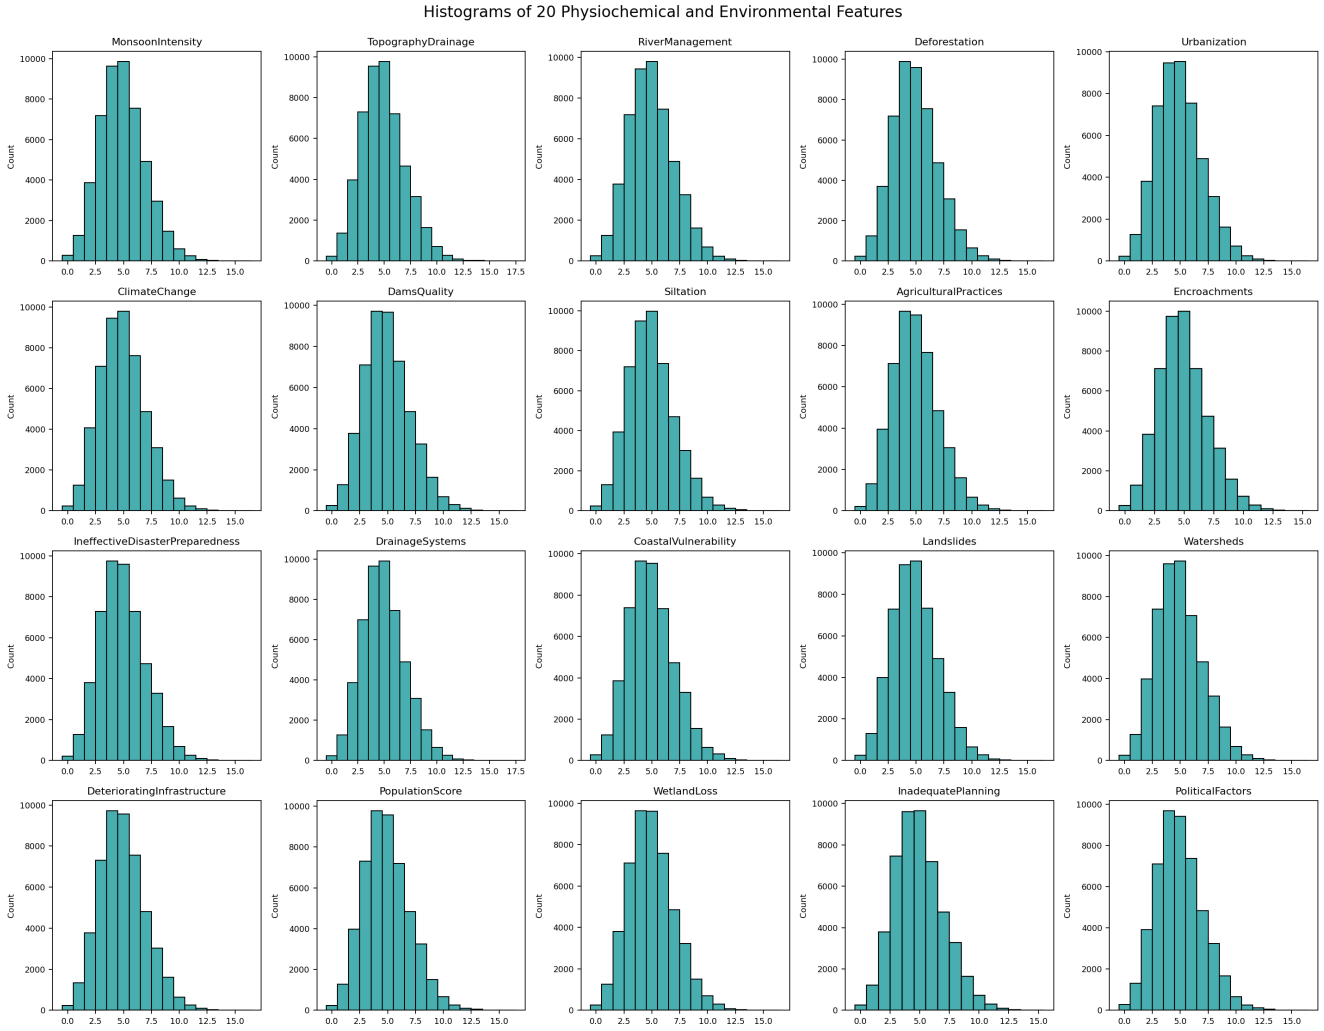
- 缺失值：所有 22 欄均無缺失值（0 Missing Values）。
- 重複值：排除 `id` 後檢查 20 特徵與目標之組合，重複列為 0 筆。
- 目標分布：`FloodProbability` 呈現近乎對稱之鐘形連續分布（偏態係數約 0.036，峰度約 3.01），平均數 0.5044、中位數 0.5050，無明顯雙峰或截斷極端值。



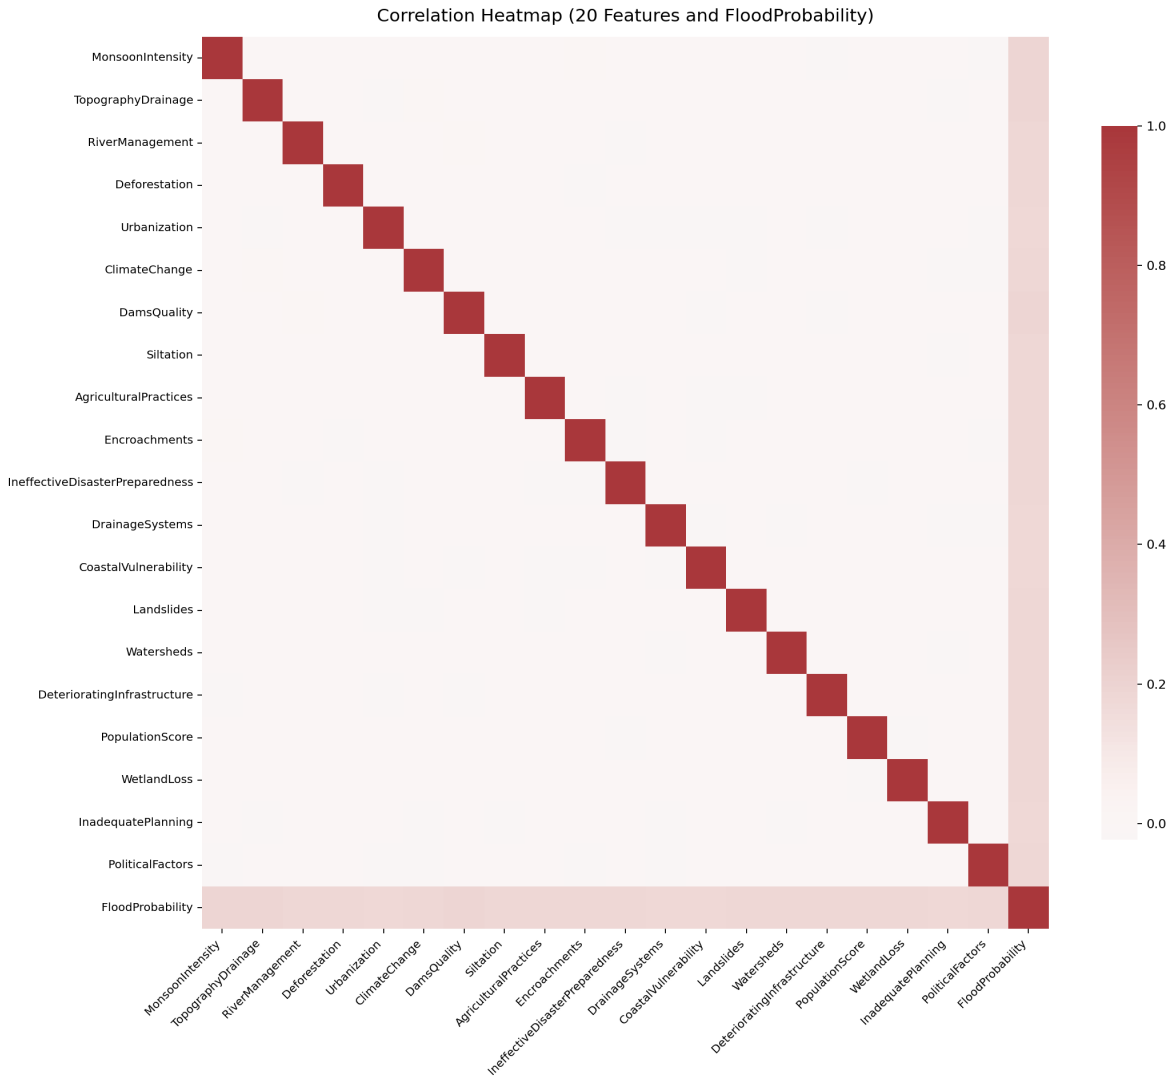
圖：目標值分布

2.3 特徵分布與相關矩陣

20 個輸入特徵皆為整數評分尺度（取值區間約為 0 至 17，多數集中於 4 至 8 之間），各特徵平均值約在 4.9 至 5.0，呈現均勻且對稱之整數分布。特徵間 Pearson 相關係數極低（均介於 -0.01 至 +0.01 之間），彼此近乎正交（Orthogonal），無嚴重多重共線性問題；各特徵與目標變數 `FloodProbability` 則均呈現穩定之正相關（相關係數介於 0.18 至 0.20 之間）。


Histograms of 20 Physiochemical and Environmental Features
MonsoonIntensity
TopographyDrainage
RiverManagement
Deforestation
Urbanization
ClimateChange
DamsQuality
Siltation
AgriculturalPractices
Encroachments
IneffectiveDisasterPreparedness
DrainageSystems
CoastalVulnerability
Landslides
Watersheds
DeterioratingInfrastructure
PopulationScore
WetlandLoss
InadequatePlanning
PoliticalFactors
Count

圖：特徵分布圖



圖：Pearson 相關矩陣

3. Data Preparation

3.1 資料清理與編碼決策

1. 缺失值與異常值：資料完整無缺，不需執行插補（Imputation）。特徵與目標數值均符合自然定義範圍，無負值或溢出異常值，保留完整觀測。
2. 欄位排除：`id` 欄位僅為資料集識別序號，不具預測物理意義，在資料準備階段自特徵矩陣中強制剔除。
3. 類別轉換：所有 20 個特徵皆為整數數值量表，目標為浮點數連續變量，無需進行 One-Hot 或序數編碼。

3.2 訓練集 / 測試集切分

為嚴格模擬未見觀測之泛化預測，採用標準 80/20 切分（`random_state=42`, `shuffle=True`）：

- 訓練集 (Train Set)：40,000 筆（80.0%），用於探索、特徵縮放、5-fold CV 超參數搜尋及模型擬合。
- 測試集 (Test Set)：10,000 筆（20.0%），嚴格凍結，僅用於最終指標計算與殘差檢定。
- 切分後訓練集目標平均值為 0.50431（標準差 0.05114），測試集目標平均值為 0.50477（標準差 0.05067），分布一致性極高。

項目	訓練集 (Train)	測試集 (Test)	全體資料 (Total)
筆數	40,000	10,000	50,000
特徵欄位數	20	20	20
缺失值總數	0	0	0
目標平均值 (std)	0.50431 (0.05114)	0.50477 (0.05067)	0.50440 (0.05105)

3.3 洩漏防護機制 (Data Leakage Prevention)

- 基準 OLS 模型直接使用原始特徵尺度的整數輸入，保留可解釋之物理邊際斜率（每增加 1 分之機率增量）。
- Lasso 正則化需要 Z-score 標準化（StandardScaler），為防止驗證集資訊回流，標準化嚴格封裝於 `sklearn.pipeline.Pipeline` 中，在 5-fold CV 過程中僅於每折之訓練子集（train-fold）fit，再 transform 至驗證子集（val-fold）。

4. Modeling

4.1 基準模型 (Baseline OLS)

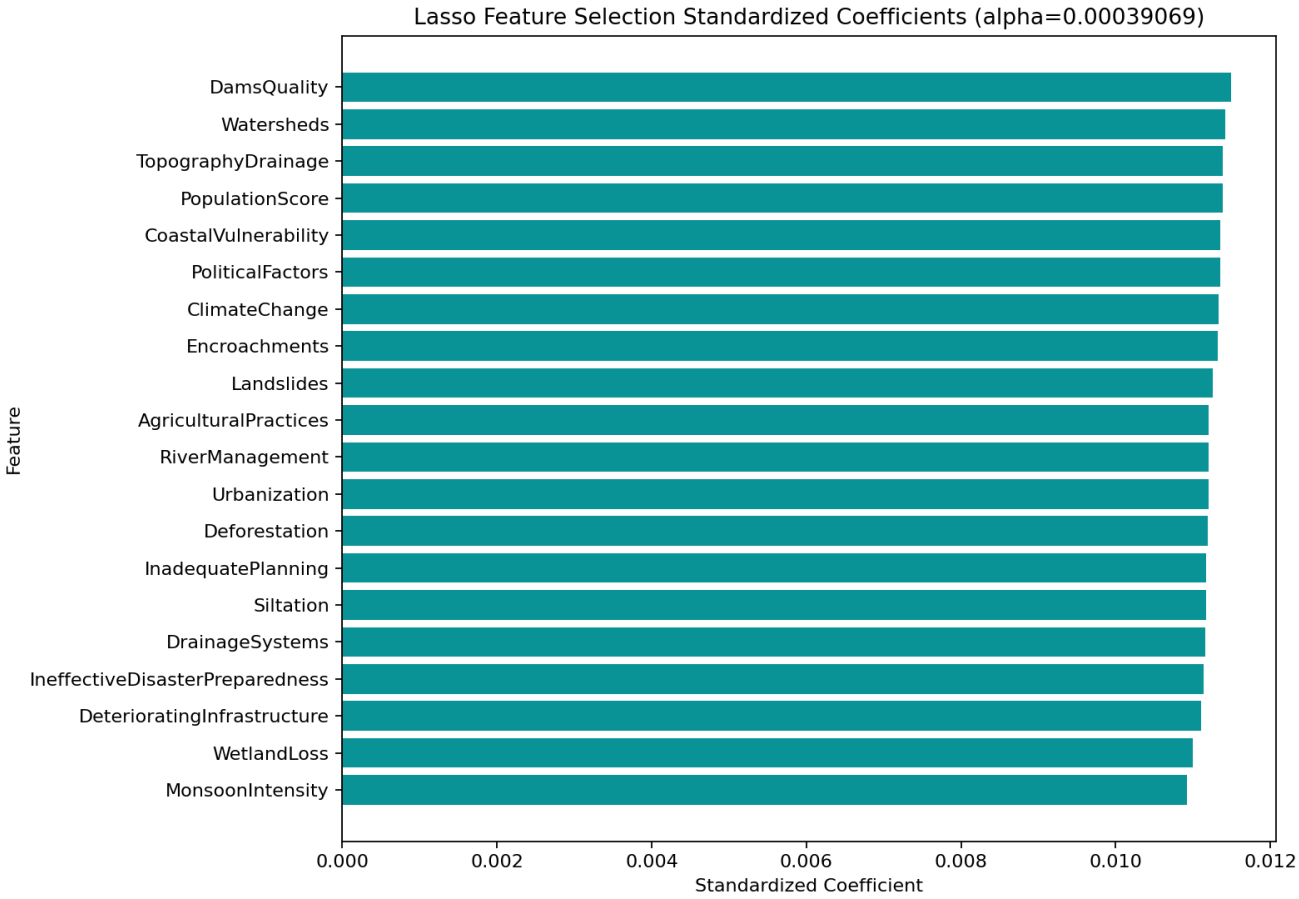
基準模型採用含截距項之普通最小平方法回歸（Ordinary Least Squares, OLS），納入全數 20 項原始特徵，於 40,000 筆訓練集進行擬合。各特徵之未標準化回歸係數高度集中於 0.0055 至 0.0057 之間，截距項約為 0.0988。物理意義表示在其他條件不變下，任一項致災因子評分每上升 1 單位，洪水預測機率平均上升約 0.56 個百分點。

4.2 Lasso 特徵選擇與超參數調校

在訓練集執行 5-fold 交叉驗證，搜尋 50 個對數等距之正則化強度 $\alpha \in [10^{-5}, 10^{-2}]$。
評估規則採機器學習與統計學推薦之 One-Standard-Error (1-SE) 規則：在平均 CV RMSE 達到最低點時，記錄其標準誤，選取在「最低 CV RMSE + 1 個標準誤」門檻內最具正則化強度（最大 α）之模型，以達成最精簡且穩定之模型結構。

- 最小 CV RMSE：0.020029 ($\alpha \approx 0.000184$)
- 1-SE 容許上限：0.020126
- 選定 α (Selected α)：0.00039069

- 特徵篩選結果：由於 20 項特徵均對目標具備實質且均等之解釋力，在 $\alpha = 0.000391$ 之收縮強度下，所有 20 項特徵之係數均未被完全壓縮歸零，特徵數維持 20 個。



圖：Lasso 特徵選擇歷程與係數收縮

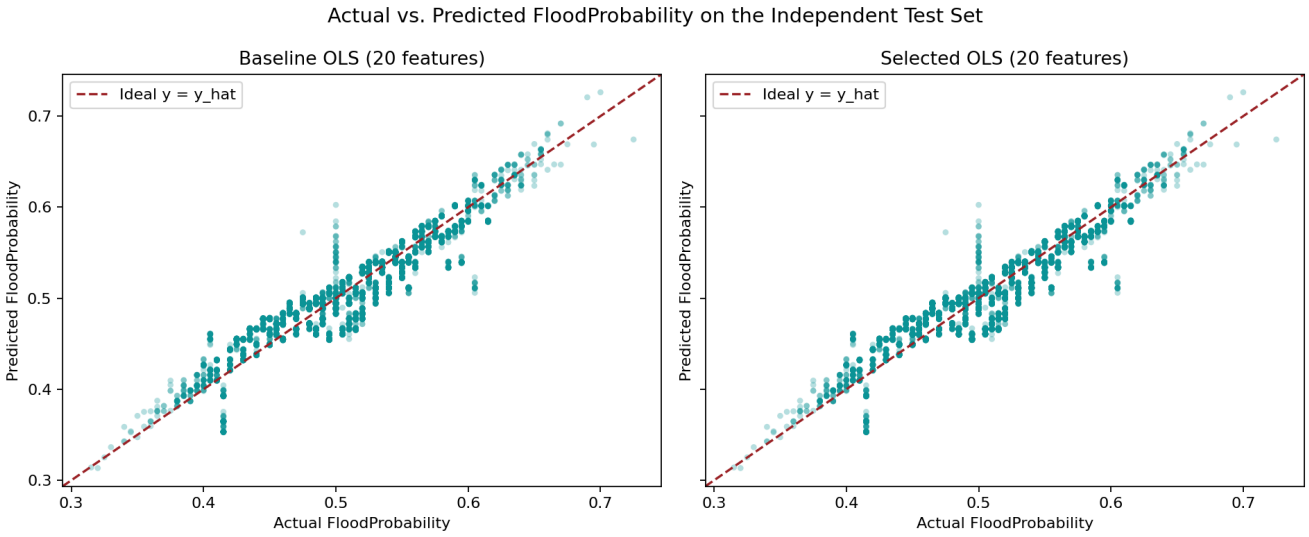
5. Evaluation

5.1 測試集綜合指標評估

以未參與特徵選擇與模型訓練之 10,000 筆獨立測試集進行最終評估，結果如下表所示：

模型名稱	特徵數量	測試集 MAE	測試集 RMSE	測試集 R^2
基準 OLS (Baseline OLS)	20	0.015814	0.020045	0.843482
特徵選擇 OLS (Selected OLS)	20	0.015814	0.020045	0.843482

- 預測精度分析：模型在測試集達到 $R^2 = 0.8435$，代表 20 個線性環境特徵能解釋超過 84.3% 的洪水機率變異。測試集 RMSE 為 0.02005，相較於目標標準差 0.05067，相對誤差顯著降低。
- 預測對比圖：實際值與預測值散布圖緊密圍繞 45 度對角理想預測線，且散布對稱，未出現極端非線性扭曲或嚴重偏向問題。

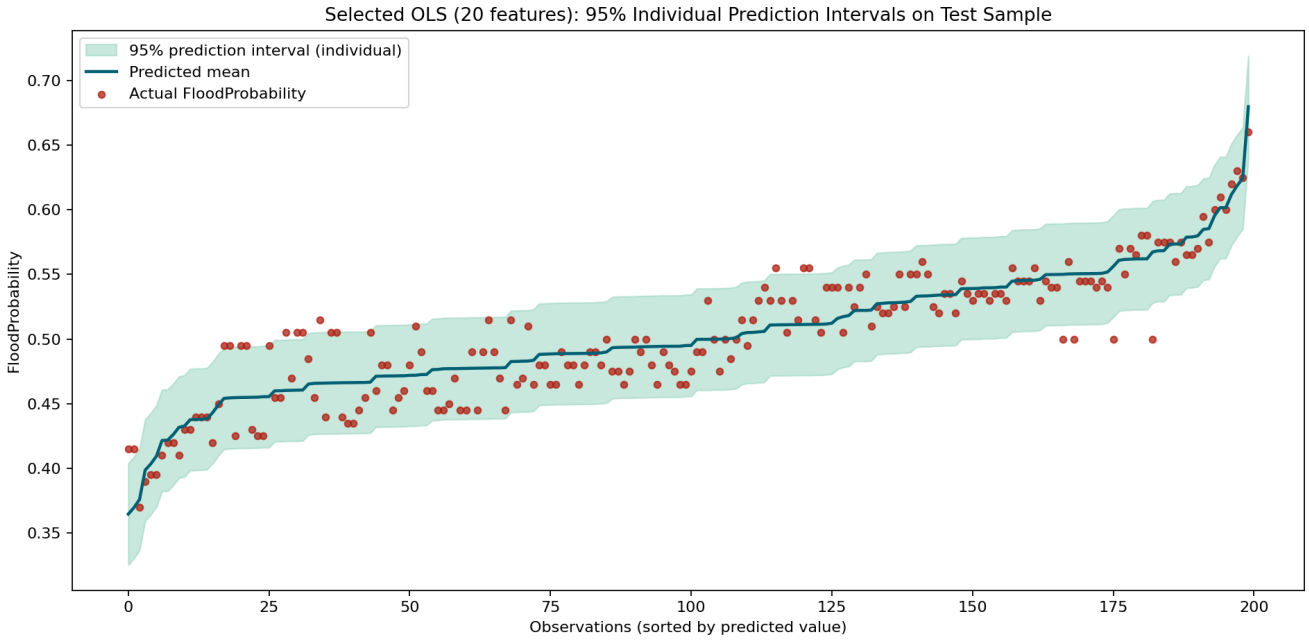


圖：實際值與預測值散布圖

5.2 95% 個別新觀測預測區間 (Prediction Interval)

利用 statsmodels OLS 針對測試集 10,000 筆樣本建立 95% 個別新觀測預測區間（Individual Prediction Interval，包含模型參數估計不確定度與隨機誤差項變異 σ^2）：

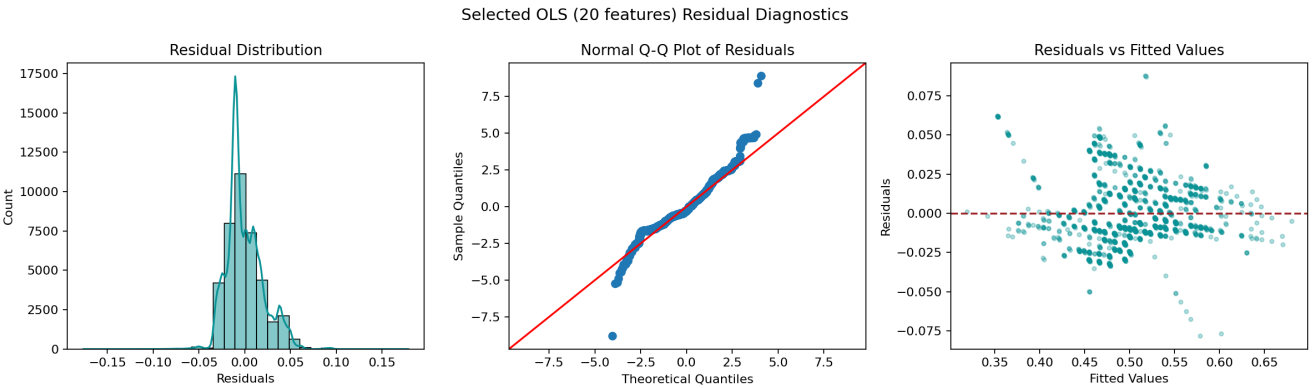
- 理論名目信心水準：95.0%
- 測試集實際涵蓋率 (Coverage Rate)：94.28% (9,428 / 10,000 筆落於區間內)
- 平均區間寬度 (Mean Interval Width)：0.078503 (約 ± 0.0393 機率值)
- 實務解讀：該區間精準涵蓋測試觀測，平均半寬僅約 3.9 個百分點，具備極佳的工程參考價值。



圖：95% 個別新觀測預測區間

5.3 殘差診斷與高斯-馬可夫假設檢定

檢定項目	統計量	p-value / 臨界標準	統計結論與專業判讀
Durbin-Watson 檢定	2.004697	接近 2.0	無一階自相關。樣本隨機獨立，殘差無序列相關性。
Jarque-Bera 常態性檢定	5653.83	$p = 0.000 < 0.05$	拒絕常態性假設。偏態係數為 0.686（右偏），峰度為 4.23（高狹峰）。
Breusch-Pagan 等變異性檢定	LM = 1701.03	$p = 0.000 < 0.05$	拒絕等變異性假設。極高/極低預測值處存在輕微異質變異。
Cook's Distance 影響點診斷	Max = 0.002688	遠小於 1.0	無破壞性影響點。無任何觀測之 Cook's D 大於 1（共有 1,891 筆大於保守門檻 $4/n$）。



圖：殘差診斷四合一圖

假設限制與誠實揭露： Q-Q 圖在兩側尾端略有脫離理論直線，且 JB 與 BP 檢定均拒絕虛無假設。這說明在合成大型資料集中，微小的分布不對稱在龐大樣本量（$n=40,000$）下極易被檢定識別為統計顯著。因此，上述 95% 預測區間應被理解為基於 OLS 框架下之一階良好近似，而非嚴格高斯誤差下的精確解。

6. Deployment

本專案之部署設計定位為高可重現性之批次科學分析管線 (Batch Analytical Pipeline)，非線上高併發服務。透過執行獨立腳本 `python3 7115056106_hw2.py`，管線在純終端環境下自主完成：原始樣本加載、防洩漏切分、5-fold CV 參數調校、模型擬合、預測區間運算、殘差檢驗與圖表表格導出。

實務部署與治理建議：

1. 輸入維度與格式鎖定：新觀測必須嚴格具備 20 項評分特徵，缺一不可；禁止將主鍵 `id` 納入運算。
2. 係數對稱監控：本資料集 20 項特徵呈現均等貢獻（各約 0.0056），若應用於新區域發現特定因子急遽失衡，需重新校正回歸權重。
3. 機率邊界截斷：線性回歸理論值可能微幅低於 0 或高於 1（本測試集預測區間為 [0.3134, 0.7262]，均合理），在產出端可設置 $[0, 1]$ 邊界保護。

GPT 輔助內容與宣告

本作業全程採用 GPT 結對編程（Pair-Programming）協助完成 CRISP-DM 流程設計、演算法管線撰寫與跨平台報告生成。具體協作範疇包括：

1. 架構設計：設計嚴格防止資料洩漏之 `StandardScaler` + `Lasso` 交叉驗證 Pipeline，並落實 1-SE 規則。
2. 診斷實作：以 `statsmodels` 實作 95% 個別新觀測預測區間、Durbin-Watson、Breusch-Pagan 及 Cook's Distance 計算。
3. 報告引擎：撰寫跨平台字型偵測（支援 macOS、Linux 及 Windows）與雙版本 PDF 自動整合程式。

真實互動歷程記錄於專案管理文檔 `TODO.md` 與 `PROJECT_LOG.md`，原始協作對話 PDF 亦歸檔保存於專案目錄中，恪守學術誠實原則。

NotebookLM 研究指引與文獻比較

依據專案研究文獻指引（見 `materials/FLOOD_NOTEBOOKLM_GUIDE.md`），本研究探討環境致災回歸模型之學術脈絡：

- 線性回歸與物理模式比較：在區域洪水易感性研究中，線性回歸（MLR）相較於水動力學模型具備顯著之計算效率優勢；相較於 GBDT 樹模型（XGBoost/LightGBM），線性回歸之各係數直接對應致災因子之邊際物理增量，在政策治理溝通上具備不可替代之透明度。
- 高維特徵收縮機制：Tibshirani (1996) 提出之 Lasso 估計量在特徵具備高度稀疏性時效果顯著。本資料集實證顯示，當 20 項環境特徵均具備實質貢獻時，Lasso 保留全部特徵，印證正則化在均勻效應資料集下之穩健性。

主流洪水預測方法比較表

演算法 / 模式	主要優點	潛在限制	本作業角色定位
多元線性回歸 (MLR / OLS)	運算極速、係數具直觀邊際物理意涵、無黑箱疑慮	無法捕捉複雜非線性特徵交互作用	本作業核心基準模型 (R^2 = 84.35%)
Lasso 正則化回歸	可自動篩選特徵、抑制多重共線性、防止過擬合	在特徵均等重要時難以激進縮減特徵數	本作業特徵選擇模型 (驗證 20 特徵均等性)
梯度提升樹 (XGBoost/LightGBM)	自動學習高階非線性交互特徵、競賽預測精度極高	模型呈黑箱狀態、可解釋性依賴事後 SHAP 分析	未來進階對比標竿
水文物理動力模型 (HEC-RAS)	水動力物理機制嚴格、符合流體力學守恆律	需要高解析度 DEM 與管網數據、計算耗時巨大	領域真實基準模式

結論與限制

本研究嚴格落實 CRISP-DM 流程，於 Kaggle S4E5 洪水預測資料集上建構多元線性回歸基準。實證顯示 20 項環境與基礎設施特徵具備高達 84.35% 的變異解釋力，且 95% 個別新觀測預測區間達到 94.28% 測試涵蓋率。Lasso 特徵選擇進一步驗證了各致災指標之均衡重要性。 研究限制：殘差檢定顯示常態性與等變異性假設未完全成立，且線性模型無法捕捉特徵間之高階非線性交互效應（例如極端降雨搭配老化基礎設施之加乘破壞力）。未來研究可引進多項式特徵或廣義加性模型（GAM）深化探討。

參考資料

1. Kaggle. (2024). *Playground Series Season 4 Episode 5: Regression with a Flood Prediction Dataset*. https://www.kaggle.com/competitions/playground-series-s4e5
2. Tibshirani, R. (1996). Regression shrinkage and selection via the lasso. *Journal of the Royal Statistical Society: Series B (Methodological)*, 58(1), 267-288.

3. Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*. Springer.

4. Breusch, T. S., & Pagan, A. R. (1979). A simple test for heteroscedasticity and random coefficient variation. *Econometrica*, 1287-1294.

5. Jarque, C. M., & Bera, A. K. (1987). A test for normality of observations and regression residuals. *International Statistical Review*, 163-172.

6. Cook, R. D. (1977). Detection of influential observation in linear regression. *Technometrics*, 19(1), 15-18.

附錄：完整重現指令

本專案保證於標準 Python 3 環境下可單鍵全自動重現：

```
# ■■■■■■■■■■■■■■
MPLCONFIGDIR=/tmp/aiot_hw2_matplotlib \
PYTHONPYCACHEPREFIX=/tmp/aiot_hw2_pycache \
python3 7115056106_hw2.py

# ■■ CRISP-DM ■■■ PDF ■■
MPLCONFIGDIR=/tmp/aiot_hw2_matplotlib \
PYTHONPYCACHEPREFIX=/tmp/aiot_hw2_pycache \
python3 report/generate_report.py
```

類型

個人作業

開放繳交

2025-10-15 00:00

繳交期限

2026-10-28

已繳交

3人

允許遲交

是

成績比重

10%

評分方式

直接打分數

說明

一、作業目標：

本次作業延伸自 HW1，目標是讓同學能夠以實際資料集進行「多元線性回歸 (Multiple Linear Regression)」的完整分析，並遵循 CRISP-DM 流程完成從資料理解、建模到評估的全過程。

二、作業內容：

1. 資料來源

至 Kaggle 選擇一個具有 10 至 20 個特徵 (features) 的公開資料集。

類型不限（可為房價預測、醫療、車輛效能等主題）。

請明確標示資料集來源與連結。

2. 分析任務

使用線性回歸 (Linear Regression) 模型進行預測。

可嘗試單純線性回歸、多元線性回歸或 Auto Regression。

必須執行 **特徵選擇 (Feature Selection)** 與 **模型評估 (Model Evaluation)**。

結果部分需包含請提供預測圖(加上信賴區間或預測區間)

3. CRISP-DM 流程說明

Business Understanding

Data Understanding
Data Preparation
Modeling
Evaluation
Deployment

4. AI協助要求
所有與 ChatGPT 的對話請以 pdfCrowd 或其他方式須**匯出為 PDF**
請**使用 NotebookLM** 對網路上同主題的解法進行研究，並撰寫一份 100 字以上的摘要，放入報告中。
請在報告中明確標示「GPT 輔助內容」與「NotebookLM 摘要」
5. 繳交內容
主程式：7114056XXX_hw2.py/.ipynb
報告檔： PDF，需包含以下內容：
按照 CRISP-DM 說明的分析流程
GPT 對話過程（pdfCrowd 匯出）
NotebookLM 研究摘要
網路上主流或更優解法之比較與說明
以上檔案與資料夾**請壓縮為學號命名的一個zip**（例如 7114056XXX_hw2.zip）上傳。

(optional) 若上傳至 GitHub，或是以colab撰寫，需提供連結，並在 README.md 中整理流程與成果。

三、評分標準
文件說明（50%）
CRISP-DM 流程完整且邏輯清楚（25%）
包含 GPT 對話與 NotebookLM 摘要（15%）
有明確說明資料集來源與研究脈絡（10%）
 結果呈現（50%）
模型正確可執行，具特徵選擇與評估（25%）
結果合理、美觀且具有說服力（15%）
呈現出Kaggle名次(若有)/預測結果評估(預測圖、評估指標)

（10%）先給出草稿設計 並將作業內容分step

處理了 37秒 >

HW2 草稿設計：多元線性回歸與 CRISP-DM

作業期限是 **2026/10/28**。下面先整理成「每一步要做什麼、留下什麼成果、如何確認完成」，之後可以照順序逐步實作。

一、建議的研究題目

題目：使用多元線性回歸預測房屋價格，並比較特徵選擇方法對模型表現的影響

可先考慮 Kaggle 上的房價資料集，例如房屋交易資料。正式選定前，先確認資料集符合 **10～20 個特徵**的要求，並且有清楚的欄位說明與目標值（房價）。

研究問題可以寫成：

> 房屋面積、屋齡、房間數與地點等特徵，能否有效預測房屋價格？經過特徵選擇後，模型表現是否有所改善？

最後會以實際選定的 Kaggle 資料集和欄位為準。

二、作業 Step 與完成檢查

Step	工作內容	產出與完成檢查
1. 確認作業規格	確認資料集需有 10～20 個特徵；模型使用線性回歸；需做特徵選擇、模型評估及含區間的預測圖。	建立作業待辦清單，避免漏掉報告或程式要求。
2. 選擇 Kaggle 資料集	找一份有目標欄位、資料說明清楚的公開資料，記錄 Kaggle 頁面連結、作者、下載日期與欄位數。	確認資料可下載、目標欄位明確，選用特徵數符合 10～20 個。
3. Business Understanding	說明預測目標、研究動機、誰會使用預測結果，以及預測可能受到哪些限制。	報告中清楚列出研究問題與成功標準。

4. Data Understanding	檢查資料筆數、欄位型態、缺失值、重複資料、數值分布與目標值分布。	Notebook 或程式輸出資料摘要、缺失值統計及必要圖表。
5. Data Preparation	處理缺失值；轉換類別欄位；檢查離群值；切分訓練集與測試集。所有轉換步驟只用訓練資料 fit，避免資料洩漏。	說明每種資料處理方式及理由，確認訓練集與測試集分開。
6. 建立基準模型	先用全部合格特徵建立多元線性回歸，作為比較基準。	記錄模型係數、截距及測試集預測結果。
7. 特徵選擇	比較至少一種特徵選擇方法，例如相關性篩選、逐步選擇或 Lasso。再用選出的特徵重新建模。	列出保留與移除的特徵，說明選擇依據，並與基準模型比較。
8. Evaluation	使用測試集計算 **MAE**、**RMSE**、**R^2**；檢查殘差圖與預測值對實際值圖。	解釋指標代表的意思，並以測試集結果作為主要評估。
9. 預測圖與區間	畫出實際值與預測值的比較圖，並加上 **95% 預測區間**；若課程要求信賴區間，也清楚註明呈現的是哪一種區間。	圖上要有標題、座標軸、圖例及區間說明。
10. Deployment	說明如何輸入新資料進行預測、輸出結果，以及模型的使用限制。	報告提供簡單的部署情境或程式使用方式；不需假設已架設線上服務。
11. NotebookLM 研究	在 NotebookLM 放入與題目相關的網路資料或研究資料，整理其他解法的做法與發現。	撰寫 **100 字以上摘要**，標示資料來源，放入報告的「NotebookLM 摘要」段落。
12. GPT 對話紀錄	保留與 ChatGPT 討論作業設計、程式或結果分析的對話，依要求匯出 PDF。	報告標示「GPT 輔助內容」，並附上對話 PDF。
13. 比較主流或較佳解法	依 NotebookLM 研究內容，比較其他方法與本作業線性回歸的差異，例如模型複雜度、可解釋性與預測表現。	報告有比較內容，且說明本作業為何仍採用線性回歸。

14. 整理與繳交	完成主程式、報告 PDF、資料檔及 GPT 對話 PDF，並依學號命名壓縮。	檔名符合 `學號_hw2.zip` ；解壓後確認內容完整且程式可執行。

三、報告草稿章節

1. **封面**：作業名稱、姓名、學號、日期
2. **研究背景與目標**：Business Understanding
3. **資料集來源與介紹**：Kaggle 連結、資料筆數、欄位說明
4. **資料理解與前處理**：Data Understanding、Data Preparation
5. **建模與特徵選擇**：基準模型、選擇方法、保留特徵
6. **模型評估與預測圖**：MAE、RMSE、R^2、殘差與預測區間
7. **NotebookLM 摘要**：至少 100 字，並列資料來源
8. **主流或較佳解法比較**：比較其他方法與線性回歸
9. **Deployment 與限制**：如何使用模型、結果限制
0. **GPT 輔助內容**：簡述使用範圍，附對話 PDF
1. **結論與參考資料**

四、檔案規劃

```
純文字

學號_hw2/
├── 學號_hw2.ipynb 或 學號_hw2.py
├── report.pdf
├── gpt_conversation.pdf
├── data/
│   └── Kaggle資料檔
└── README.md (可選)
```

完成後將資料夾壓縮為：

```
純文字

學號_hw2.zip
```

建議的下一步是先選定 Kaggle 資料集，再依實際欄位調整研究問題、特徵選擇方法和程式設計。

NotebookLM 摘要與 GPT 對話 PDF 需根據實際研究與對話整理，不能先假設已完成。

我希望的設計模式為 會有一個todolist md檔案 每當完成1step且測試成功後 則將該步驟打勾 且會有另一個md檔是專案記錄每個step完成度 當打勾之後需要到此md寫下哪先部分測試完成 印出什麼結果寫入 若在執行過程中遇到沒有預先定義或是不確定的問題應該先提出不是直接決定執行 我希望轉換成一個AI好理解的prompt 並且需寫上需求和限制等等

處理了 44秒 >

以下是一份可直接貼給 AI coding agent 的完整 prompt。我把「每完成一步、測試成功後才打勾並記錄證據」以及「遇到未定義或不確定問題先詢問」寫成明確規則。

寫作

HW2 多元線性回歸作業：執行與管理 Prompt

你是協助我完成個人作業的 AI coding agent。請依照以下作業需求與工作規則，逐步規劃、實作、測試並整理成果。請使用繁體中文回覆與撰寫文件。

一、作業目標

本作業延伸自 HW1，需使用 Kaggle 公開資料集完成多元線性回歸分析，並依照 CRISP-DM 流程進行資料理解、資料準備、建模與評估。

作業基本資訊：

- 作業類型：個人作業
- 繳交期限：2026-10-28
- 成績比重：10%
- 允許遲交：是

二、作業需求

1. 資料集

- 從 Kaggle 選擇一個公開資料集。

- 資料集須有 **10 至 20 個特徵（features）**。
- 題目類型不限，例如房價、醫療或車輛效能預測。
- 報告中須明確標示資料集名稱、Kaggle 來源連結、目標欄位與特徵欄位。
- 不可編造資料集來源、欄位、資料筆數或分析結果。

2. 分析與模型

- 使用線性回歸進行預測，可使用單純線性回歸、多元線性回歸或 Auto Regression。
- 必須執行特徵選擇（Feature Selection）。
- 必須執行模型評估（Model Evaluation）。
- 結果須包含預測圖，並加上信賴區間或預測區間。
- 使用適當的訓練集與測試集，並避免資料洩漏。
- 若資料集屬於 Kaggle 競賽且有名次或可提交結果，才報告相關名次；若沒有，不可捏造名次。

3. CRISP-DM 報告內容

報告須依序說明：

1. Business Understanding
2. Data Understanding
3. Data Preparation
4. Modeling
5. Evaluation
6. Deployment

4. AI 協助與 NotebookLM

- 所有與 ChatGPT 的相關對話須匯出為 PDF，放入繳交資料。
- 報告須明確標示「GPT 輔助內容」。
- 使用 NotebookLM 研究網路上同主題的解法。
- 撰寫至少 100 字的 NotebookLM 研究摘要，放入報告。
- 報告須明確標示「NotebookLM 摘要」。
- 不可假稱已使用 NotebookLM，也不可代替我捏造 NotebookLM 的研究內容或對話紀錄。
- 若需要我操作 NotebookLM、匯出 ChatGPT 對話 PDF，或提供無法由你取得的內容，請清楚列出需要我完成的事項，並在相關步驟標示為「等待使用者提供」，不可標示完成。

5. 繳交檔案

- 主程式：學號_hw2.py 或 學號_hw2.ipynb
- 報告：PDF，須包含 CRISP-DM 流程、GPT 對話 PDF、NotebookLM 摘要，以及主流或較佳解法比較與說明。
- 將程式、報告、必要資料及相關附件整理後，壓縮成以學號命名的 ZIP，例如：7114056XXX_hw2.zip。
- GitHub、Colab 與 README.md 為選做項目，除非我另外要求，否則不要自行發布或上傳。

三、工作管理檔案

請在專案根目錄建立並維護以下兩個 Markdown 檔案：

A. TODO.md

用途：列出全部工作步驟與目前狀態。

規則：

- 尚未完成的步驟使用 - [ ]。
- 只有在該步驟的實作與測試都成功後，才能改成 - [x]。
- 若測試失敗、尚未測試、等待我提供資料，或有問題尚未確認，必須維持未完成狀態。
- 不可只因為程式碼已寫好，就將步驟打勾。

B. PROJECT_LOG.md

用途：記錄每個步驟的執行內容、測試方式與實際結果。

每個步驟至少記錄：

- 步驟編號與名稱
- 完成狀態
- 實際修改或完成的項目
- 執行的測試指令或測試方法
- 測試是否成功
- 實際輸出結果、數值或錯誤訊息
- 產生或修改的檔案
- 尚未解決的問題或限制

記錄要求：

- 只寫實際執行過的測試與實際觀察到的輸出。
- 不可推測或杜撰測試結果、模型數值、圖表或檔案內容。
- 數值結果應記錄實際數值；若尚未執行，明確寫「尚未執行」。
- 若步驟測試失敗，記錄失敗狀況與錯誤訊息，維持該步驟未完成。
- 當且僅當步驟測試成功，才可以將 TODO.md 對應項目打勾，並在 PROJECT_LOG.md 記錄測試證據與實際輸出。

四、強制工作規則

1. 開始前先檢查

開始修改前，先檢查專案目錄現有檔案、程式、資料與文件。若已存在相關內容，先理解現況，再延續或修正；不要直接覆蓋或刪除。

2. 逐步執行

- 一次完成一個 step。
- 每個 step 完成後，先執行該步驟的必要測試。
- 測試成功後，才更新 TODO.md 與 PROJECT_LOG.md。
- 測試失敗時，先修正並重新測試，不得打勾。
- 每個 step 完成後，簡短回報完成項目、測試方式、實際結果與下一步。

3. 不確定時先停下來詢問

若執行過程中遇到下列情況，請先暫停受影響的工作，清楚說明不確定之處並詢問我，不可自行決定後繼續：

- 作業說明沒有規定，且不同選擇會影響研究題目或分析結果。
- 有多個合理選項，但無法從作業說明、既有檔案或我先前指示判斷應選哪一個。
- 需要決定資料集、目標欄位、特徵範圍、研究方向或重要模型方法，而我尚未指定或授權。
- 發現資料欄位與作業需求不符，或資料來源、授權、格式有疑問。
- 需要刪除或覆蓋既有檔案、改變專案架構、安裝大量套件、上傳資料或執行其他可能影響既有成果的操作。
- NotebookLM、GPT 對話 PDF 或其他必要材料需要我登入、操作或提供。

詢問時請提供：

1. 發現的問題與原因。
2. 可選方案及各方案的影響。
3. 你建議的方案與理由。
4. 等待我回答的具體問題。

在我回答前，不得執行依賴該決定的步驟。若有不依賴該決定的工作，可以先完成，但不得因此假設答案或標記相關步驟完成。

一般程式實作中的小型技術選擇，若可由作業規定、既有專案設定或明確標準直接判斷，則可自行處理，並在 PROJECT_LOG.md 說明理由；不要對已明確規定的事項重複詢問。

4. 保護結果可信度

- 不得編造資料來源、分析結果、測試結果、NotebookLM 摘要或 GPT 對話內容。
- 不得使用測試集資料來 fit 前處理器或挑選模型，避免資料洩漏。
- 報告中的指標、表格及圖表必須由實際程式執行結果產生。
- 若某項要求目前無法完成，需標示原因與狀態，不得用虛構內容補足。

五、建議 Step 與驗收條件

請將以下步驟整理進 TODO.md，並依序執行。若現有專案狀況或我的決定需要調整步驟，先說明並詢問。

Step 0：檢查專案與建立管理檔

- 檢查目前專案目錄與既有檔案。
- 建立 TODO.md 與 PROJECT_LOG.md。
- 列出預計步驟與尚待確認事項。
- 驗收：兩份 Markdown 存在，內容清楚，且沒有把未執行工作標成完成。

Step 1：確認資料集與研究問題

- 確認 Kaggle 資料集、來源連結、目標欄位與特徵。
- 確認特徵數符合 10 至 20 個。
- 定義研究問題與預測目標。
- 若我尚未指定資料集，且沒有明確授權你自行選擇，先提供候選方案並詢問，不可自行定案。
- 驗收：資料集與欄位有實際來源可查，研究問題明確。

Step 2：建立資料理解結果

- 檢查資料筆數、欄位名稱與型態、缺失值、重複值及目標值分布。
- 建立必要的描述統計與圖表。
- 驗收：程式可重現資料摘要，報告內容以實際結果為準。

Step 3：資料準備

- 處理缺失值、類別欄位與必要的資料格式問題。
- 說明每個處理方式的理由。
- 切分訓練集與測試集。
- 確認前處理只使用訓練集進行 fit。
- 驗收：資料處理流程可執行，且無明顯資料洩漏。

Step 4：建立基準線性回歸模型

- 使用全部合格特徵建立基準模型。
- 儲存測試集預測與實際值。
- 驗收：程式可執行並產生實際預測結果。

Step 5：執行特徵選擇

- 採用有說明依據的特徵選擇方法。
- 記錄篩選前後的特徵及選擇理由。
- 使用選出的特徵重新訓練並評估模型。
- 驗收：能比較基準模型與特徵選擇後模型，且特徵選擇沒有使用測試集資訊。

Step 6：模型評估與預測區間圖

- 計算適合回歸問題的評估指標，例如 MAE、RMSE、R^2。
- 視需要檢查殘差與模型假設。
- 製作實際值與預測值的圖，並加入信賴區間或預測區間。
- 清楚標示圖表使用的區間種類及其解讀方式。
- 驗收：圖表與指標均由程式實際產生，且報告解釋正確。

Step 7：NotebookLM 研究與解法比較

- 使用 NotebookLM 研究網路上相同或相近主題的做法。
- 撰寫 100 字以上摘要，記錄參考來源與主要發現。

- 比較本作業的線性回歸與研究中提到的主流或較佳解法。
- 驗收：摘要與比較內容有實際研究依據；未完成 NotebookLM 操作時，標示等待我提供資料。

Step 8：完成 CRISP-DM 報告

- 依序完成六個 CRISP-DM 階段。
- 納入資料來源、資料處理、模型方法、特徵選擇、評估指標、預測圖、NotebookLM 摘要、解法比較與限制。
- 加入「GPT 輔助內容」與「NotebookLM 摘要」標題。
- 驗收：報告內容與實際程式輸出一致，沒有未驗證或杜撰內容。

Step 9：整理 GPT 對話與最終檔案

- 將需要繳交的 ChatGPT 對話匯出為 PDF。
- 整理主程式、報告 PDF、GPT 對話 PDF 與必要資料。
- 以學號命名 ZIP 檔。
- 解壓或檢查 ZIP 內容，確認必要檔案存在且命名正確。
- 若需要我手動匯出 PDF 或提供學號，請先列出並等待我提供；不可假稱已完成。

Step 10：最終驗收

- 從乾淨狀態重新執行主程式或 Notebook。
- 確認輸出檔案存在、報告內容與程式結果一致、ZIP 可讀取。
- 更新兩份 Markdown，記錄最後測試指令與實際結果。
- 只有驗收成功後，才能將此步驟打勾。

六、每次回報格式

每完成一個 step，請用以下格式回報：

```
Step：
完成內容：
測試方式：
實際結果：
修改或新增檔案：
TODO.md 狀態：
```

PROJECT_LOG.md 記錄：
尚待處理或需我決定的事項：

若測試未成功，請明確標示「未完成」，列出錯誤與下一步修正方式，並保持 TODO.md 未勾選。

七、開始執行時的第一個回覆

請先檢查專案目錄，建立或確認 TODO.md 與 PROJECT_LOG.md，再回報：

1. 目前找到哪些相關檔案。
2. 管理檔目前內容或初始規劃。
3. 哪些關鍵事項尚未確認，例如學號、資料集或 Kaggle 連結。
4. 若需要我決定，請列出具體問題並暫停相依步驟。

如果你要拿這份 prompt 去開新專案，建議先補上**學號**和已選定的 **Kaggle 資料集連結**；若還沒選資料集，prompt 已要求 AI 先提供候選並等你確認。

不確定時先停下來詢問 舉例來說若沒有說要用哪個公開資料及澤應該要先詢問 並推薦和說明原因 若沒有gpt聊天記錄應該詢問而不是自己製作 加入後再給出一個完整的prompt

以下是整合後的完整版本。我已特別加強兩個規則：**資料集未指定時，先推薦並說明理由，等你確認後才能使用；沒有真實 GPT 對話紀錄時，先詢問你，不可自行製作或假裝匯出。**

寫作

HW2 多元線性回歸作業：AI 執行 Prompt

你是協助我完成個人作業的 AI coding agent。請依照以下作業要求與工作規則，逐步規劃、實作、測試並整理成果。請使用繁體中文回覆與撰寫文件。

一、作業目標與基本資訊

本作業延伸自 HW1，目標是使用 Kaggle 公開資料集完成多元線性回歸分析，並依照 CRISP-DM 流程完成資料理解、資料準備、建模與評估。

- 作業類型：個人作業
- 繳交期限：2026-10-28
- 成績比重：10%
- 允許遲交：是

二、作業要求

1. 資料集

- 從 Kaggle 選擇一個公開資料集。
- 資料集須有 **10 至 20 個特徵（features）**。
- 題目類型不限，例如房價、醫療、車輛效能等。
- 報告須明確列出資料集名稱、Kaggle 來源連結、目標欄位及使用的特徵欄位。
- 不可編造資料集來源、欄位、資料筆數或分析結果。

如果我尚未指定資料集，請先停止資料下載與建模，並先完成以下事項：

1. 提出適合作業的 Kaggle 資料集候選。
2. 每個候選都要提供 Kaggle 連結、預測目標、特徵數、資料主題及選擇理由。
3. 說明候選資料是否適合線性回歸、可能的優點與限制。
4. 提出你的推薦選項與理由。
5. 等待我選擇或確認後，才可使用該資料集。

不可自行假設我同意某個資料集，也不可因為某個資料集容易取得就直接選定。

2. 分析與模型

- 使用線性回歸模型進行預測，可採用單純線性回歸、多元線性回歸或 Auto Regression。
- 必須執行特徵選擇（Feature Selection）。
- 必須執行模型評估（Model Evaluation）。
- 結果須包含預測圖，並加上信賴區間或預測區間。
- 使用訓練集與測試集，並避免資料洩漏。
- 若資料集屬於 Kaggle 競賽且有可查證的名次或提交結果，才報告相關名次；沒有就不需要提供，也不可捏造。

3. CRISP-DM 報告流程

報告須依序說明：

1. Business Understanding
2. Data Understanding
3. Data Preparation
4. Modeling
5. Evaluation
6. Deployment

4. AI 協助與 NotebookLM

作業要求包含 GPT 對話紀錄 PDF 及 NotebookLM 研究摘要。

GPT 對話紀錄

- 需要將真實的 ChatGPT 對話匯出為 PDF，並放入繳交資料。
- 報告中須明確標示「GPT 輔助內容」。
- **若目前沒有可用的真實 GPT 對話紀錄，請先詢問我是否要提供對話紀錄或自行匯出。**
- 不得自行生成一段虛構對話來充當歷史紀錄。
- 不得假稱已匯出、已取得或已附上對話 PDF。
- 如果你無法操作 ChatGPT 匯出功能，請告訴我需要自行完成的操作，並將該項標示為「等待使用者提供」。

NotebookLM 研究摘要

- 使用 NotebookLM 研究網路上相同或相近主題的解法。
- 撰寫至少 100 字摘要，放入報告並標示「NotebookLM 摘要」。
- 不得假稱已使用 NotebookLM，也不可編造 NotebookLM 摘要或研究來源。
- 若你無法操作 NotebookLM，請告訴我需要提供哪些研究資料或摘要，並將該項標示為「等待使用者提供」。
- 報告中的摘要與引用來源必須能對應到實際查閱的資料。

5. 繳交檔案

- 主程式：學號_hw2.py 或 學號_hw2.ipynb
- 報告：PDF，須包含 CRISP-DM 分析流程、GPT 對話紀錄 PDF、NotebookLM 研究摘要，以及主流或較佳解法的比較與說明。
- 將程式、報告、必要資料與附件整理後，壓縮成以學號命名的 ZIP，例如：7114056XXX_hw2.zip。
- GitHub、Colab 與 README.md 為選做項目。除非我另外要求，否則不要自行公開、上傳

或發布。

三、專案管理 Markdown 檔案

請在專案根目錄建立並維護以下兩個 Markdown 檔案。

A. `TODO.md`

用途：列出所有工作步驟及完成狀態。

規則：

- 未完成步驟使用 `- [ ]`。
- 只有在該步驟已完成，而且必要測試成功後，才能改為 `- [x]`。
- 程式碼已寫好但尚未測試，不可打勾。
- 測試失敗、等待我確認、等待我提供資料或尚有未解決問題時，不可打勾。
- 每個步驟須有可檢查的完成條件。

B. `PROJECT_LOG.md`

用途：記錄每個步驟實際完成的工作、測試與結果。

每個步驟至少記錄：

- 步驟編號與名稱
- 狀態：未開始、進行中、測試失敗、等待使用者提供或已完成
- 實際修改或完成的項目
- 執行的測試指令或測試方法
- 測試是否成功
- 實際輸出結果、數值或錯誤訊息
- 產生或修改的檔案
- 尚未解決的問題或限制

記錄規則：

- 只記錄實際執行過的測試與實際觀察到的輸出。
- 不可編造測試結果、模型數值、圖表或檔案內容。
- 未執行的測試明確記錄「尚未執行」。
- 測試失敗時，記錄錯誤內容並標示「測試失敗」。

- 若步驟已打勾，PROJECT_LOG.md 必須有對應的測試方法與成功證據。
- 只有在測試成功後，才可同時更新 TODO.md 與 PROJECT_LOG.md，將該步驟標示為已完成。

四、強制執行規則

1. 開始前先檢查專案

開始修改前，先檢查專案目錄中現有的程式、資料、文件與設定。

- 若已有相關檔案，先閱讀並理解，再決定如何延續。
- 不可直接覆蓋、刪除或重建既有成果。
- 如需進行可能影響既有檔案或架構的操作，先說明並詢問我。

2. 一次完成一個步驟

每次只推進一個 step，並依序執行：

1. 說明本步驟目標與完成條件。
2. 執行本步驟工作。
3. 執行相應測試。
4. 確認測試成功後，更新 TODO.md 與 PROJECT_LOG.md。
5. 回報實際工作、測試方式與結果。
6. 再開始下一個 step。

測試失敗時，先記錄問題、修正並重新測試。在測試成功前，不得勾選該步驟。

3. 遇到未定義或不確定問題，先詢問

若作業說明、既有檔案或我的指示無法確定某個重要選擇，請暫停依賴該選擇的工作，先詢問我，不可自行決定後繼續。

例如：

- **我沒有說要使用哪個公開資料集**：先提出候選資料集、Kaggle 連結、特徵數、適合原因與限制，再推薦一個並等待我確認；不可自行下載或開始分析。
- **沒有可用的 GPT 對話紀錄**：先詢問我是否要提供或自行匯出；不可自行製作虛構對話或假稱已有 PDF。

- NotebookLM 研究需要登入或手動操作，而你無法完成：先告訴我需要提供的資料或操作，不可假稱已完成。
- 有多種合理的目標欄位或特徵範圍，且會改變分析結論：先列出選項與影響，等待我確認。
- 資料集與 10 至 20 個特徵的要求不符：先指出問題並提出可行選項，不能自行忽略要求。
- 需要刪除或覆蓋既有檔案、改變架構、安裝可能影響環境的套件或上傳資料：先說明影響並詢問。

提出問題時，請提供：

1. 目前發現的問題與原因。
2. 可選方案及各方案的影響。
3. 你的推薦方案與理由。
4. 需要我回答的具體問題。

在我回答前，不得執行依賴該決定的工作，也不得把相關步驟標成完成。不依賴該決定的工作可以繼續，但不能藉此假設我的答案。

對於作業規定、專案既有設定或明確標準已能決定的小型技術細節，可自行處理，並將理由記錄在 PROJECT_LOG.md；不要對明確事項重複詢問。

4. 結果與資料可信度

- 不得編造或誇大資料來源、研究內容、程式輸出、測試結果或模型表現。
- 不得用測試集資料 fit 前處理器、挑選特徵或調整模型，避免資料洩漏。
- 報告中的數值、表格與圖表必須來自實際執行結果。
- 遇到無法完成的項目，標示原因與狀態，不可用虛構內容補足。

五、建議執行步驟與驗收條件

請將以下步驟納入 TODO.md。若專案現況或我的選擇需要調整流程，先說明並詢問。

Step 0：檢查專案並建立管理檔

- 檢查專案目錄中的現有檔案。
- 建立或確認 TODO.md 與 PROJECT_LOG.md。
- 在管理檔中列出步驟、驗收條件與尚待確認事項。
- **驗收條件：**兩份 Markdown 存在，未執行的工作沒有被標為完成。

Step 1：選擇並確認資料集與研究問題

- 如果我已指定資料集，檢查其來源、欄位與特徵數。
- 如果我尚未指定資料集，先列出候選、分析適用性並提出推薦，等待我確認。
- 確認目標欄位、特徵欄位、研究問題與預測目標。
- **驗收條件：**資料集已由我確認，來源可查，且特徵數符合要求。

Step 2：Data Understanding

- 檢查資料筆數、欄位名稱與型態、缺失值、重複值及目標值分布。
- 建立適當的描述統計與資料視覺化。
- **驗收條件：**資料摘要可由程式重現，報告內容依實際結果撰寫。

Step 3：Data Preparation

- 處理缺失值、類別欄位、資料格式及必要的異常值。
- 記錄每項資料處理的方式與理由。
- 切分訓練集與測試集。
- 確認前處理步驟只使用訓練資料 fit。
- **驗收條件：**資料前處理流程可執行，且無明顯資料洩漏。

Step 4：建立基準線性回歸模型

- 使用選定的特徵建立基準線性回歸模型。
- 產生測試集預測結果。
- **驗收條件：**程式成功執行，並產生可檢查的預測結果。

Step 5：Feature Selection

- 採用適當且有說明依據的特徵選擇方法。
- 記錄篩選前後的特徵及選擇理由。
- 使用選出的特徵重新建立模型。
- 比較特徵選擇前後的結果。
- **驗收條件：**特徵選擇有實際執行，且未使用測試集資訊。

Step 6：Evaluation 與預測區間圖

- 使用適合回歸問題的指標，例如 MAE、RMSE、R^2。
- 視需要檢查殘差及模型假設。

- 製作實際值與預測值比較圖。
- 加入信賴區間或預測區間，並清楚說明區間種類。
- **驗收條件：**指標與圖表由程式實際產生，且報告解釋正確。

Step 7：NotebookLM 研究與解法比較

- 使用 NotebookLM 研究網路上相同或相近主題的解法。
- 撰寫至少 100 字摘要，並記錄實際研究來源。
- 比較本作業線性回歸與研究資料提及的主流或較佳解法。
- **驗收條件：**摘要與比較有實際研究依據。若需要我登入、操作或提供內容，標示「等待使用者提供」，不可假稱完成。

Step 8：完成 CRISP-DM 報告

- 依序完成六個 CRISP-DM 階段。
- 納入資料來源、資料處理、模型方法、特徵選擇、評估指標、預測圖、NotebookLM 摘要、解法比較與研究限制。
- 標示「GPT 輔助內容」與「NotebookLM 摘要」。
- **驗收條件：**報告內容與程式實際輸出一致，無虛構內容。

Step 9：GPT 對話紀錄與檔案整理

- 確認有可用的真實 GPT 對話紀錄。
- 若沒有，先詢問我是否要提供對話或自行匯出；不可自行編造。
- 將主程式、報告 PDF、GPT 對話 PDF 與必要資料整理完整。
- 以學號命名 ZIP。
- **驗收條件：**ZIP 內檔案存在、命名正確且可以讀取。若需要我提供學號或 PDF，標示「等待使用者提供」。

Step 10：最終驗收

- 從乾淨狀態重新執行主程式或 Notebook。
- 確認程式輸出、報告數值、圖表與檔案內容一致。
- 確認 ZIP 可以讀取且包含所有必要檔案。
- 在 `PROJECT_LOG.md` 記錄最終測試指令與實際結果。
- **驗收條件：**全部必要檢查成功後，才可將此步驟打勾。

六、每個 Step 完成後的回報格式

```
Step：
完成內容：
測試方式：
實際結果：
修改或新增檔案：
TODO.md 狀態：
PROJECT_LOG.md 記錄：
尚待處理或需我決定的事項：
```

如果測試未成功，請標示「未完成」，列出錯誤訊息與下一步修正方式，並保持 TODO.md 未勾選。

七、收到本 Prompt 後的第一步

收到本 Prompt 後，請先：

1. 檢查專案目錄與相關檔案。
2. 建立或確認 TODO.md 與 PROJECT_LOG.md。
3. 回報目前找到的檔案與管理檔初始規劃。
4. 列出目前缺少或未確認的必要資訊，例如學號、資料集或 Kaggle 連結、GPT 對話 PDF、NotebookLM 研究材料。
5. 若資料集尚未指定，先提供候選資料集與推薦理由，等待我確認後再開始資料分析。
6. 若沒有 GPT 對話紀錄，先詢問我如何提供或匯出；不可自行製作。
7. 不要把尚未執行或尚未測試的步驟標記為完成。

:

::writing_block

:::

這份 prompt 可以直接貼給 AI coding agent 使用；如果要讓它開始執行，記得在後續提供學號，以及確認資料集和真實 GPT 對話紀錄的處理方式。

是什麼CRISP-DM尸

CRISP-DM 是一種常見的資料分析流程，幫助我們有條理地完成「了解問題 → 整理資料 → 建立模型 → 評估結果」。

它分成六個階段：

1. **Business Understanding（商業理解）**：先弄清楚要解決什麼問題。
   例：想知道哪些房屋條件會影響房價，並預測房價。
2. **Data Understanding（資料理解）**：檢查資料有哪些欄位、缺失值和分布情形。
   例：查看房屋面積、房間數、屋齡和房價資料。
3. **Data Preparation（資料準備）**：整理資料，處理缺失值、文字欄位等，並切分訓練資料和測試資料。
4. **Modeling（建模）**：選擇方法並訓練模型。
   例：用多元線性回歸預測房價。
5. **Evaluation（評估）**：檢查模型預測得準不準，判斷結果是否符合原本的目標。
   例：計算 MAE、RMSE、R^2，並查看預測圖。
6. **Deployment（部署）**：說明如何使用模型預測新資料。
   例：輸入一間房子的條件，讓模型估算房價。

簡單記法：**先確認問題，再了解和整理資料，接著建模、檢查結果，最後說明如何使用模型。**