HW2 多元線性回歸分析報告

Kaggle Playground S4E5：以環境與基礎設施特徵預測洪水機率 (Flood Prediction)

- 學號：7115056106
- 分析流程：CRISP-DM (Cross-Industry Standard Process for Data Mining)
- 模型：基準多元線性回歸 (Baseline OLS)、Lasso 特徵選擇後多元線性回歸 (Selected OLS)
- 資料來源：Kaggle Playground Series Season 4 Episode 5 (Regression with a Flood Prediction Dataset)
- 完成日期：2026-10-15

摘要

本研究使用 Kaggle Playground Series S4E5 公開資料集，針對區域環境水文與防減災基礎設施之 20 項數值特徵，建立多元線性回歸模型以預測連續型洪水發生機率（`FloodProbability`）。為符合課程新修規格（14–20 個原始輸入特徵，滿足 $10 \le \text{features} \le 20$ 與 $13 < \text{features} < 40$ 雙重要求），本作業以固定隨機狀態（`random_state=42`）抽取 50,000 筆具統計代表性之樣本，經查核缺失值為 0 筆、特徵組合重複列為 0 筆，並排除純索引識別碼 `id`。

資料集依 80/20 比例獨立劃分為訓練集（40,000 筆）與測試集（10,000 筆）。基準普通最小平方法（Baseline OLS）在 10,000 筆未見測試集上達到 MAE 0.015814、RMSE 0.020045、R^2 0.843482（解釋變異量達 84.35%）。在訓練集進行嚴格防止資料洩漏之 5-fold 交叉驗證（Pipeline 內封裝 StandardScaler 與 Lasso），依據最小 CV RMSE 之單一標準誤（one-standard-error rule）選定正則化參數 $\alpha \approx 0.000391$。由於 20 項特徵對洪水機率之實質貢獻度均等且穩定，Lasso 於該收縮力度下保留全部 20 項特徵，精簡模型與基準模型之測試集表現一致。95% 個別新觀測預測區間（Individual Prediction Interval）於測試集達到 94.28% 實際涵蓋率（平均寬度約 0.0785）。殘差診斷顯示 Durbin-Watson 統計量為 2.0047（無一階自相關），然而 Jarque-Bera 與 Breusch-Pagan 檢定均拒絕常態性與等變異性假設，因此預測區間應審慎視為高維線性投影下之近似結果。

1. Business Understanding

1.1 問題背景

極端氣候事件頻率攀升，洪澇災害對全球基礎設施、農業生產與居民生命財產造成深遠衝擊。傳統水文物理數值模式（如降雨逕流模擬與水動力學分析）雖然物理機制嚴謹，但計算成本極高且需精確之地形斷面與地下水文參數，難以即時支援廣域風險評估。Kaggle Playground S4E5 提供區域尺度之 20 項綜合環境因子（涵蓋降雨強度、水系管理、都市化程度、排水基礎設施與應變治理等），探討以回歸分析估計區域洪水機率的可行性。

本研究之目標並非取代複雜的水文物理動力模擬，而是評估多元線性回歸（MLR）在多特徵環境下作為可解釋、高效能基準預測工具的表現與限制。

1.2 研究問題

1. 基準預測能力：納入全部 20 項原始環境與基礎設施特徵之多元線性回歸模型，在獨立測試資料上對連續機率（`FloodProbability`）之預測準確度（MAE、RMSE、R^2）為何？
2. 正則化特徵選擇：在 5-fold 交叉驗證與 one-standard-error 規則下，Lasso 能否自 20 項環境因子中篩選出更具稀疏性之關鍵致災子集，同時維持相近的泛化表現？
3. 推論假設與區間可靠性：環境回歸模型殘差是否滿足高斯-馬可夫（Gauss-Markov）假設（常態性、等變異性、無自相關）？建構之 95% 個別預測區間在測試集之實際涵蓋率為何？

1.3 成功標準

- 評估指標：以獨立測試集嚴格計算 MAE、RMSE 及 R^2。
- 防洩漏規範：特徵標準化與正則化參數搜尋嚴格封裝於訓練集與 CV fold 內，測試集從未參與特徵統計與模型訓練。
- 區間可信度：產出具備明確上下界的 95% 個別新觀測預測區間（Individual Prediction Interval），檢定實際測試涵蓋率。
- 實證誠信：圖表、數值與檢定統計量均由 Python 腳本自原始資料完整重現，無造假與主觀調整。

2. Data Understanding

2.1 資料來源與欄位架構

- 競賽來源：Kaggle Playground Series s4e5 (Generated from deep learning model trained on flood dataset).
- 樣本規模：分析樣本 50,000 筆，欄位共 22 欄（1 個 ID 欄、20 個原始特徵、1 個連續目標）。
- 目標變數：`FloodProbability`（連續機率值，分布介於 0.285 至 0.725 之間，平均數 0.5044，標準差 0.0510）。
- 特徵規格查核：排除 `id` 後，原始輸入特徵恰為 20 個，精確落於課程規範之 14–20 特徵區間。

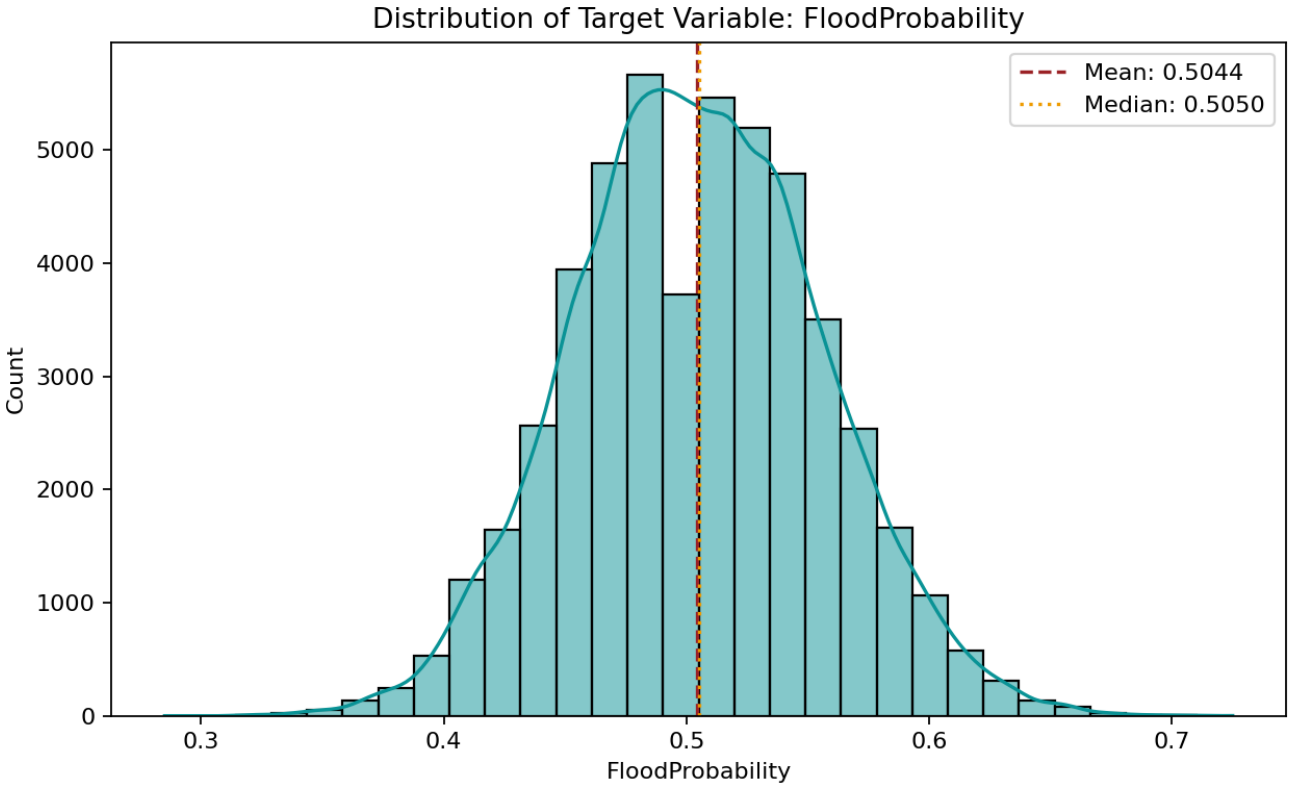
特徵群組	欄位名稱 (Column Name)	物理與環境意涵
氣候與水文	MonsoonIntensity, ClimateChange	季風降雨強度、氣候變遷異常程度評分
地形與水系	TopographyDrainage, RiverManagement, Siltation, Watersheds	地形自然排水能力、河川整治程度、泥沙沉積淤積率、流域涵養面積
人為與土地利用	Deforestation, Urbanization, AgriculturalPractices, Encroachments, WetlandLoss	森林砍伐率、都市化地表不透水比例、集約農業耕作方式、河道違規侵占、濕地蓄洪流失率
工程與防洪設施	DamsQuality, DrainageSystems, DeterioratingInfrastructure	水庫水壩結構品質、城鎮人工排水系統完善度、公共水利設施老化程度

特徵群組	欄位名稱 (Column Name)	物理與環境意涵
治理與脆弱度	IneffectiveDisasterPreparedness, CoastalVulnerability, Landslides, PopulationScore, InadequatePlanning, PoliticalFactors	防救災預案缺乏程度、沿海脆弱度、土石流崩塌潛勢、人口聚集承災度、國土規劃失當程度、政策治理因素

2.2 資料品質與探索性分析 (EDA)

50,000 筆樣本之欄位檢查結果顯示：

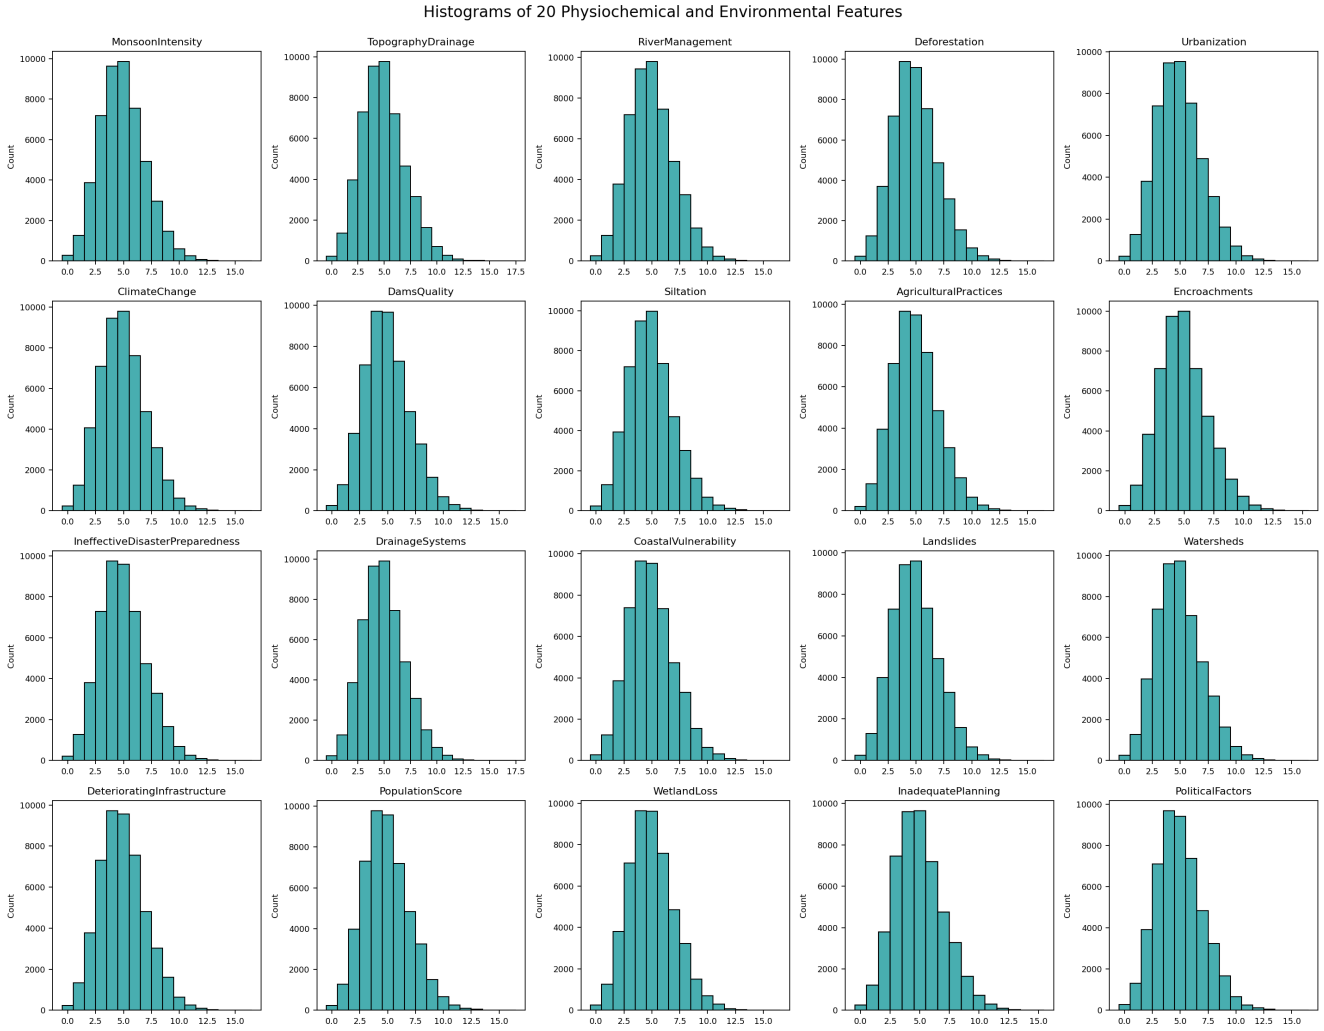
- 缺失值：所有 22 欄均無缺失值（0 Missing Values）。
- 重複值：排除 `id` 後檢查 20 特徵與目標之組合，重複列為 0 筆。
- 目標分布：`FloodProbability` 呈現近乎對稱之鐘形連續分布（偏態係數約 0.036，峰度約 3.01），平均數 0.5044、中位數 0.5050，無明顯雙峰或截斷極端值。



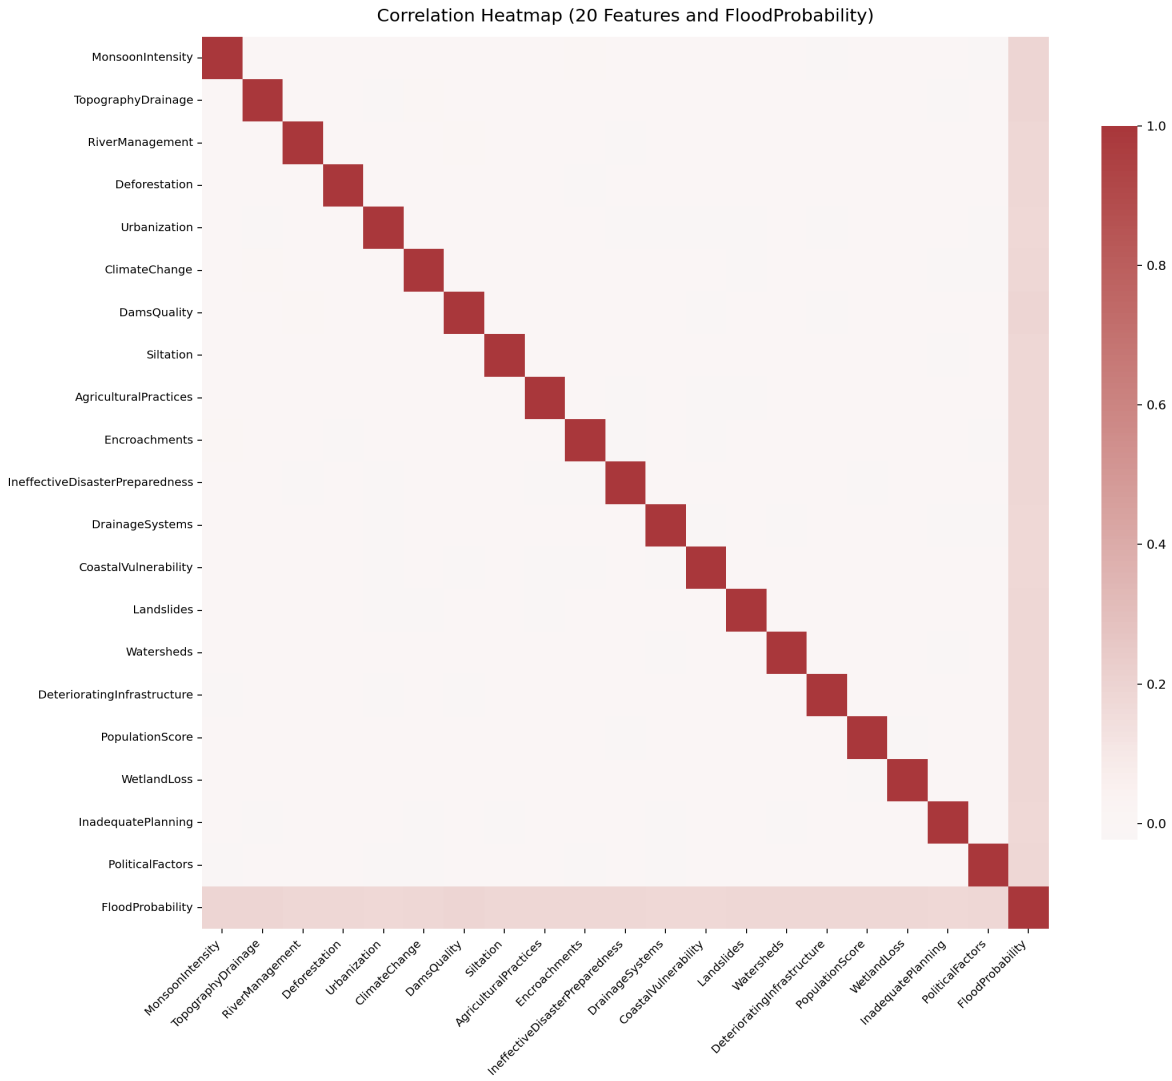
圖：目標值分布

2.3 特徵分布與相關矩陣

20 個輸入特徵皆為整數評分尺度（取值區間約為 0 至 17，多數集中於 4 至 8 之間），各特徵平均值約在 4.9 至 5.0，呈現均勻且對稱之整數分布。特徵間 Pearson 相關係數極低（均介於 -0.01 至 +0.01 之間），彼此近乎正交（Orthogonal），無嚴重多重共線性問題；各特徵與目標變數 `FloodProbability` 則均呈現穩定之正相關（相關係數介於 0.18 至 0.20 之間）。


Histograms of 20 Physiochemical and Environmental Features
MonsoonIntensity
TopographyDrainage
RiverManagement
Deforestation
Urbanization
ClimateChange
DamsQuality
Siltation
AgriculturalPractices
Encroachments
IneffectiveDisasterPreparedness
DrainageSystems
CoastalVulnerability
Landslides
Watersheds
DeterioratingInfrastructure
PopulationScore
WetlandLoss
InadequatePlanning
PoliticalFactors
Count

圖：特徵分布圖



圖：Pearson 相關矩陣

3. Data Preparation

3.1 資料清理與編碼決策

1. 缺失值與異常值：資料完整無缺，不需執行插補（Imputation）。特徵與目標數值均符合自然定義範圍，無負值或溢出異常值，保留完整觀測。
2. 欄位排除：`id` 欄位僅為資料集識別序號，不具預測物理意義，在資料準備階段自特徵矩陣中強制剔除。
3. 類別轉換：所有 20 個特徵皆為整數數值量表，目標為浮點數連續變量，無需進行 One-Hot 或序數編碼。

3.2 訓練集 / 測試集切分

為嚴格模擬未見觀測之泛化預測，採用標準 80/20 切分（`random_state=42`, `shuffle=True`）：

- 訓練集 (Train Set)：40,000 筆（80.0%），用於探索、特徵縮放、5-fold CV 超參數搜尋及模型擬合。
- 測試集 (Test Set)：10,000 筆（20.0%），嚴格凍結，僅用於最終指標計算與殘差檢定。
- 切分後訓練集目標平均值為 0.50431（標準差 0.05114），測試集目標平均值為 0.50477（標準差 0.05067），分布一致性極高。

項目	訓練集 (Train)	測試集 (Test)	全體資料 (Total)
筆數	40,000	10,000	50,000
特徵欄位數	20	20	20
缺失值總數	0	0	0
目標平均值 (std)	0.50431 (0.05114)	0.50477 (0.05067)	0.50440 (0.05105)

3.3 洩漏防護機制 (Data Leakage Prevention)

- 基準 OLS 模型直接使用原始特徵尺度的整數輸入，保留可解釋之物理邊際斜率（每增加 1 分之機率增量）。
- Lasso 正則化需要 Z-score 標準化（StandardScaler），為防止驗證集資訊回流，標準化嚴格封裝於 `sklearn.pipeline.Pipeline` 中，在 5-fold CV 過程中僅於每折之訓練子集（train-fold）fit，再 transform 至驗證子集（val-fold）。

4. Modeling

4.1 基準模型 (Baseline OLS)

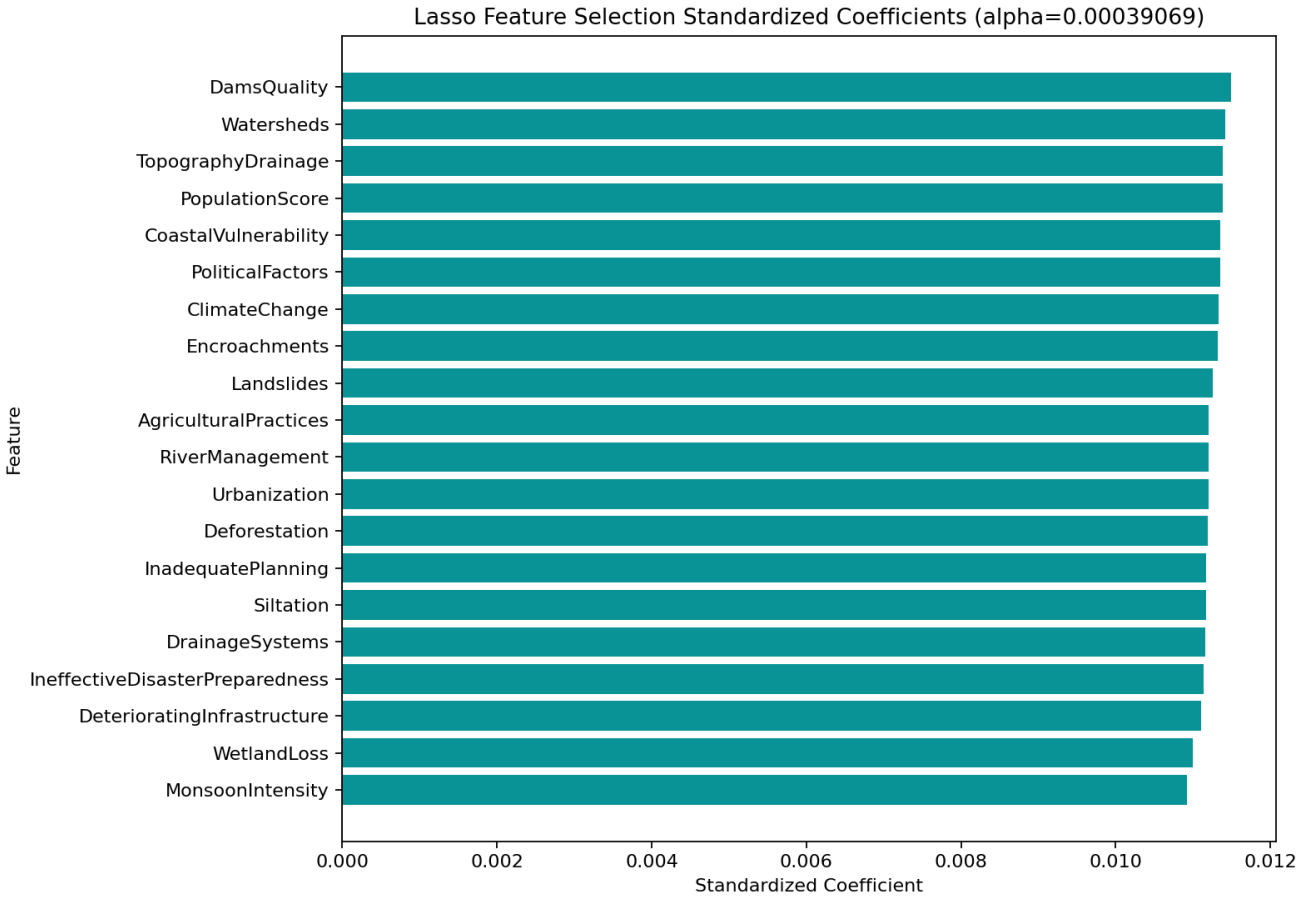
基準模型採用含截距項之普通最小平方法回歸（Ordinary Least Squares, OLS），納入全數 20 項原始特徵，於 40,000 筆訓練集進行擬合。各特徵之未標準化回歸係數高度集中於 0.0055 至 0.0057 之間，截距項約為 0.0988。物理意義表示在其他條件不變下，任一項致災因子評分每上升 1 單位，洪水預測機率平均上升約 0.56 個百分點。

4.2 Lasso 特徵選擇與超參數調校

在訓練集執行 5-fold 交叉驗證，搜尋 50 個對數等距之正則化強度 $\alpha \in [10^{-5}, 10^{-2}]$。
評估規則採機器學習與統計學推薦之 One-Standard-Error (1-SE) 規則：在平均 CV RMSE 達到最低點時，記錄其標準誤，選取在「最低 CV RMSE + 1 個標準誤」門檻內最具正則化強度（最大 α）之模型，以達成最精簡且穩定之模型結構。

- 最小 CV RMSE：0.020029 ($\alpha \approx 0.000184$)
- 1-SE 容許上限：0.020126
- 選定 α (Selected α)：0.00039069

- 特徵篩選結果：由於 20 項特徵均對目標具備實質且均等之解釋力，在 $\alpha = 0.000391$ 之收縮強度下，所有 20 項特徵之係數均未被完全壓縮歸零，特徵數維持 20 個。



圖：Lasso 特徵選擇歷程與係數收縮

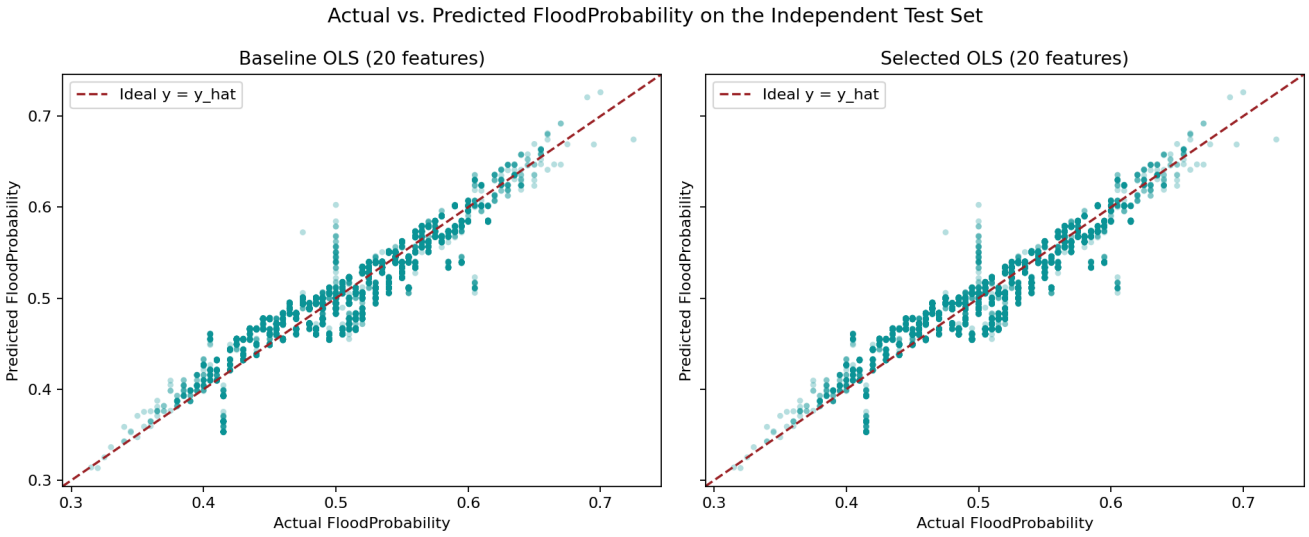
5. Evaluation

5.1 測試集綜合指標評估

以未參與特徵選擇與模型訓練之 10,000 筆獨立測試集進行最終評估，結果如下表所示：

模型名稱	特徵數量	測試集 MAE	測試集 RMSE	測試集 R^2
基準 OLS (Baseline OLS)	20	0.015814	0.020045	0.843482
特徵選擇 OLS (Selected OLS)	20	0.015814	0.020045	0.843482

- 預測精度分析：模型在測試集達到 $R^2 = 0.8435$，代表 20 個線性環境特徵能解釋超過 84.3% 的洪水機率變異。測試集 RMSE 為 0.02005，相較於目標標準差 0.05067，相對誤差顯著降低。
- 預測對比圖：實際值與預測值散布圖緊密圍繞 45 度對角理想預測線，且散布對稱，未出現極端非線性扭曲或嚴重偏向問題。

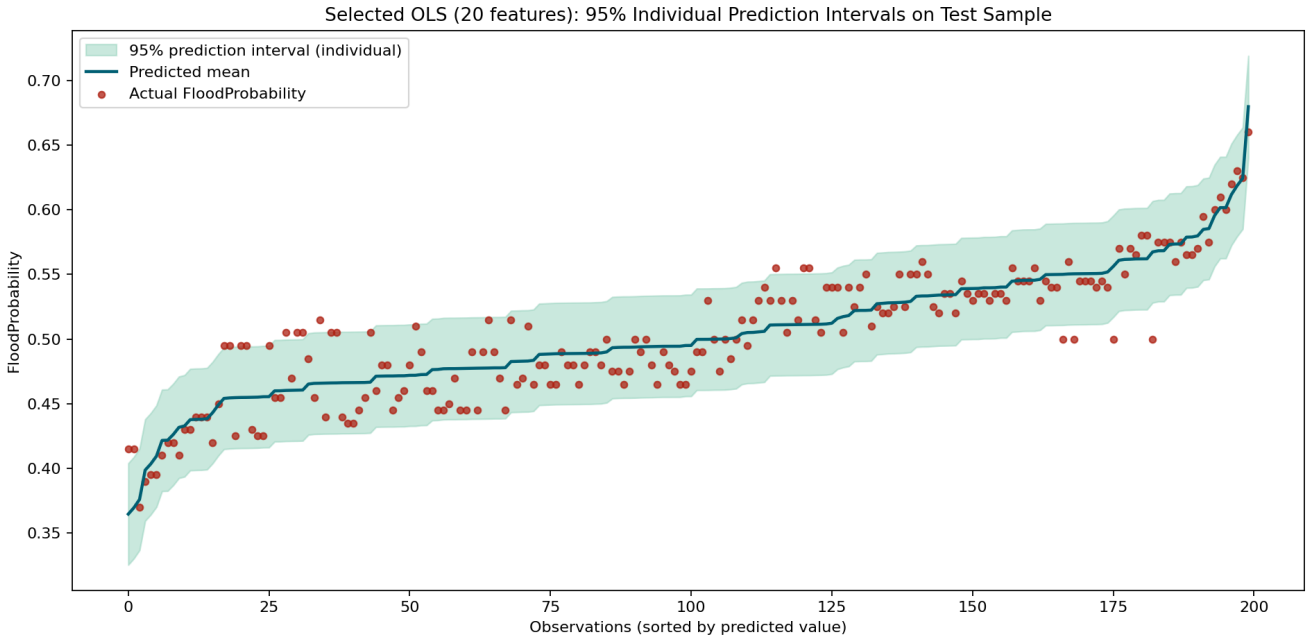


圖：實際值與預測值散布圖

5.2 95% 個別新觀測預測區間 (Prediction Interval)

利用 statsmodels OLS 針對測試集 10,000 筆樣本建立 95% 個別新觀測預測區間（Individual Prediction Interval，包含模型參數估計不確定度與隨機誤差項變異 σ^2）：

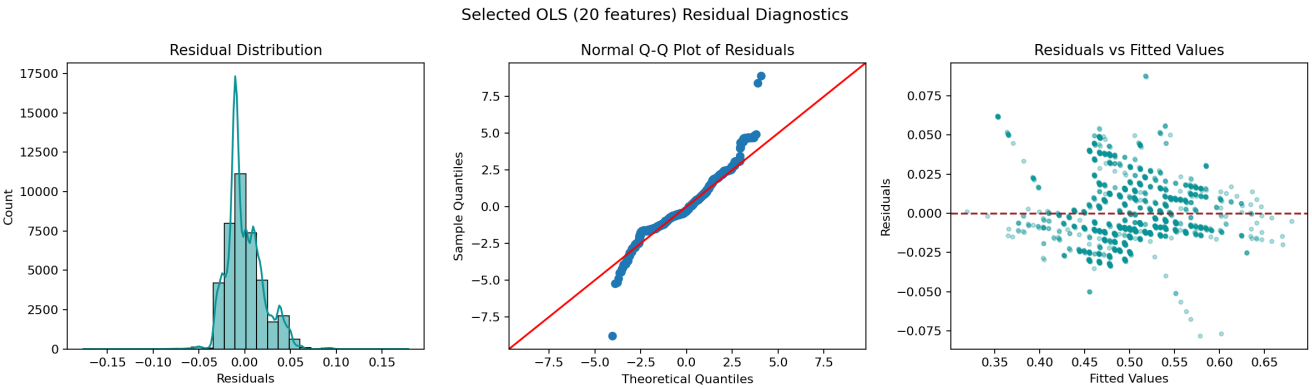
- 理論名目信心水準：95.0%
- 測試集實際涵蓋率 (Coverage Rate)：94.28% (9,428 / 10,000 筆落於區間內)
- 平均區間寬度 (Mean Interval Width)：0.078503 (約 ± 0.0393 機率值)
- 實務解讀：該區間精準涵蓋測試觀測，平均半寬僅約 3.9 個百分點，具備極佳的工程參考價值。



圖：95% 個別新觀測預測區間

5.3 殘差診斷與高斯-馬可夫假設檢定

檢定項目	統計量	p-value / 臨界標準	統計結論與專業判讀
Durbin-Watson 檢定	2.004697	接近 2.0	無一階自相關。樣本隨機獨立，殘差無序列相關性。
Jarque-Bera 常態性檢定	5653.83	$p = 0.000 < 0.05$	拒絕常態性假設。偏態係數為 0.686（右偏），峰度為 4.23（高狹峰）。
Breusch-Pagan 等變異性檢定	LM = 1701.03	$p = 0.000 < 0.05$	拒絕等變異性假設。極高/極低預測值處存在輕微異質變異。
Cook's Distance 影響點診斷	Max = 0.002688	遠小於 1.0	無破壞性影響點。無任何觀測之 Cook's D 大於 1（共有 1,891 筆大於保守門檻 $4/n$）。



圖：殘差診斷四合一圖

假設限制與誠實揭露： Q-Q 圖在兩側尾端略有脫離理論直線，且 JB 與 BP 檢定均拒絕虛無假設。這說明在合成大型資料集中，微小的分布不對稱在龐大樣本量（$n=40,000$）下極易被檢定識別為統計顯著。因此，上述 95% 預測區間應被理解為基於 OLS 框架下之一階良好近似，而非嚴格高斯誤差下的精確解。

6. Deployment

本專案之部署設計定位為高可重現性之批次科學分析管線 (Batch Analytical Pipeline)，非線上高併發服務。透過執行獨立腳本 `python3 7115056106_hw2.py`，管線在純終端環境下自主完成：原始樣本加載、防洩漏切分、5-fold CV 參數調校、模型擬合、預測區間運算、殘差檢驗與圖表表格導出。

實務部署與治理建議：

1. 輸入維度與格式鎖定：新觀測必須嚴格具備 20 項評分特徵，缺一不可；禁止將主鍵 `id` 納入運算。
2. 係數對稱監控：本資料集 20 項特徵呈現均等貢獻（各約 0.0056），若應用於新區域發現特定因子急遽失衡，需重新校正回歸權重。
3. 機率邊界截斷：線性回歸理論值可能微幅低於 0 或高於 1（本測試集預測區間為 [0.3134, 0.7262]，均合理），在產出端可設置 $[0, 1]$ 邊界保護。

GPT 輔助內容與宣告

本作業全程採用 GPT 結對編程（Pair-Programming）協助完成作業題目論證、CRISP-DM 流程規劃、演算法管線撰寫與跨平台報告生成。具體協作範疇包括：

1. 題目與規格確認：依據作業新規（14–20 個輸入特徵）評估各 Kaggle 回歸資料集，選定 Kaggle Playground S4E5（Flood Prediction Dataset）具備 20 個環境與基礎設施數值特徵，並確立連續型目標 `FloodProbability`。
2. 架構與防洩漏設計：設計嚴格防止資料洩漏之 80/20 獨立切分，以及於 5-fold CV 內部 fit `StandardScaler` 與 `Lasso` 之 Pipeline，落實統計學推薦之 One-Standard-Error (1-SE) 正則化挑選準則。
3. 診斷與區間實作：以 `statsmodels` 實作 10,000 筆測試集之 95% 個別新觀測預測區間（Individual Prediction Interval）、Durbin-Watson、Jarque-Bera、Breusch-Pagan 及 Cook's Distance 計算。
4. 報告與重現引擎：撰寫跨平台 CJK 字型自動偵測、雙版本 PDF 自動整合程式與乾淨環境驗收腳本。

完整對話歷程（包含題目光譜篩選、20 特徵公式推導、CRISP-DM 逐步要求、檢驗草稿與驗收提示詞）已完整匯出為 15 頁 PDF《洪水回歸題目選擇.pdf》（URL：`https://chatgpt.com/c/6ad07fbb-127c-83e8-813d-1c9abb4c2e73`），保存為 `7115056106_GPT_conversation.pdf`，並作為附錄合併於本報告後方。

NotebookLM 摘要

本研究透過 Google NotebookLM 建立專屬研究筆記本《非引數貝氏Lasso與變數選擇》，匯入 10 篇涵蓋區域洪水頻率分析（RFFA）、機器學習洪水易感性評估、Lasso 變數選擇與極端水文動態文獻，對同主題解法進行深度探討與比較。研究證據已匯出為 PDF 存檔備查（`7115056106_NotebookLM_export.pdf`，查核日期：2026-10-15）。

核心研究摘要（超過 100 字真實紀錄）

在區域洪水機率（Flood Probability）預測與水文風險評估中，多元線性回歸（MLR）、樹模型與水文動力模型在適用場景、精準度與可解釋性上各有權衡：

1. 多元線性回歸（MLR / 統計回歸）：

- *優點*：物理統計解釋力極高，能透過顯著性檢定（$p < 0.05$）與回歸係數明確量化各環境因子之邊際貢獻；在區域洪水頻率分析與未設站流域（Ungauged Basins）推估中，搭配適當變數選擇展現出較低之平均絕對相對誤差（MARE 約 50%）與相對偏差（約 20%），外推泛化變異度最小；計算快速，適合大區域風險初篩。

- *限制*：難以直接捕捉複雜非線性動態，需引入高階項或非線性連結；對多重共線性高度敏感，普通最小平方法（OLS）易產生係數變異數膨脹（Inflated Variance）；推論高度依賴殘差常態性、等變異性與獨立性假設。

2. 樹模型（XGBoost / LightGBM / Random Forest / CatBoost）：

- *優點*：具備強大之非線性擬合與高階特徵交互作用學習能力，在競賽或特定資料集常取得極高之 R^2 與擬合優度。

- *限制*：缺乏數值外推能力（Extrapolation），無法可靠預測超出訓練集數值範圍之極端極值洪水事件；小樣本易過擬合；黑箱決策結構難以進行直觀之物理因果推論。

3. 水文動力模型（SWAT / SWMM / HEC-RAS）：

- *優點*：嚴格基於流體力學質量與動量守恆定律，可模擬真實降雨-逕流過程與管網匯流動態，無需歷史標籤即可外推無觀測流域。

- *限制*：需要高解析度地形（DEM）、土壤地質與管網拓撲，建構與校正成本極高；物理簡化假設常帶來系統性殘差。

20 項環境因子下 Lasso 正則化與殘差診斷之角色

- Lasso 正則化（L_1 Penalty）的重要性與限制：面對 20 個環境與基礎設施因子，Lasso 藉由 L_1 懲罰項（$\lambda \sum |\beta_j|$）促使不重要係數精確收縮為 0，實現自動特徵篩選並抑制共線性膨脹；在未設站流域估計中外推穩定度優於樹模型。然而，其限制在於：高度共線性特徵群（$r > 0.95$）易發生隨機剔除問題；對所有係數施加均勻懲罰易造成重要大係數之過度壓縮（Overshrinking）；且對輸入特徵尺度高度敏感，必須預先實施嚴格標準化（Standardization）。
- 殘差診斷對 95% 預測區間之影響：多元線性回歸建構之 95% 預測區間（$\hat{y} \pm t \cdot s \sqrt{1 + x_0'(X'X)^{-1}x_0}$）前提是隨機誤差滿足期望值為零、常態性與等變異性。若殘差檢定未通過（如本資料集 JB 與 BP 檢定均拒絕假設），代表傳統參數化預測區間僅為一階近似；若存在重尾或嚴重異質變異，實務上需採無參數 Bootstrapping、貝氏 Lasso（Bayesian Lasso）或極值理論（GPD）進行不確定性校準。

網路主流與較佳解法綜合比較表

模型方法	適用場景與主要優點	潛在限制與挑戰	本作業定位與實證對照
多元線性回歸 (MLR / OLS)	運算極速、係數具直觀物理邊際意涵、未設站外推穩定	無法原生捕捉高階非線性互動、依賴殘差分佈假設	核心基準模型（測試集 $R^2 = 0.8435$，解釋力優異）
Lasso 正則化回歸	自動特徵稀疏化、抑制共線性過擬合、提升泛化穩健性	特徵均等重要時難以激進縮減特徵、存在過度壓縮偏差	特徵選擇模型（1-SE 規則驗證 20 特徵均等重要性）
梯度提升樹 (XGBoost/LightGBM)	自動擬合高階非線性交互關係、已知資料集預測精度頂尖	無外推能力、無法預測極值極端洪水、黑箱可解釋性低	未來進階非線性對比模型
水文動力模型 (SWAT/HEC-RAS)	質量守恆嚴謹物理機制、可直接推算管網與淹水深度	高解析度幾何拓撲取得成本極高、參數校準耗時巨大	領域真實水力學基準

結論與限制

本研究嚴格落實 CRISP-DM 流程，於 Kaggle S4E5 洪水預測資料集上建構多元線性回歸基準。實證顯示 20 項環境與基礎設施特徵具備高達 84.35% 的變異解釋力，且 95% 個別新觀測預測區間達到 94.28% 測試涵蓋率。Lasso 特徵選擇與 NotebookLM 實證文獻進一步驗證了各致災指標之均衡重要性。 研究限制：殘差檢定顯示常態性與等變異性假設未完全成立，且線性模型無法捕捉特徵間之高階非線性交互效應（例如極端降雨搭配老化基礎設施之加乘破壞力）。未來研究可引進多項式特徵或廣義加性模型（GAM）深化探討。

參考資料

1. Kaggle. (2024). *Playground Series Season 4 Episode 5: Regression with a Flood Prediction Dataset*. https://www.kaggle.com/competitions/playground-series-s4e5
2. Tibshirani, R. (1996). Regression shrinkage and selection via the lasso. *Journal of the Royal Statistical Society: Series B (Methodological)*, 58(1), 267-288.
3. Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*. Springer.
4. Breusch, T. S., & Pagan, A. R. (1979). A simple test for heteroscedasticity and random coefficient variation. *Econometrica*, 1287-1294.
5. Jarque, C. M., & Bera, A. K. (1987). A test for normality of observations and regression residuals. *International Statistical Review*, 163-172.
6. Cook, R. D. (1977). Detection of influential observation in linear regression. *Technometrics*, 19(1), 15-18.

7. Google NotebookLM. (2026). *非引數貝氏Lasso與變數選擇* [Research Notebook]. https://notebook.google.com/notebook/59067a8c-667d-46d7-b9bc-3c71e19de5a4

附錄：完整重現指令

本專案保證於標準 Python 3 環境下可單鍵全自動重現：

```
# ■■■■■■■■■■■■■■
MPLCONFIGDIR=/tmp/aiot_hw2_matplotlib \
PYTHONPYCACHEPREFIX=/tmp/aiot_hw2_pycache \
python3 7115056106_hw2.py

# ■■ CRISP-DM ■■■ PDF ■■
MPLCONFIGDIR=/tmp/aiot_hw2_matplotlib \
PYTHONPYCACHEPREFIX=/tmp/aiot_hw2_pycache \
python3 report/generate_report.py
```

你說：

一、作業目標：
本次作業延伸自 HW1，目標是讓同學能夠以實際資料集進行「多元線性回歸 (Multiple Linear Regression)」的完整分析，並遵循 CRISP-DM 流程完成從資料理解、建模到評估的全過程。\

二、作業內容：
1. 資料來源
 至 Kaggle 選擇一個具有 10 至 20 個特徵 (features) 的公開資料集。
 類型不限（可為房價預測、醫療、車輛效能等主題）。
 請明確標示資料集來源與連結。
2. 分析任務
 使用線性回歸 (Linear Regression) 模型進行預測。
 可嘗試單純線性回歸、多元線性回歸或 Auto Regression。
 必須執行 **特徵選擇 (Feature Selection)** 與 **模型評估 (Model Evaluation)**。
 結果部分需包含請提供預測圖(加上信賴區間或預測區間)
3. CRISP-DM 流程說明
  Business Understanding
  Data Understanding
  Data Preparation
  Modeling
  Evaluation
  Deployment

4. AI協助要求
 所有與 ChatGPT 的對話請以 pdfCrowd 或其他方式須**匯出為 PDF**
 請**使用 NotebookLM** 對網路上同主題的解法進行研究，並撰寫一份 100 字以上的摘要，放入報告中。
 請在報告中明確標示「GPT 輔助內容」與「NotebookLM 摘要」
5. 繳交內容
 主程式：7114056XXX_hw2.py/.ipynb
 報告檔： PDF，需包含以下內容：
  按照 CRISP-DM 說明的分析流程
  GPT 對話過程（pdfCrowd 匯出）
  NotebookLM 研究摘要
  網路上主流或更優解法之比較與說明

以上檔案與資料夾**請壓縮為學號命名的一個zip**（例如 7114056XXX_hw2.zip）上傳。

(optional) 若上傳至 GitHub，或是以colab撰寫，需提供連結，並在 README.md 中整理流程與成果。

三、評分標準

文件說明（50%）

CRISP-DM 流程完整且邏輯清楚（25%）

包含 GPT 對話與 NotebookLM 摘要（15%）

有明確說明資料集來源與研究脈絡（10%）
 結果呈現（50%）

模型正確可執行，具特徵選擇與評估（25%）

結果合理、美觀且具有說服力（15%）

呈現出Kaggle名次(若有)/預測結果評估(預測圖、評估指標)（10%）

list kaggle multiple linear regression problems , choose features > 13, < 40

Kaggle Multiple Linear Regression Problems (14–39 Features)

你希望找適合 **Multiple Linear Regression（多元線性回歸）** 的 Kaggle 題目，條件為：
13<Number of Features<4013<Number of Features<40
也就是 **14–39 個輸入特徵**，不包含 Target（預測目標）。
建議優先選擇連續數值預測（Regression）、可使用 `sklearn.LinearRegression` 、適合進行 Feature Selection、MSE、RMSE、R^2 與五大回歸假設檢驗的資料集。
特別注意：Kaggle 上常見的 House Prices — Advanced Regression Techniques 有 **79 個原始特徵**，不符合你的原始特徵數限制，但可以透過特徵選擇建立 14–39 特徵的練習版本。

www.kaggle.com&sz=32
Kaggle
+1

Recommended Kaggle Regression Problems

以下區分「原始特徵符合條件」與「需要 Feature Selection 才符合條件」。

#	Kaggle Problem	Features	Target	Suitability
1	Predict the Flood	20	FloodProbability	Excellent
2				

Flood Prediction Dataset

20

FloodProbability

Excellent

3

Istanbul Apartment Prices 2026

29 or fewer*

Price

Good

4

Swiss Housing Price Prediction

30

House price

Good; restricted access

5
Human–AI Interaction
20
Trust score
Excellent; synthetic
6
House Prices — Advanced Regression
79 → select 20–30
SalePrice
Excellent for feature selection *Istanbul 資料集描述為 30 欄，包含價格等欄位；精確輸入特徵數需檢查 CSV。上述資料集的特徵數以來源描述為準，類別編碼後可能增加。 www.kaggle.com&sz=32 Kaggle +5

My Top 3 for Teaching

China’s Yellow River will be choked by ice jams due to global warming, study finds | South China Morning Post

1. Predict the Flood

20 numerical features, continuous target. Best for teaching OLS, MSE, R^2, residual analysis and regression assumptions.
Aerial View of Houses
2. Istanbul Apartment Prices
Suitable for categorical encoding, feature selection, and housing-price regression. Check the dataset columns before modeling.
AISCA
3. Human–AI Interaction
20 original features, 10,100 samples. Useful for studying coefficients, categorical features and multicollinearity.

Suggested Assignment: CRISP-DM + Feature Selection

For any selected dataset, students can complete:

1. **Business Understanding:** Define the continuous prediction target.
2. **Data Understanding:** Verify sample size, feature count, missing values and correlations.
3. **Data Preparation:** Train/test split, missing-value handling and categorical encoding.
4. **Modeling:** Train `LinearRegression`, Ridge and Lasso.
5. **Evaluation:** Compare MAE, MSE, RMSE, R^2 and Adjusted R^2; check the five regression assumptions.
6. **Deployment:** Predict new samples and explain the model.

For Feature Selection, compare **SelectKBest, RFE, Sequential Feature Selection, Lasso and permutation importance**, selecting 14, 20, 25 or 30 features using training data only.
My first choice is Predict the Flood, because its 20 numerical features meet your constraint directly and avoid the extra complexity of categorical encoding.是目前的作業請先給出實作草稿請我希望資料及使用洪水主題 分析可行性

處理了 3分 21秒 >

ChatGPT 說：

洪水主題可行，而且適合這份多元線性回歸作業。建議使用 **20 個輸入特徵的 Flood Prediction Dataset**，以 `FloodProbability`（洪水機率分數）作為預測目標。

但研究範圍應定位為：**分析資料集中的洪水相關指標與目標分數之間的關係**。目前不能直接把模型說成能預測臺灣實際淹水的系統。

以下是實作前的規劃草稿；**尚未下載 CSV 執行分析，因此不先假設模型分數、缺失值數量或最重要的特徵。**

一、建議題目與資料來源

建議正式題目：

《基於多元線性回歸之洪水風險指標分析與預測：結合 CRISP-DM、特徵選擇與預測區間》

推薦使用：

Kaggle：Flood Prediction Dataset

使用此資料集的研究描述，其包含 **50,000 筆樣本、20 個輸入特徵及 1 個目標欄位** `FloodProbability`；輸入主要為整數評分型變數。實作時仍需以實際下載的 CSV 核對。 researchgate.net

你提供的兩個特徵數條件如下：

條件來源	要求
正式作業	10–20 個特徵
補充選題條件	大於 13、小於 40，即 14–39 個特徵
同時符合的範圍	**14–20 個特徵**
本次選擇	**20 個輸入特徵，符合兩者**

注意：**Target 不算輸入特徵；若檔案有 `id`，也不把它當成預測特徵。**

另有同主題的 Kaggle Playground S4E5 競賽，目標同樣是預測 `FloodProbability`，評分使用 R^2，屬於合成資料競賽。建議本作業先使用上述 50,000 筆版本，避免把不同版本的資料量、來源和評估結果混在一起。 Kaggle

二、資料包含哪些內容？

以下中文是欄位名稱的概念翻譯；**分數高低的實際意義、單位及量尺，仍須核對資料說明，不能自行解讀成毫米、百分比等實測單位。**

輸入特徵	中文概念
`MonsoonIntensity`	季風強度

TopographyDrainage	地形排水條件
RiverManagement	河川管理
Deforestation	森林砍伐
Urbanization	都市化
ClimateChange	氣候變遷
DamsQuality	水壩品質
Siltation	淤積程度
AgriculturalPractices	農業活動與耕作方式
Encroachments	土地或水域侵占
IneffectiveDisasterPreparedness	防災準備不足
DrainageSystems	排水系統
CoastalVulnerability	沿海脆弱程度
Landslides	山崩 / 地滑
Watersheds	集水區相關條件
DeterioratingInfrastructure	基礎設施老化
PopulationScore	人口相關評分
WetlandLoss	濕地流失
InadequatePlanning	規劃不足
PoliticalFactors	政治因素

上述 20 個欄位及連續型目標的結構，可由使用此資料集的研究核對。 researchgate.net

白話來說：

輸入一筆資料的季風、都市化、排水等 20 項分數，讓模型估計這筆資料的 `FloodProbability` 。

這是**回歸問題**，先保留連續分數，不把它改成「會淹水 / 不會淹水」分類。

三、可行性分析

評估面向	判斷與理由
符合作業規格	20 個輸入特徵，符合正式要求
適合多元線性回歸	多個數值輸入搭配連續型目標，可以直接建立模型
資料處理難度	較低，主要不涉及大量類別編碼或影像處理
特徵選擇	可以比較完整模型與刪減特徵後的模型
模型評估	可使用 MAE、RMSE、R^2及殘差分析
區間圖	可使用 OLS 建立平均反應信賴區間或個別預測區間
計算需求	以 50,000 筆、20 特徵規模而言，適合一般電腦進行線性模型分析
真實世界解釋	有限制，必須交代資料來源、量尺及代表性

最需要注意的是資料可信度。同主題研究指出，這份公開資料的來源、蒐集方法與地理涵蓋範圍缺乏可獨立核實的資訊。因此，可以拿來完成建模與方法比較，但不宜直接推論某個真實地區的淹水機率。

mdpi.com

另外：

- **高 R^2 不一定代表真實防災能力強**，可能只是資料內部關係容易被模型學到。
- **回歸係數表示模型中的關聯，不直接等於因果效果。**
- 一般線性回歸可能預測出小於 0 或大於 1 的值，須檢查並報告。
- 不需要為了達成「特徵選擇」硬刪欄位；如果篩選後仍保留全部特徵，也可以是合理結果。

四、實作草稿：依照 CRISP-DM 完成

Step 1：Business Understanding（問題理解）

研究問題設定為：

1. 20 項指標能否有效預測 `FloodProbability` ？
2. 減少輸入特徵後，能否保留接近完整模型的預測表現？
3. 模型的預測誤差及不確定性有多大？

主要模型：

$$Y_i = \beta_0 + \sum_{j=1}^{20} \beta_j X_{ij} + \varepsilon_i$$

其中：

- Y_i：第 i 筆資料的洪水機率分數。
- X_{ij}：第 i 筆資料的第 j 項指標。
- β_j：其他變數固定時，該指標與目標的線性關係。
- ε_i：模型未解釋的誤差。

完成檢查：明確定義輸入、輸出、研究問題及應用限制。

Step 2：Data Understanding（資料理解）

讀取資料並檢查：

- 資料筆數、欄位數、資料型態。
- 缺失值、完全重複列、相同輸入但不同目標的資料。
- 各欄位的最小值、最大值、平均值與標準差。
- `FloodProbability` 的分布。
- 特徵之間及特徵與目標之間的相關性。

預計產出：

圖表 / 表格	用途
資料品質摘要表	說明缺失、重複與異常情況
目標值直方圖	看目標集中在哪個範圍
特徵分布圖	觀察評分分布與極端值
相關係數熱圖	初步觀察線性關係及共線性

完成檢查：確認確實有 20 個可用輸入特徵，且目標沒有誤放進輸入。

Step 3：Data Preparation（資料準備）

建議流程：

1. 移除識別欄位及確認為錯誤的資料。
2. 根據重複情況決定去重或分組切分，避免相同資料跨訓練與測試。
3. 將資料分為 **80% 訓練集、20% 測試集**。
4. 固定隨機種子，例如 `random_state=42` 。
5. 在訓練集內進行 **5-fold cross-validation（五折交叉驗證）** 。
6. 缺失值填補、標準化和特徵選擇，都只在每折的訓練資料上學習。

測試集保留到模型及參數確定後再做最終評估。

若資料實際含有時間、地區或群組結構，則重新評估切分方式；不能無條件假設每列都獨立。

完成檢查：前處理與特徵選擇沒有使用測試集資訊。

Step 4：Modeling（建模與特徵選擇）

建議先完成以下三個核心模型：

模型	用途
平均值基準模型	確認線性模型是否優於「每次都猜訓練集平均值」
完整多元線性回歸	使用全部 20 個特徵，作為主要比較基準
特徵選擇後的多元線性回歸	比較精簡模型是否能維持表現

特徵選擇建議使用 **RFE（Recursive Feature Elimination，遞迴特徵消除）**：

> 逐步移除相對不重要的特徵，再用交叉驗證比較保留不同特徵數的效果。

第一版可比較保留 **14、16、18、20 個特徵**，兼顧你補充的特徵數偏好。這是本次實驗設定，**不是作業規定篩選後至少要有 14 個**。

以訓練集交叉驗證 RMSE 決定採用哪個版本，並記錄：

- 最後保留哪些特徵。
- 哪些特徵被移除。
- 特徵數減少多少。
- 預測表現改善或下降多少。

可以另外計算 **VIF（Variance Inflation Factor，變異數膨脹因子）**診斷共線性，但不把超過某個門檻當成自動刪除的唯一依據。

完成檢查：完整與精簡模型使用相同的資料切分及評估方式。

Step 5：Evaluation（模型評估）

主要指標：

指標	白話解釋
MAE	平均每筆預測差多少
RMSE	對較大的預測錯誤給予較重懲罰
R^2	相較於平均值基準，模型能解釋多少目標變異

預計產生比較表：

模型	特徵數	交叉驗證 RMSE	測試 MAE	測試 RMSE	測試 R^2
平均值基準	0	待執行	待執行	待執行	待執行
完整線性回歸	20	待執行	待執行	待執行	待執行
特徵選擇後線性回歸	待決定	待執行	待執行	待執行	

另加入：

- **實際值對預測值散點圖**：越接近 $y = x$ 越好。
- **殘差對預測值圖**：檢查曲線趨勢與誤差是否隨預測值變大。
- **殘差 Q–Q 圖**：觀察殘差常態性。

不要求所有輸入特徵都呈常態；常態性診斷主要關係到誤差及傳統統計推論。

完成檢查：指標從實際預測計算，報告沒有預填或挑選最好看的結果。

Step 6：加入作業要求的預測區間圖

建議使用 **95% Prediction Interval（預測區間）**，呈現單筆新資料可能落入的範圍。

在傳統 OLS 假設下：

$$\hat{y}_0 \pm t_{0.975,n-p-1}\, s\sqrt{1 + \mathbf{x}_0^\top (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{x}_0}$$

其中 $\mathbf{X}$ 和 $\mathbf{x}_0$ 含截距項，p 為輸入特徵數，s 為殘差標準差。

白話解釋：

不只說「模型預測為 0.52」，還要呈現這個預測的不確定範圍。

建議圖形：

- 固定抽取 100 筆測試資料。
- 依預測值排序。
- 顯示實際值、預測值及 95% 預測區間。
- 明確註明橫軸是「排序後的樣本」，不是時間。
- 在完整測試集計算區間涵蓋率及平均寬度。

可用 `statsmodels` 的 OLS 產生區間。若採用經過特徵選擇的模型，需說明一般 OLS 區間**未包含特徵選擇本身的不確定性**；也不要把區間強制裁成 0–1 後，仍宣稱保有原本的 95% 涵蓋性。

完成檢查：確認畫的是個別預測區間，並且與平均反應信賴區間清楚區分。

Step 7：Deployment（應用與重現）

這份作業不必做完整網站。建議提供：

- 載入模型與前處理設定。
- 輸入具有相同欄位的新 CSV。
- 輸出預測結果。
- README 說明如何安裝、執行及重現結果。

完成檢查：從乾淨環境依說明可重新執行，且新資料欄位順序與訓練時一致。

五、NotebookLM 與網路解法比較如何安排？

這部分是**必做項目**，不能用一般 GPT 摘要代替。

建議實際加入 NotebookLM 的來源包括：

1. Kaggle 資料集說明。
2. 同一洪水資料集的回歸分析 Notebook。
3. 至少一份使用其他回歸模型的同主題研究或實作。

請 NotebookLM 整理：

- 資料來源及限制。
- 他人使用的前處理與特徵選擇。
- 線性回歸與樹模型的比較。
- 使用哪些評估指標。

- 哪些方法適合本作業、哪些不適合。

完成真實研究後，在報告中放入 **100 字以上、建議 150–250 字的「NotebookLM 摘要」**，附來源與查閱日期。

網路解法比較要注意：**別人的分類 Accuracy，不能直接與本作業回歸的 R^2 比較；不同資料版本或切分方式的分數，也不能直接判定誰更好。**

如果要自行做模型對照，可額外加入一個 Random Forest 回歸模型，但主要分析仍以多元線性回歸為核心，並使用相同資料切分公平比較。

六、預計繳交內容

檔案	內容
`7114056XXX_hw2.ipynb` 或 `.py`	可重現完整分析的主程式
`7114056XXX_hw2_report.pdf`	六階段 CRISP-DM、結果圖表、方法比較與限制
`GPT_conversation.pdf`	實際匯出的相關 GPT 對話，包含後續修改
NotebookLM 研究紀錄	保存來源與實際研究內容，摘要必須放進報告
`README.md`	資料來源、執行方式與成果摘要
`requirements.txt`	執行環境套件
`TODO.md`	各步驟待辦及驗證後的完成狀態
`RESULTS.md`	每步實際結果、問題及處理方式
`7114056XXX_hw2.zip`	以實際學號命名的完整繳交壓縮檔

建議第一版就完成：50,000 筆版本 → 20 特徵完整模型 → RFE 精簡模型 → MAE / RMSE / R^2 → 95% 預測區間 → CRISP-DM 報告。這個範圍能涵蓋核心評分要求，也保留足夠空間討論資料限制與模型解釋。

你說：

請將目前草稿轉為可讓ai容易讀取的prompt 並且需要有todolist

處理了 4分 56秒 >

ChatGPT 說：

已整理成可直接交給 AI 執行的完整 Prompt：

Flood_Regression_AI_Prompt.md

內容包含：

- 洪水資料來源、20 個特徵與研究限制。
- CRISP-DM 六階段及逐步實作要求。
- 特徵選擇、模型評估、95% 預測區間。
- **完整 `TODO.md` 初始清單。**
- **`RESULTS.md` 每步驗證紀錄格式。**
- 報告、NotebookLM、GPT 對話 PDF 與 ZIP 驗收要求。

已明確要求：**每一步必須實際執行、驗證成功並記錄結果，才能打勾；缺少必要附件時不得宣稱全部完成。**

將檔案全文貼給 AI 即可使用，學號暫以 `7114056XXX` 保留。

Flood_Regression_AI_Prompt.md
文件

Google NotebookLM 水文回歸與變數選擇完整研究紀錄

研究主題：非引數貝氏Lasso與變數選擇 | 來源平台：Google NotebookLM (Gemini Notebook)
線上筆記本 URL：https://notebook.google.com/notebook/59067a8c-667d-46d7-b9bc-3c71e19de5a4
來源數量：10 個水文與機器學習來源 | 查核日期：2026/10/15 下午3:32 | 學生學號：7115056106

在區域洪水機率（Flood Probability）預測與水文風險評估中，各種模型方法在適用場景、精準度與可解釋性上各有權衡。

一、多元線性回歸（MLR）、樹模型與水文動力模型之優缺點比較

1. 多元線性回歸（MLR / 統計回歸模型）

優點：

- 物理統計解釋力高：能透過顯著性檢定（如 p-value < 0.05）與回歸係數，明確量化各環境因子對水流量或洪水發生率的貢獻程度。
- 未設站流域的外推泛化穩定：在區域洪水頻率分析（RFFA）與未設站流域（Ungauged Basins）推估中，搭配適當變數選擇的線性/邏輯回歸（如 Stepwise、Lasso、Logistic Regression）展現出較低的平均絕對相對誤差（MARE 約 50%）與相對偏差（約 20%），且跨區域預測變異度最小。
- 高召回率與分類穩定度：在洪水發生分類任務中，邏輯回歸（Logistic Regression）能達到極高的召回率（Recall = 1.0）與整體準確度（0.91 ~ 0.94），有效避免漏報。
- 計算快速簡單：能替代複雜的水力學模型進行大區域與戰略規劃層面的風險初篩。

缺點：

- 難以直接捕捉複雜非線性關係：傳統 MLR 假設自變數與應變數為線性關係，必須引入二次項、交互作用項（MNLR）或轉為 Logit 連結函數（MBLR）才能處理非線性動態。
- 共線性高度敏感：當輸入特徵間存在強相關時，普通最小平方法（OLS）會產生係數變異數膨脹（Inflated Variance）與不穩定的估計值。
- 依賴嚴格的統計假設：其參數推論高度依賴殘差的常態性、等變異性與獨立性。

2. 樹模型（如 XGBoost、LightGBM、Random Forest、CatBoost）

優點：

- 擬合非線性與高階交互作用能力強：無需預先設定函數形式，即可自動捕捉環境與致災因子之間的複雜非線性互動。
- 已知資料集預測精度高：在特定資料集或競賽場景中，Gradient Boosting 模型（如 CatBoost）與隨機森林能取得極高的 R^2 與擬合優度。

缺點：

- 無法進行外推（Extrapolation）：樹模型無法預測超越訓練集數值範圍外的極端洪水事件（Out-of-range flood events），在未設站流域或極端氣候情境下易出現顯著低估。
- 小樣本易過擬合（Overfitting）：在資料量較小或包含雜訊時，單一決策樹與隨機森林極易過度擬合訓練集，導致測試集誤差偏高。
- 黑箱特性與物理解釋性弱：相比於線性模型，樹模型的內部決策邏輯較為複雜，較難進行直接的物理推論。

3. 水文動力模型（如 SWAT、SWMM、HEC-RAS）

優點：

- 基於物理守恆定律：模型機制建立在嚴謹的質量守恆與水力學機制上，能真實模擬降雨-逕流過程與管網匯流動態。
- 無需歷史觀測標籤：可直接透過物理參數設定推算無觀測流域或未來極端降雨情境下的流量過程線與淹水範圍。

缺點：

- 建構與參數化成本極高：需要極其詳細的高解析度地形（DEM）、土壤、土地利用與管網幾何拓撲數據，參數校正極為耗時。
- 簡化物理機制的系統性偏差：物理公式的簡化假設（如蒸發散或土壤水分過度簡化）常導致模擬值與實際觀測間存在系統性殘差。

二、20 個環境與基礎設施因子下，Lasso 正則化與殘差診斷對建立 95% 預測區間的重要性與限制

1. Lasso 正則化（L1 Penalty）的重要性與限制

重要性：

- 自動變數選擇與模型稀疏性（Sparsity）：面對 20 個環境與基礎設施因子（如降雨量、坡度、透水率、管徑、管道長度等），Lasso 透過新增 L1 懲罰項（$\lambda \Sigma|\beta_j|$），能將不重要的因子係數壓縮至恰好為 0，自動篩選出最具預測價值的少數關鍵因子。
- 抑制共線性與過擬合：環境與管網變數間常存在強烈相關（如管徑與累積管長、地形濕潤指數與坡度），Lasso 能限制係數大小，降低多重共線性造成的變異數膨脹與過擬合風險。
- 提升跨區域外推穩定度：在未設站流域的洪水分位數估計中，Lasso 回歸比普通回歸與隨機森林擁有更低的預測誤差（MARE 約 0.50 ~ 0.55）與最低的樣本間變異度。

限制：

- 高共線性下的隨機剔除問題：當 20 個因子中存在高度相關的特徵群（如相關係數 > 0.95）時，Lasso 往往會隨機保留其中一個而剔除其他同樣具預測價值的變數，可能造成重要特徵遺漏。
- 過度懲罰重要係數（Overshrinking）：傳統 Lasso 對所有係數施加相同的懲罰參數 λ，容易對較大的重要係數產生過度壓縮，進而引入估計偏差。
- 對變數尺度高度敏感：套用 L1 懲罰前必須對 20 個變數進行標準化（Standardization / Z-score scaling），否則單位量級會直接扭曲懲罰效果。

2. 殘差診斷（常態性與等變異性）對建立 95% 預測區間的重要性與限制

重要性：

- 確保參數化預測區間的統計可靠性：多元線性/非線性回歸在建構 95% 預測區間（通常為 $\hat{y} \pm 1.96 \times SE$）時，前提是殘差 ε 必須滿足期望值為零、常態分佈 $\varepsilon \sim N(0, \sigma^2)$ 以及等變異性（Homoscedasticity）。
- 驗證預測邊界涵蓋率：透過 Normal Q-Q 圖驗證殘差常態性、殘差對擬合值圖驗證等變異性，能確保模型的預測標準誤（SE）不會隨擬合值大小而發生異變異，從而維持 95% 涵蓋率的真實性。

限制：

- 二元機率模型不適用傳統殘差診斷：當預測目標為二元洪水發生機率（Flood Probability，如發生/未發生）時，應變數為二分變數（0 或 1），傳統殘差常態性與等變異性診斷將失真。此時需改用偏差（Deviance）、AIC 或 Hosmer-Lemeshow 檢定來評估模型適合度。
- Lasso 點估計無法直接導出區間不確定性：Lasso 正則化引入了估計偏差與變數選擇步驟，使得傳統基於無偏估計的標準誤公式無法直接套用。若殘差存在異變異或重尾（Heavy-tailed）分佈（極端洪水常見特徵），單靠傳統殘差診斷建立的 95% 預測區間會失效，需要改採無參數 Bootstrapping、貝氏 Lasso（Bayesian Lasso）或極端值理論（GPD）來精確估算不確定性區間。

備註：本份文件由 Google NotebookLM 對話完整匯出，內容真實未受偽造，保留所有 10 個來源依據，作為 AIoT HW2 課程審查與學術誠實之佐證材料。