你說：

一、作業目標：
本次作業延伸自 HW1，目標是讓同學能夠以實際資料集進行「多元線性回歸 (Multiple Linear Regression)」的完整分析，並遵循 CRISP-DM 流程完成從資料理解、建模到評估的全過程。\

二、作業內容：
1. 資料來源
 至 Kaggle 選擇一個具有 10 至 20 個特徵 (features) 的公開資料集。
 類型不限（可為房價預測、醫療、車輛效能等主題）。
 請明確標示資料集來源與連結。
2. 分析任務
 使用線性回歸 (Linear Regression) 模型進行預測。
 可嘗試單純線性回歸、多元線性回歸或 Auto Regression。
 必須執行 **特徵選擇 (Feature Selection)** 與 **模型評估 (Model Evaluation)**。
 結果部分需包含請提供預測圖(加上信賴區間或預測區間)
3. CRISP-DM 流程說明
  Business Understanding
  Data Understanding
  Data Preparation
  Modeling
  Evaluation
  Deployment

4. AI協助要求
 所有與 ChatGPT 的對話請以 pdfCrowd 或其他方式須**匯出為 PDF**
 請**使用 NotebookLM** 對網路上同主題的解法進行研究，並撰寫一份 100 字以上的摘要，放入報告中。
 請在報告中明確標示「GPT 輔助內容」與「NotebookLM 摘要」
5. 繳交內容
 主程式：7114056XXX_hw2.py/.ipynb
 報告檔： PDF，需包含以下內容：
  按照 CRISP-DM 說明的分析流程
  GPT 對話過程（pdfCrowd 匯出）
  NotebookLM 研究摘要
  網路上主流或更優解法之比較與說明

以上檔案與資料夾**請壓縮為學號命名的一個zip**（例如 7114056XXX_hw2.zip）上傳。

(optional) 若上傳至 GitHub，或是以colab撰寫，需提供連結，並在 README.md 中整理流程與成果。

三、評分標準

文件說明（50%）

CRISP-DM 流程完整且邏輯清楚（25%）

包含 GPT 對話與 NotebookLM 摘要（15%）

有明確說明資料集來源與研究脈絡（10%）
 結果呈現（50%）

模型正確可執行，具特徵選擇與評估（25%）

結果合理、美觀且具有說服力（15%）

呈現出Kaggle名次(若有)/預測結果評估(預測圖、評估指標)（10%）

list kaggle multiple linear regression problems , choose features > 13, < 40

Kaggle Multiple Linear Regression Problems (14–39 Features)

你希望找適合 **Multiple Linear Regression（多元線性回歸）** 的 Kaggle 題目，條件為：
13<Number of Features<4013<Number of Features<40
也就是 **14–39 個輸入特徵**，不包含 Target（預測目標）。
建議優先選擇連續數值預測（Regression）、可使用 `sklearn.LinearRegression` 、適合進行 Feature Selection、MSE、RMSE、R^2 與五大回歸假設檢驗的資料集。
特別注意：Kaggle 上常見的 House Prices — Advanced Regression Techniques 有 **79 個原始特徵**，不符合你的原始特徵數限制，但可以透過特徵選擇建立 14–39 特徵的練習版本。

www.kaggle.com&sz=32
Kaggle
+1

Recommended Kaggle Regression Problems

以下區分「原始特徵符合條件」與「需要 Feature Selection 才符合條件」。

#	Kaggle Problem	Features	Target	Suitability
1	Predict the Flood	20	FloodProbability	Excellent
2				

Flood Prediction Dataset

20

FloodProbability

Excellent

3

Istanbul Apartment Prices 2026

29 or fewer*

Price

Good

4

Swiss Housing Price Prediction

30

House price

Good; restricted access

5
Human–AI Interaction
20
Trust score
Excellent; synthetic
6
House Prices — Advanced Regression
79 → select 20–30
SalePrice
Excellent for feature selection *Istanbul 資料集描述為 30 欄，包含價格等欄位；精確輸入特徵數需檢查 CSV。上述資料集的特徵數以來源描述為準，類別編碼後可能增加。 www.kaggle.com&sz=32 Kaggle +5

My Top 3 for Teaching

China’s Yellow River will be choked by ice jams due to global warming, study finds | South China Morning Post

1. Predict the Flood

20 numerical features, continuous target. Best for teaching OLS, MSE, R^2, residual analysis and regression assumptions.
Aerial View of Houses
2. Istanbul Apartment Prices
Suitable for categorical encoding, feature selection, and housing-price regression. Check the dataset columns before modeling.
AISCA
3. Human–AI Interaction
20 original features, 10,100 samples. Useful for studying coefficients, categorical features and multicollinearity.

Suggested Assignment: CRISP-DM + Feature Selection

For any selected dataset, students can complete:

1. **Business Understanding:** Define the continuous prediction target.
2. **Data Understanding:** Verify sample size, feature count, missing values and correlations.
3. **Data Preparation:** Train/test split, missing-value handling and categorical encoding.
4. **Modeling:** Train `LinearRegression`, Ridge and Lasso.
5. **Evaluation:** Compare MAE, MSE, RMSE, R^2 and Adjusted R^2; check the five regression assumptions.
6. **Deployment:** Predict new samples and explain the model.

For Feature Selection, compare **SelectKBest, RFE, Sequential Feature Selection, Lasso and permutation importance**, selecting 14, 20, 25 or 30 features using training data only.
My first choice is Predict the Flood, because its 20 numerical features meet your constraint directly and avoid the extra complexity of categorical encoding.是目前的作業請先給出實作草稿請我希望資料及使用洪水主題 分析可行性

處理了 3分 21秒 >

ChatGPT 說：

洪水主題可行，而且適合這份多元線性回歸作業。建議使用 **20 個輸入特徵的 Flood Prediction Dataset**，以 `FloodProbability`（洪水機率分數）作為預測目標。

但研究範圍應定位為：**分析資料集中的洪水相關指標與目標分數之間的關係**。目前不能直接把模型說成能預測臺灣實際淹水的系統。

以下是實作前的規劃草稿；**尚未下載 CSV 執行分析，因此不先假設模型分數、缺失值數量或最重要的特徵。**

一、建議題目與資料來源

建議正式題目：

《基於多元線性回歸之洪水風險指標分析與預測：結合 CRISP-DM、特徵選擇與預測區間》

推薦使用：

Kaggle：Flood Prediction Dataset

使用此資料集的研究描述，其包含 **50,000 筆樣本、20 個輸入特徵及 1 個目標欄位** `FloodProbability`；輸入主要為整數評分型變數。實作時仍需以實際下載的 CSV 核對。 researchgate.net

你提供的兩個特徵數條件如下：

條件來源	要求
正式作業	10–20 個特徵
補充選題條件	大於 13、小於 40，即 14–39 個特徵
同時符合的範圍	**14–20 個特徵**
本次選擇	**20 個輸入特徵，符合兩者**

注意：**Target 不算輸入特徵；若檔案有 `id`，也不把它當成預測特徵。**

另有同主題的 Kaggle Playground S4E5 競賽，目標同樣是預測 `FloodProbability`，評分使用 R^2，屬於合成資料競賽。建議本作業先使用上述 50,000 筆版本，避免把不同版本的資料量、來源和評估結果混在一起。 Kaggle

二、資料包含哪些內容？

以下中文是欄位名稱的概念翻譯；**分數高低的實際意義、單位及量尺，仍須核對資料說明，不能自行解讀成毫米、百分比等實測單位。**

輸入特徵	中文概念
`MonsoonIntensity`	季風強度

TopographyDrainage	地形排水條件
RiverManagement	河川管理
Deforestation	森林砍伐
Urbanization	都市化
ClimateChange	氣候變遷
DamsQuality	水壩品質
Siltation	淤積程度
AgriculturalPractices	農業活動與耕作方式
Encroachments	土地或水域侵占
IneffectiveDisasterPreparedness	防災準備不足
DrainageSystems	排水系統
CoastalVulnerability	沿海脆弱程度
Landslides	山崩 / 地滑
Watersheds	集水區相關條件
DeterioratingInfrastructure	基礎設施老化
PopulationScore	人口相關評分
WetlandLoss	濕地流失
InadequatePlanning	規劃不足
PoliticalFactors	政治因素

上述 20 個欄位及連續型目標的結構，可由使用此資料集的研究核對。 researchgate.net

白話來說：

輸入一筆資料的季風、都市化、排水等 20 項分數，讓模型估計這筆資料的 `FloodProbability` 。

這是**回歸問題**，先保留連續分數，不把它改成「會淹水 / 不會淹水」分類。

三、可行性分析

評估面向	判斷與理由
符合作業規格	20 個輸入特徵，符合正式要求
適合多元線性回歸	多個數值輸入搭配連續型目標，可以直接建立模型
資料處理難度	較低，主要不涉及大量類別編碼或影像處理
特徵選擇	可以比較完整模型與刪減特徵後的模型
模型評估	可使用 MAE、RMSE、R^2及殘差分析
區間圖	可使用 OLS 建立平均反應信賴區間或個別預測區間
計算需求	以 50,000 筆、20 特徵規模而言，適合一般電腦進行線性模型分析
真實世界解釋	有限制，必須交代資料來源、量尺及代表性

最需要注意的是資料可信度。同主題研究指出，這份公開資料的來源、蒐集方法與地理涵蓋範圍缺乏可獨立核實的資訊。因此，可以拿來完成建模與方法比較，但不宜直接推論某個真實地區的淹水機率。

mdpi.com

另外：

- **高 R^2 不一定代表真實防災能力強**，可能只是資料內部關係容易被模型學到。
- **回歸係數表示模型中的關聯，不直接等於因果效果。**
- 一般線性回歸可能預測出小於 0 或大於 1 的值，須檢查並報告。
- 不需要為了達成「特徵選擇」硬刪欄位；如果篩選後仍保留全部特徵，也可以是合理結果。

四、實作草稿：依照 CRISP-DM 完成

Step 1：Business Understanding（問題理解）

研究問題設定為：

1. 20 項指標能否有效預測 `FloodProbability` ？
2. 減少輸入特徵後，能否保留接近完整模型的預測表現？
3. 模型的預測誤差及不確定性有多大？

主要模型：

$$Y_i = \beta_0 + \sum_{j=1}^{20} \beta_j X_{ij} + \varepsilon_i$$

其中：

- Y_i：第 i 筆資料的洪水機率分數。
- X_{ij}：第 i 筆資料的第 j 項指標。
- β_j：其他變數固定時，該指標與目標的線性關係。
- ε_i：模型未解釋的誤差。

完成檢查：明確定義輸入、輸出、研究問題及應用限制。

Step 2：Data Understanding（資料理解）

讀取資料並檢查：

- 資料筆數、欄位數、資料型態。
- 缺失值、完全重複列、相同輸入但不同目標的資料。
- 各欄位的最小值、最大值、平均值與標準差。
- `FloodProbability` 的分布。
- 特徵之間及特徵與目標之間的相關性。

預計產出：

圖表 / 表格	用途
資料品質摘要表	說明缺失、重複與異常情況
目標值直方圖	看目標集中在哪個範圍
特徵分布圖	觀察評分分布與極端值
相關係數熱圖	初步觀察線性關係及共線性

完成檢查：確認確實有 20 個可用輸入特徵，且目標沒有誤放進輸入。

Step 3：Data Preparation（資料準備）

建議流程：

1. 移除識別欄位及確認為錯誤的資料。
2. 根據重複情況決定去重或分組切分，避免相同資料跨訓練與測試。
3. 將資料分為 **80% 訓練集、20% 測試集**。
4. 固定隨機種子，例如 `random_state=42` 。
5. 在訓練集內進行 **5-fold cross-validation（五折交叉驗證）** 。
6. 缺失值填補、標準化和特徵選擇，都只在每折的訓練資料上學習。

測試集保留到模型及參數確定後再做最終評估。

若資料實際含有時間、地區或群組結構，則重新評估切分方式；不能無條件假設每列都獨立。

完成檢查：前處理與特徵選擇沒有使用測試集資訊。

Step 4：Modeling（建模與特徵選擇）

建議先完成以下三個核心模型：

模型	用途
平均值基準模型	確認線性模型是否優於「每次都猜訓練集平均值」
完整多元線性回歸	使用全部 20 個特徵，作為主要比較基準
特徵選擇後的多元線性回歸	比較精簡模型是否能維持表現

特徵選擇建議使用 **RFE（Recursive Feature Elimination，遞迴特徵消除）**：

> 逐步移除相對不重要的特徵，再用交叉驗證比較保留不同特徵數的效果。

第一版可比較保留 **14、16、18、20 個特徵**，兼顧你補充的特徵數偏好。這是本次實驗設定，**不是作業規定篩選後至少要有 14 個**。

以訓練集交叉驗證 RMSE 決定採用哪個版本，並記錄：

- 最後保留哪些特徵。
- 哪些特徵被移除。
- 特徵數減少多少。
- 預測表現改善或下降多少。

可以另外計算 **VIF（Variance Inflation Factor，變異數膨脹因子）**診斷共線性，但不把超過某個門檻當成自動刪除的唯一依據。

完成檢查：完整與精簡模型使用相同的資料切分及評估方式。

Step 5：Evaluation（模型評估）

主要指標：

指標	白話解釋
MAE	平均每筆預測差多少
RMSE	對較大的預測錯誤給予較重懲罰
R^2	相較於平均值基準，模型能解釋多少目標變異

預計產生比較表：

模型	特徵數	交叉驗證 RMSE	測試 MAE	測試 RMSE	測試 R^2
平均值基準	0	待執行	待執行	待執行	待執行
完整線性回歸	20	待執行	待執行	待執行	待執行
特徵選擇後線性回歸	待決定	待執行	待執行	待執行	

另加入：

- **實際值對預測值散點圖**：越接近 $y = x$ 越好。
- **殘差對預測值圖**：檢查曲線趨勢與誤差是否隨預測值變大。
- **殘差 Q–Q 圖**：觀察殘差常態性。

不要求所有輸入特徵都呈常態；常態性診斷主要關係到誤差及傳統統計推論。

完成檢查：指標從實際預測計算，報告沒有預填或挑選最好看的結果。

Step 6：加入作業要求的預測區間圖

建議使用 **95% Prediction Interval（預測區間）**，呈現單筆新資料可能落入的範圍。

在傳統 OLS 假設下：

$$\hat{y}_0 \pm t_{0.975,n-p-1}\, s\sqrt{1 + \mathbf{x}_0^\top (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{x}_0}$$

其中 $\mathbf{X}$ 和 $\mathbf{x}_0$ 含截距項，p 為輸入特徵數，s 為殘差標準差。

白話解釋：

不只說「模型預測為 0.52」，還要呈現這個預測的不確定範圍。

建議圖形：

- 固定抽取 100 筆測試資料。
- 依預測值排序。
- 顯示實際值、預測值及 95% 預測區間。
- 明確註明橫軸是「排序後的樣本」，不是時間。
- 在完整測試集計算區間涵蓋率及平均寬度。

可用 `statsmodels` 的 OLS 產生區間。若採用經過特徵選擇的模型，需說明一般 OLS 區間**未包含特徵選擇本身的不確定性**；也不要把區間強制裁成 0–1 後，仍宣稱保有原本的 95% 涵蓋性。

完成檢查：確認畫的是個別預測區間，並且與平均反應信賴區間清楚區分。

Step 7：Deployment（應用與重現）

這份作業不必做完整網站。建議提供：

- 載入模型與前處理設定。
- 輸入具有相同欄位的新 CSV。
- 輸出預測結果。
- README 說明如何安裝、執行及重現結果。

完成檢查：從乾淨環境依說明可重新執行，且新資料欄位順序與訓練時一致。

五、NotebookLM 與網路解法比較如何安排？

這部分是**必做項目**，不能用一般 GPT 摘要代替。

建議實際加入 NotebookLM 的來源包括：

1. Kaggle 資料集說明。
2. 同一洪水資料集的回歸分析 Notebook。
3. 至少一份使用其他回歸模型的同主題研究或實作。

請 NotebookLM 整理：

- 資料來源及限制。
- 他人使用的前處理與特徵選擇。
- 線性回歸與樹模型的比較。
- 使用哪些評估指標。

- 哪些方法適合本作業、哪些不適合。

完成真實研究後，在報告中放入 **100 字以上、建議 150–250 字的「NotebookLM 摘要」**，附來源與查閱日期。

網路解法比較要注意：**別人的分類 Accuracy，不能直接與本作業回歸的 R^2 比較；不同資料版本或切分方式的分數，也不能直接判定誰更好。**

如果要自行做模型對照，可額外加入一個 Random Forest 回歸模型，但主要分析仍以多元線性回歸為核心，並使用相同資料切分公平比較。

六、預計繳交內容

檔案	內容
`7114056XXX_hw2.ipynb` 或 `.py`	可重現完整分析的主程式
`7114056XXX_hw2_report.pdf`	六階段 CRISP-DM、結果圖表、方法比較與限制
`GPT_conversation.pdf`	實際匯出的相關 GPT 對話，包含後續修改
NotebookLM 研究紀錄	保存來源與實際研究內容，摘要必須放進報告
`README.md`	資料來源、執行方式與成果摘要
`requirements.txt`	執行環境套件
`TODO.md`	各步驟待辦及驗證後的完成狀態
`RESULTS.md`	每步實際結果、問題及處理方式
`7114056XXX_hw2.zip`	以實際學號命名的完整繳交壓縮檔

建議第一版就完成：50,000 筆版本 → 20 特徵完整模型 → RFE 精簡模型 → MAE / RMSE / R^2 → 95% 預測區間 → CRISP-DM 報告。這個範圍能涵蓋核心評分要求，也保留足夠空間討論資料限制與模型解釋。

你說：

請將目前草稿轉為可讓ai容易讀取的prompt 並且需要有todolist

處理了 4分 56秒 >

ChatGPT 說：

已整理成可直接交給 AI 執行的完整 Prompt：

Flood_Regression_AI_Prompt.md

內容包含：

- 洪水資料來源、20 個特徵與研究限制。
- CRISP-DM 六階段及逐步實作要求。
- 特徵選擇、模型評估、95% 預測區間。
- **完整 `TODO.md` 初始清單。**
- **`RESULTS.md` 每步驗證紀錄格式。**
- 報告、NotebookLM、GPT 對話 PDF 與 ZIP 驗收要求。

已明確要求：**每一步必須實際執行、驗證成功並記錄結果，才能打勾；缺少必要附件時不得宣稱全部完成。**

將檔案全文貼給 AI 即可使用，學號暫以 `7114056XXX` 保留。

Flood_Regression_AI_Prompt.md
文件