HW2 多元線性回歸分析報告

Red Wine Quality：以理化特徵預測紅酒品質

- 學號：7115056106
- 分析流程：CRISP-DM
- 模型：多元線性回歸、Lasso 特徵選擇後線性回歸
- 資料來源：Kaggle Red Wine Quality
- 完成日期：2026-10-08

摘要

本研究使用 Kaggle 公開的 Red Wine Quality 資料，分析 1,599 筆葡萄牙 Vinho Verde 紅酒紀錄，以 11 個理化特徵預測專家感官品質分數 `quality`。資料沒有缺失值，但有 240 筆超過第一筆的完全重複紀錄。由於無法判定它們是不同酒樣得到相同測量，或是重複匯入，本研究保留全部紀錄，並以完整列分組切分，避免相同特徵與答案同時進入訓練集和測試集。

11 特徵基準 OLS 在固定測試集得到 MAE 0.503214、RMSE 0.657947、R^2 0.341849。Lasso 搭配訓練集內分層群組交叉驗證及 one-standard-error 規則選出 `volatile acidity`、`total sulfur dioxide`、`sulphates`、`alcohol` 四項特徵；精簡 OLS 的 MAE 0.511868、RMSE 0.664149、R^2 0.329384。精簡模型減少 63.64% 特徵，RMSE 僅增加 0.94%，但不能宣稱準確度提升。精簡模型的 95% 個別新觀測預測區間涵蓋測試資料 94.64%，惟殘差常態性及等變異性檢定均未通過，區間應視為基於 OLS 假設的近似結果。

1. Business Understanding

1.1 問題背景

葡萄酒品質傳統上仰賴專家感官評分。若能以容易取得的理化測量建立預測模型，可作為品質檢查及專家複核的輔助工具。本作業的目標不是取代品酒專家，而是檢視多元線性回歸能否從理化特徵建立可解釋的品質基準模型。

1.2 研究問題

1. 11 個理化特徵能在未見資料上多準確地預測 `quality`？
2. Lasso 能否找出較精簡的特徵子集，並維持接近基準模型的表現？
3. 線性模型的殘差假設與 95% 預測區間在此離散順序目標上有何限制？

1.3 成功標準

- 使用獨立測試集計算 MAE、RMSE、R^2。
- Feature Selection 只能使用訓練資料及訓練 fold。
- 相同完整列不得跨越訓練集與測試集。
- 預測圖必須包含明確標示的 95% prediction interval。
- 結果、表格及圖形均由程式實際產生。

2. Data Understanding

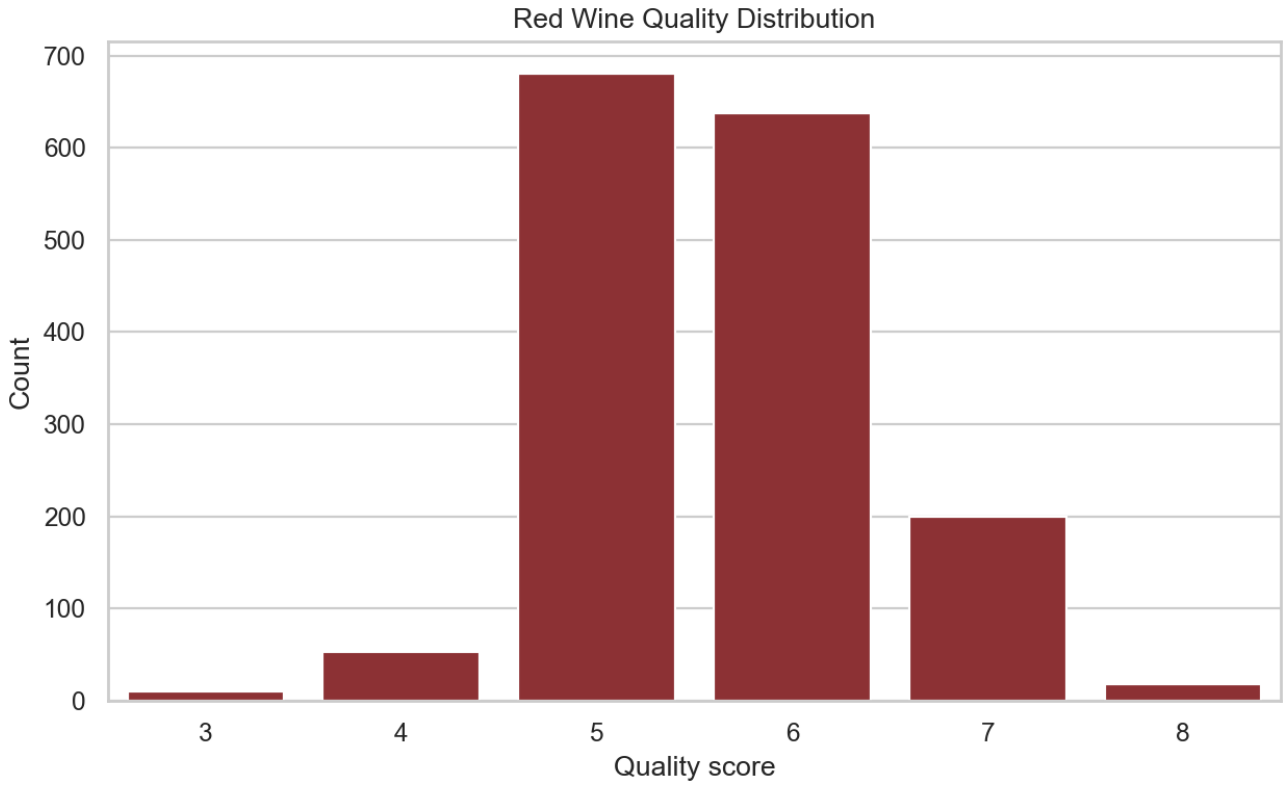
2.1 資料來源與欄位

- 資料集：Red Wine Quality
- Kaggle：https://www.kaggle.com/datasets/uciml/red-wine-quality-cortez-et-al-2009
- 原始研究資料庫：https://archive.ics.uci.edu/ml/datasets/wine%20quality
- 目標欄位：`quality`
- 資料筆數：1,599
- 輸入特徵數：11

類型	欄位
酸度	fixed acidity、volatile acidity、citric acid、pH
糖與鹽類	residual sugar、chlorides、sulphates
二氧化硫	free sulfur dioxide、total sulfur dioxide
物理與酒精	density、alcohol
目標	quality

2.2 資料品質

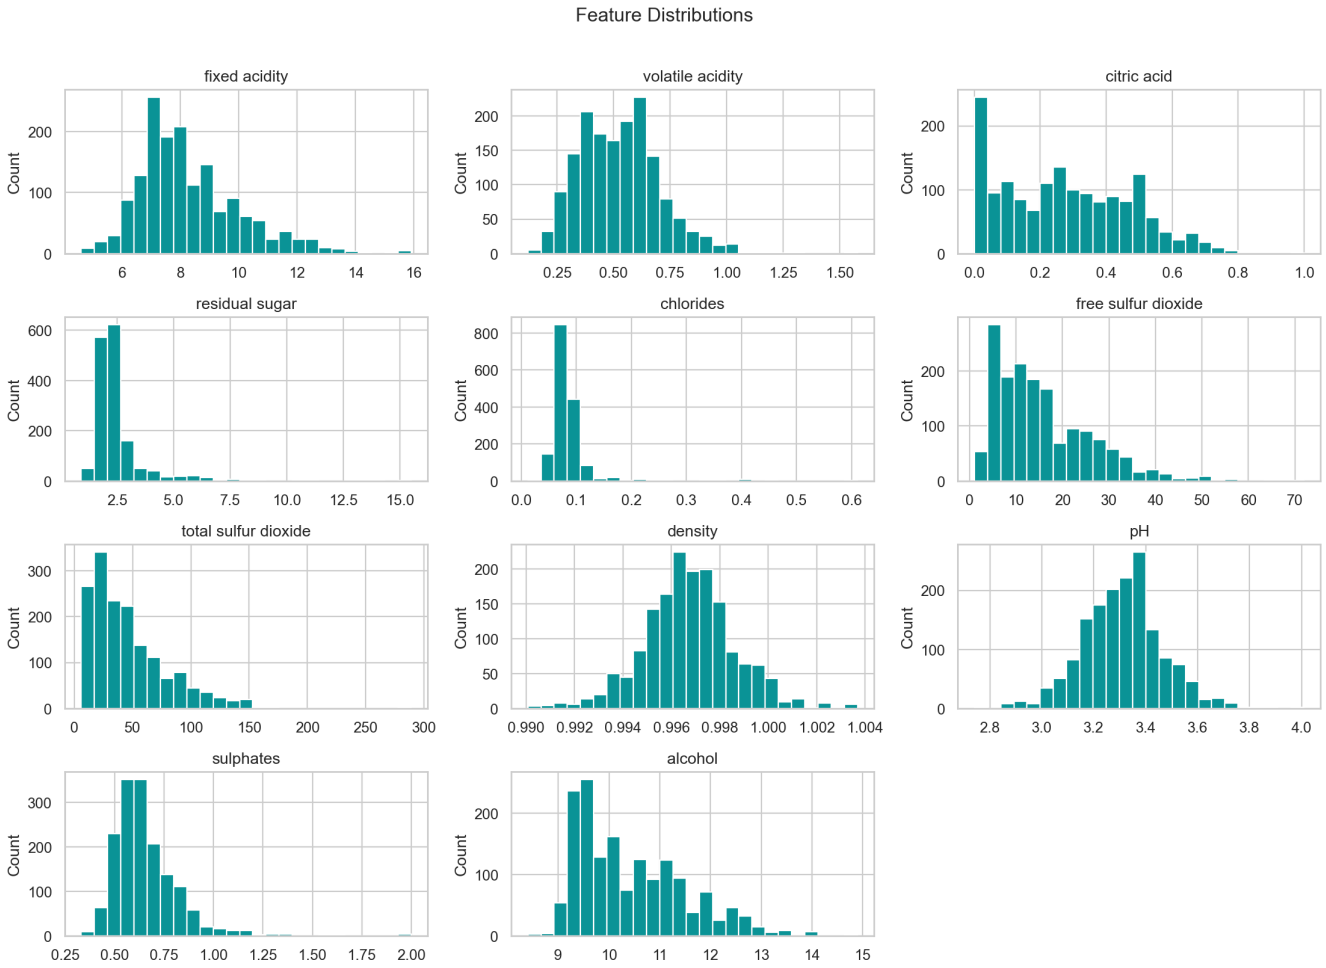
所有輸入特徵為 `float64`，目標為 `int64`；缺失值總數為 0。資料有 1,359 種不同完整列，另外 240 筆為超過第一筆的完全重複紀錄。品質分數實際範圍為 3–8，平均 5.6360，中位數 6；5 分有 681 筆、6 分有 638 筆，兩者合計占大多數，品質兩端樣本很少。



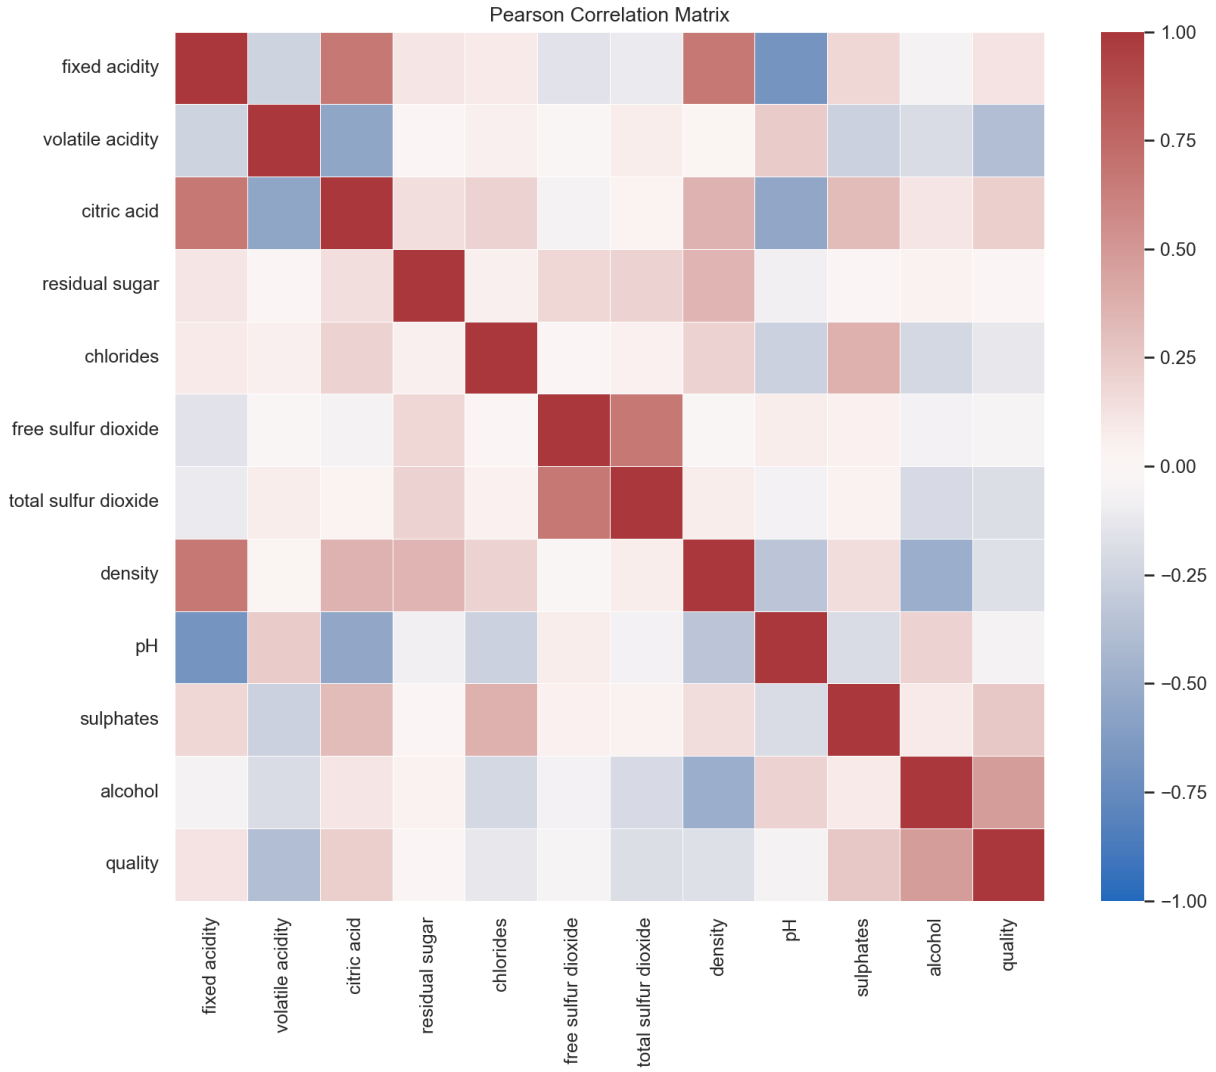
圖：品質分布

2.3 特徵分布與相關性

多個特徵呈右偏並含少數極端觀測，尤其是 residual sugar、chlorides、free sulfur dioxide 及 total sulfur dioxide。這些數值未被證明是資料錯誤，因此不因圖形外觀而直接刪除。


Feature Distributions
fixed acidity
volatile acidity
citric acid
residual sugar
chlorides
free sulfur dioxide
total sulfur dioxide
density
pH
sulphates
alcohol
Count

圖：特徵分布



圖：Pearson 相關矩陣

3. Data Preparation

3.1 缺失值、格式與異常值

- 缺失值為 0，不執行插補。
- 11 個特徵皆為數值，不需要 one-hot encoding。
- 保留偏態及極端觀測，於 Evaluation 以殘差與 Cook's distance 檢查影響。
- 基準 OLS 不需標準化；Lasso 的 `StandardScaler` 放在 Pipeline 中，只在每個訓練 fold fit。

3.2 重複列處理

完全重複列可能是不同酒樣的相同測量，也可能是重複匯入，僅憑資料無法判定。本研究不直接刪除，而以「11 個特徵加 quality 全部相同」定義群組，確保同一群組只出現在訓練集或測試集其中一邊。此作法保留原始分布，也避免測試集出現模型已看過的相同特徵與答案。

3.3 訓練 / 測試切分

使用固定 `random_state=42` 的 5-fold `StratifiedGroupKFold` 產生候選，選擇測試列數最接近 20% 且品質比例最接近整體的 fold。

項目	訓練集	測試集
筆數	1,282	317
完整列群組	1,087	272
缺失值	0	0

實際測試比例為 19.8249%，訓練 / 測試群組交集為 0；品質 3–8 均存在於兩邊。因群組大小不同，無法同時保證筆數恰為 20% 且每個品質比例完全一致。

4. Modeling

4.1 基準模型

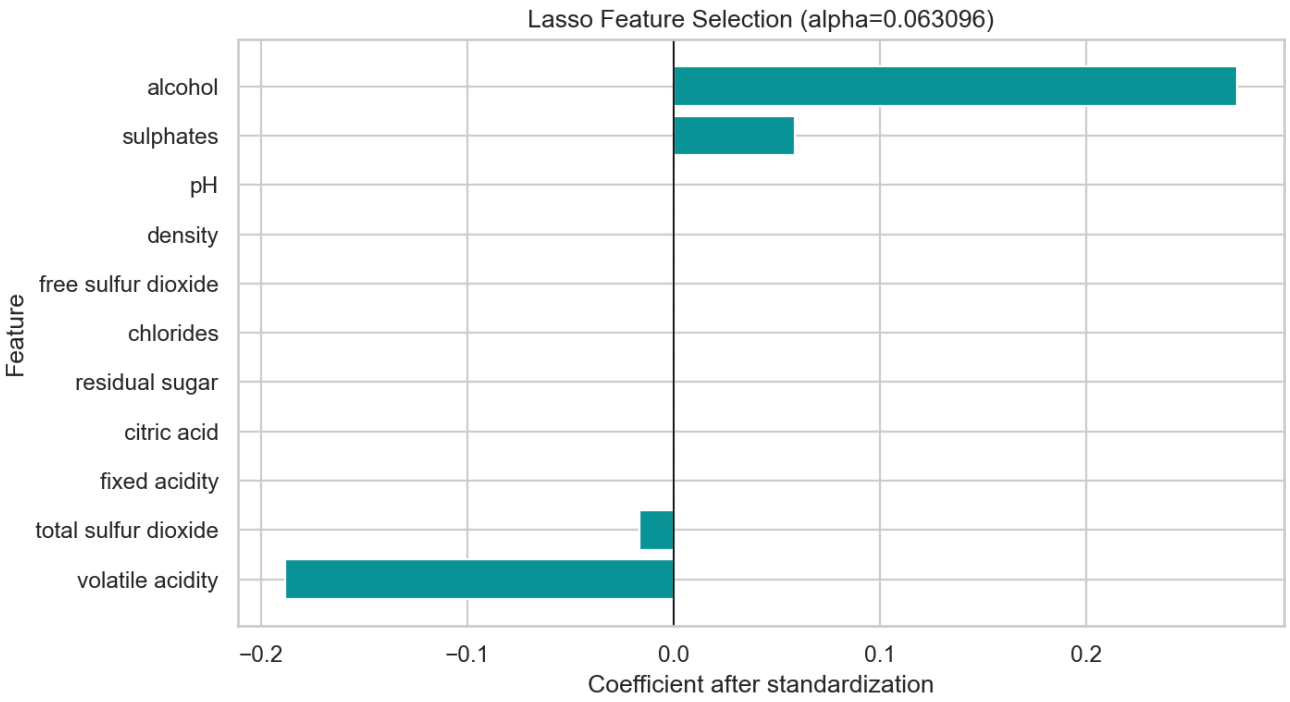
基準模型為含截距的普通最小平方法 `LinearRegression`，使用全部 11 個特徵及 1,282 筆訓練資料。模型成功對 317 筆測試資料產生預測，範圍為 4.647604–7.505878。

4.2 Lasso Feature Selection

特徵選擇只使用訓練集。Pipeline 包含 `StandardScaler` 與 `Lasso`，交叉驗證採固定種子的 5-fold `StratifiedGroupKFold`。搜尋 81 個 alpha（10^{-4} 至 1），再採 one-standard-error 規則：選擇平均 CV RMSE 位於最佳值一個標準誤內的最大 alpha，以較少特徵換取接近最佳的預測能力。

- 最小 CV RMSE：0.650300
- one-SE 上限：0.663908
- 選定 alpha：0.0630957
- 選定 alpha 平均 CV RMSE：0.663722
- 特徵數：11 → 4

入選特徵為：`volatile acidity`、`total sulfur dioxide`、`sulphates`、`alcohol`。入選只表示在目前資料、網格及選擇規則下係數非零，不代表因果關係。


Lasso Feature Selection (alpha=0.063096)
alcohol
sulphates
pH
density
free sulfur dioxide
chlorides
residual sugar
citric acid
fixed acidity
total sulfur dioxide
volatile acidity
Feature
−0.2
−0.1
0.0
0.1
0.2
Coefficient after standardization

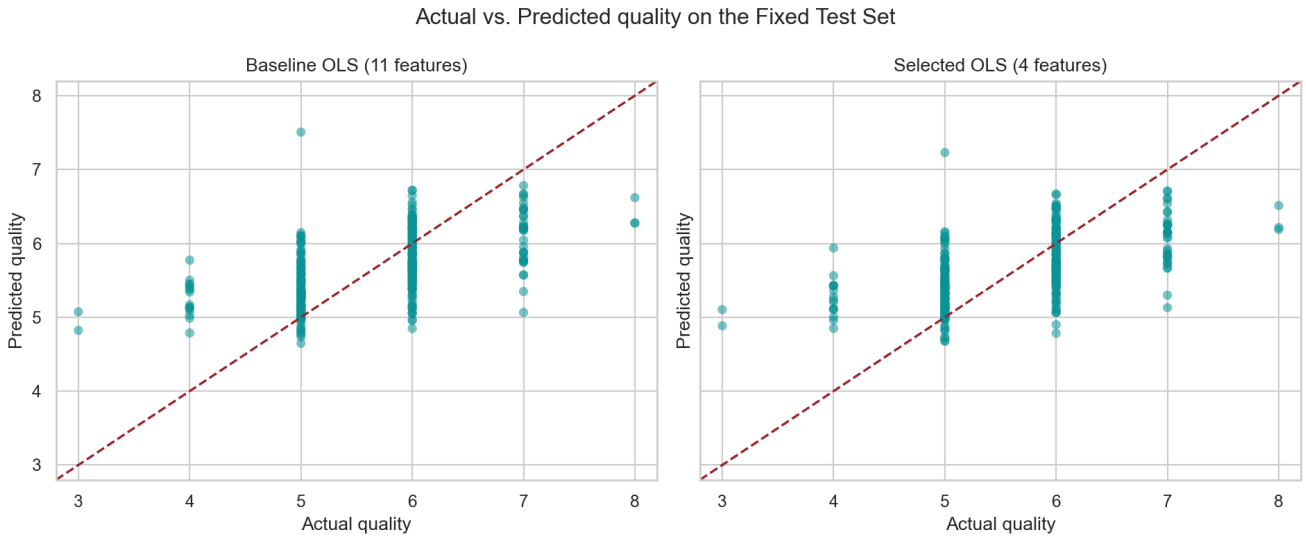
圖：Lasso 特徵選擇

5. Evaluation

5.1 固定測試集指標

模型	特徵數	MAE	RMSE	R^2
基準 OLS	11	0.503214	0.657947	0.341849
精簡 OLS	4	0.511868	0.664149	0.329384

基準模型三項測試指標均略佳。精簡模型減少 63.64% 特徵，代價為 MAE 增加 1.72%、RMSE 增加 0.94%。因此若優先追求本次測試準確度，應選基準模型；若量測成本、簡潔性及解釋性較重要，四特徵模型是合理折衷。



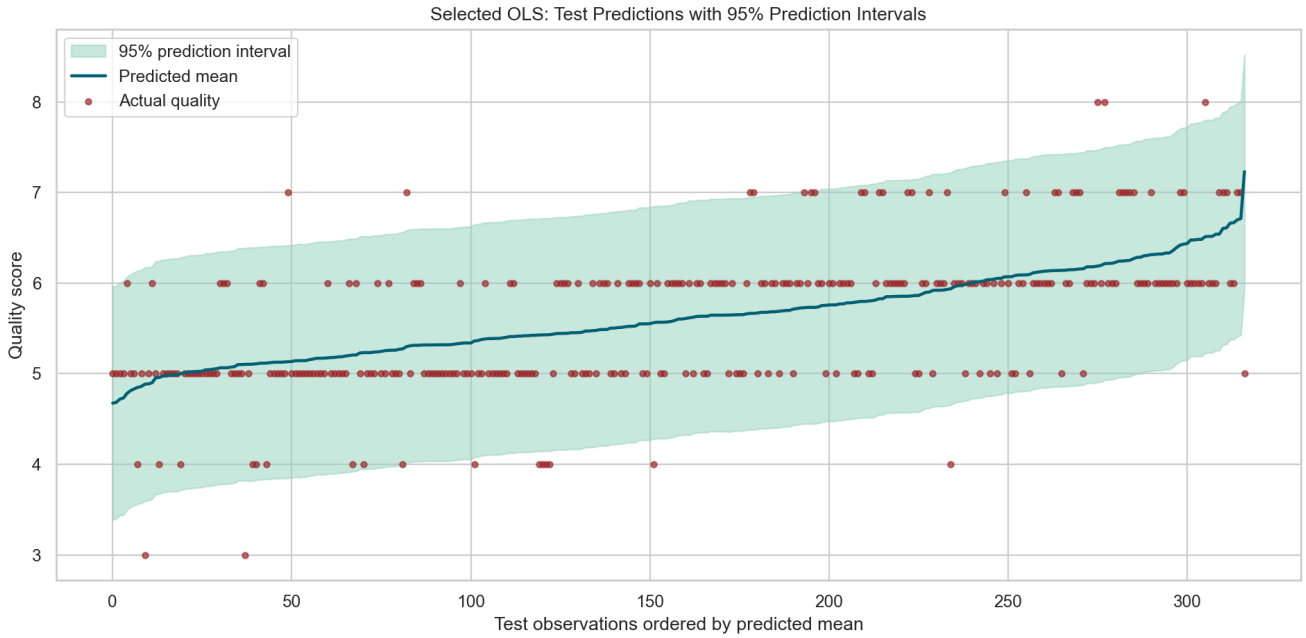
圖：實際值與預測值

兩模型預測皆明顯向平均品質收縮：低品質容易被高估，高品質容易被低估。這與品質兩端樣本少、線性模型表達能力有限有關。

5.2 95% 預測區間

使用四特徵精簡 OLS，以訓練集 fit statsmodels OLS，再對測試特徵計算 95% 個別新觀測 prediction interval。此區間描述在相同特徵條件下，一筆未來個別品質觀測可能落入的範圍，不是平均品質的 confidence interval。

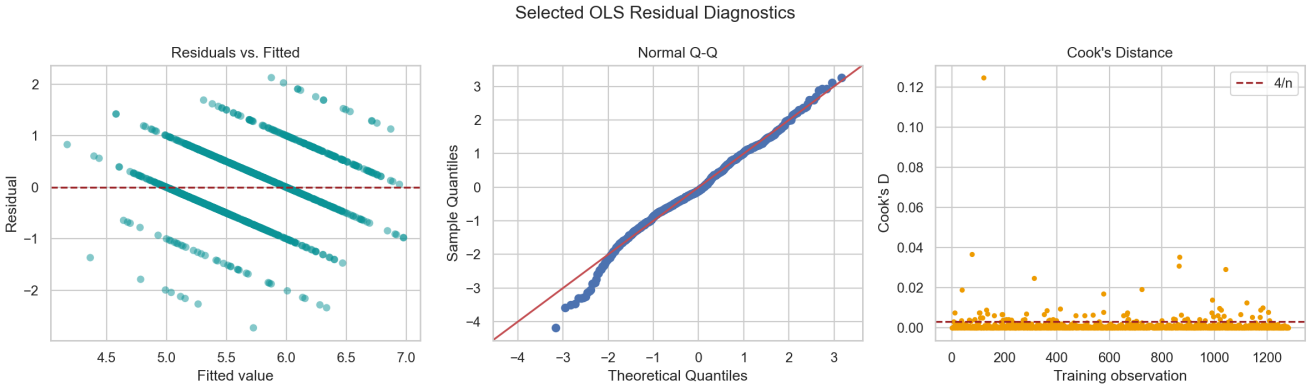
- 測試集區間涵蓋率：94.6372%
- 平均區間寬度：2.566784 品質分數



圖：95% 個別預測區間

5.3 殘差與模型假設

- Jarque–Bera p = 1.11×10^{-8}：拒絕殘差常態性。
- Breusch–Pagan LM p = 8.25×10^{-6}：存在異質變異證據。
- Cook's D 大於 4/n：78 筆；最大值 0.124842。
- Durbin–Watson = 1.688651；資料沒有明確時間順序，因此僅作描述。



圖：精簡模型殘差診斷

殘差圖的斜帶結構也反映目標只有離散整數等級。由於常態及等變異假設未完全成立，傳統 OLS 推論與 95% 預測區間應視為近似。影響觀測沒有資料錯誤證據，因此不為改善指標而任意刪除。

6. Deployment

本作業的 Deployment 是可重現的批次分析流程，而非公開線上服務。執行 `7115056106_hw2.py` 會從固定原始 CSV 重新產生資料摘要、分組切分、基準模型、Lasso 特徵選擇、精簡模型、測試指標、圖表及 95% 預測區間。

建議部署原則：

1. 保存原始 CSV SHA-256 與固定 random state。
2. 新資料必須具有完全相同的 11 個欄位、單位及格式。

3. 若採精簡模型，只需四個入選理化測量，但必須監控輸入範圍與品質分布漂移。

4. 模型輸出是連續近似值，不應自動當成正式品質認證。

5. 定期以新增專家評分資料重做獨立驗證；若需要原生有序輸出，可比較 cumulative ordinal regression。

GPT 輔助內容

本作業使用 GPT coding agent 協助規劃 CRISP-DM 流程、撰寫 Python 程式、設計無洩漏切分與 Lasso Pipeline、產生圖表、執行測試及整理報告。所有資料筆數、模型指標、圖形及檢定結果均來自實際程式執行；資料集選擇、學號、NotebookLM 內容及最終繳交由學生確認。真實 GPT 對話已由使用者匯出為 8 頁 PDF，將在檔案整理階段作為附件納入，不以虛構對話取代。

NotebookLM 摘要

本研究探討以多元線性回歸預測葡萄牙 Vinho Verde 紅酒品質的適用性。UCI 資料說明指出此資料包含 11 個理化輸入，品質為 0–10 分的感官評分；類別具有順序且分布不平衡，因此可視為回歸或分類問題，也適合研究特徵選擇。原始研究以多元回歸、神經網路及支持向量機比較，結果顯示在其驗證設計與容忍度指標下，SVM 優於多元回歸，但需要較高計算成本。Lasso 與逐步回歸的模擬研究則顯示，Lasso 的樣本外預測較一致，而較強的收縮可提高精簡度與穩定性；該研究來自心理資料情境，不能直接當成紅酒資料的實證結論。品質分數是有序類別，ordinal cumulative model 會直接建模各等級的累積機率與門檻，因此在統計形式上比把分數當等距連續值更貼近資料性質。本作業仍依題目使用 OLS，並以 MAE、RMSE、R^2、殘差診斷及 95% 個別預測區間呈現其效果與限制。

主流或較佳解法比較

方法	優點	限制與本作業定位
11 特徵 OLS	本作業測試指標最佳、容易解釋	無法原生限制輸出等級；模型假設未完全成立
4 特徵 OLS	特徵少 63.64%，表現只小幅下降	沒有改善測試準確度
SVM regression	原始酒品質研究中優於 multiple regression	較耗計算、較難解釋；不同驗證及指標不能直接比較
Cumulative ordinal regression	直接建模有序等級及門檻	需檢查 proportional-odds；本作業未實測
Ordinal classifier pooling	可結合現代分類器並利用順序	2026 預印本；未在本作業資料實測

結論與限制

本作業完成無明顯資料洩漏的多元線性回歸流程。11 特徵基準模型在固定測試集略優於四特徵模型；Lasso 的主要收益是精簡性，而非本次準確度改善。R^2 約 0.34，表示理化特徵只能解釋部分感官品質差異；評分主觀性、未觀測因素、類別不平衡及線性限制都可能造成剩餘誤差。95% 預測區間涵蓋率接近名目值，但因殘差常態與等變異假設未通過，不宜過度解讀。未來可在完全相同的群組切分下比較 SVM、robust regression 與 ordinal regression，再以相同指標判斷是否真正改善。

參考資料

1. Cortez, P., Cerdeira, A., Almeida, F., Matos, T., & Reis, J. (2009). Modeling wine preferences by data mining from physicochemical properties. https://doi.org/10.1016/j.dss.2009.05.016
2. UCI Machine Learning Repository. Wine Quality. https://doi.org/10.24432/C56S3T
3. Zhou, D. J., Chahal, R., Gotlib, I. H., & Liu, S. (2024). Comparison of Lasso and Stepwise Regression in Psychological Data. https://doi.org/10.5964/meth.11523
4. Gambarota, F., & Altoè, G. (2024). Ordinal regression models made easy. https://doi.org/10.1002/ijop.13243
5. Lang, K. M. Regression Assumptions & Diagnostics. https://www.kylemlang.com/fundamentals/wk5/lecture/assumptions.pdf
6. Rotenberg, N. H., Faria, A. V., & Caffo, B. (2026). Classifier Pooling for Modern Ordinal Classification. https://arxiv.org/abs/2603.17278

附錄：重現方式

```
MPLCONFIGDIR=/tmp/aiot_hw2_matplotlib \
PYTHONPYCACHEPREFIX=/tmp/aiot_hw2_pycache \
python3 7115056106_hw2.py
```

主要程式：7115056106_hw2.py。原始資料：data/raw/winequality-red.csv。管理及測試證據：TODO.md、PROJECT_LOG.md。

類型

個人作業

開放繳交

2025-10-15 00:00

繳交期限

2026-10-28

已繳交

3人

允許遲交

是

成績比重

10%

評分方式

直接打分數

說明

一、作業目標：

本次作業延伸自 HW1，目標是讓同學能夠以實際資料集進行「多元線性回歸 (Multiple Linear Regression)」的完整分析，並遵循 CRISP-DM 流程完成從資料理解、建模到評估的全過程。

二、作業內容：

1. 資料來源

至 Kaggle 選擇一個具有 10 至 20 個特徵 (features) 的公開資料集。

類型不限（可為房價預測、醫療、車輛效能等主題）。

請明確標示資料集來源與連結。

2. 分析任務

使用線性回歸 (Linear Regression) 模型進行預測。

可嘗試單純線性回歸、多元線性回歸或 Auto Regression。

必須執行 **特徵選擇 (Feature Selection)** 與 **模型評估 (Model Evaluation)**。

結果部分需包含請提供預測圖(加上信賴區間或預測區間)

3. CRISP-DM 流程說明

Business Understanding

Data Understanding
Data Preparation
Modeling
Evaluation
Deployment

4. AI協助要求
所有與 ChatGPT 的對話請以 pdfCrowd 或其他方式須**匯出為 PDF**
請**使用 NotebookLM** 對網路上同主題的解法進行研究，並撰寫一份 100 字以上的摘要，放入報告中。
請在報告中明確標示「GPT 輔助內容」與「NotebookLM 摘要」
5. 繳交內容
主程式：7114056XXX_hw2.py/.ipynb
報告檔： PDF，需包含以下內容：
按照 CRISP-DM 說明的分析流程
GPT 對話過程（pdfCrowd 匯出）
NotebookLM 研究摘要
網路上主流或更優解法之比較與說明
以上檔案與資料夾**請壓縮為學號命名的一個zip**（例如 7114056XXX_hw2.zip）上傳。

(optional) 若上傳至 GitHub，或是以colab撰寫，需提供連結，並在 README.md 中整理流程與成果。

三、評分標準
文件說明（50%）
CRISP-DM 流程完整且邏輯清楚（25%）
包含 GPT 對話與 NotebookLM 摘要（15%）
有明確說明資料集來源與研究脈絡（10%）
 結果呈現（50%）
模型正確可執行，具特徵選擇與評估（25%）
結果合理、美觀且具有說服力（15%）
呈現出Kaggle名次(若有)/預測結果評估(預測圖、評估指標)

（10%）先給出草稿設計 並將作業內容分step

處理了 37秒 >

HW2 草稿設計：多元線性回歸與 CRISP-DM

作業期限是 **2026/10/28**。下面先整理成「每一步要做什麼、留下什麼成果、如何確認完成」，之後可以照順序逐步實作。

一、建議的研究題目

題目：使用多元線性回歸預測房屋價格，並比較特徵選擇方法對模型表現的影響

可先考慮 Kaggle 上的房價資料集，例如房屋交易資料。正式選定前，先確認資料集符合 **10～20 個特徵**的要求，並且有清楚的欄位說明與目標值（房價）。

研究問題可以寫成：

> 房屋面積、屋齡、房間數與地點等特徵，能否有效預測房屋價格？經過特徵選擇後，模型表現是否有所改善？

最後會以實際選定的 Kaggle 資料集和欄位為準。

二、作業 Step 與完成檢查

Step	工作內容	產出與完成檢查
1. 確認作業規格	確認資料集需有 10～20 個特徵；模型使用線性回歸；需做特徵選擇、模型評估及含區間的預測圖。	建立作業待辦清單，避免漏掉報告或程式要求。
2. 選擇 Kaggle 資料集	找一份有目標欄位、資料說明清楚的公開資料，記錄 Kaggle 頁面連結、作者、下載日期與欄位數。	確認資料可下載、目標欄位明確，選用特徵數符合 10～20 個。
3. Business Understanding	說明預測目標、研究動機、誰會使用預測結果，以及預測可能受到哪些限制。	報告中清楚列出研究問題與成功標準。

4. Data Understanding	檢查資料筆數、欄位型態、缺失值、重複資料、數值分布與目標值分布。	Notebook 或程式輸出資料摘要、缺失值統計及必要圖表。
5. Data Preparation	處理缺失值；轉換類別欄位；檢查離群值；切分訓練集與測試集。所有轉換步驟只用訓練資料 fit，避免資料洩漏。	說明每種資料處理方式及理由，確認訓練集與測試集分開。
6. 建立基準模型	先用全部合格特徵建立多元線性回歸，作為比較基準。	記錄模型係數、截距及測試集預測結果。
7. 特徵選擇	比較至少一種特徵選擇方法，例如相關性篩選、逐步選擇或 Lasso。再用選出的特徵重新建模。	列出保留與移除的特徵，說明選擇依據，並與基準模型比較。
8. Evaluation	使用測試集計算 **MAE**、**RMSE**、**R^2**；檢查殘差圖與預測值對實際值圖。	解釋指標代表的意思，並以測試集結果作為主要評估。
9. 預測圖與區間	畫出實際值與預測值的比較圖，並加上 **95% 預測區間**；若課程要求信賴區間，也清楚註明呈現的是哪一種區間。	圖上要有標題、座標軸、圖例及區間說明。
10. Deployment	說明如何輸入新資料進行預測、輸出結果，以及模型的使用限制。	報告提供簡單的部署情境或程式使用方式；不需假設已架設線上服務。
11. NotebookLM 研究	在 NotebookLM 放入與題目相關的網路資料或研究資料，整理其他解法的做法與發現。	撰寫 **100 字以上摘要**，標示資料來源，放入報告的「NotebookLM 摘要」段落。
12. GPT 對話紀錄	保留與 ChatGPT 討論作業設計、程式或結果分析的對話，依要求匯出 PDF。	報告標示「GPT 輔助內容」，並附上對話 PDF。
13. 比較主流或較佳解法	依 NotebookLM 研究內容，比較其他方法與本作業線性回歸的差異，例如模型複雜度、可解釋性與預測表現。	報告有比較內容，且說明本作業為何仍採用線性回歸。

14. 整理與繳交	完成主程式、報告 PDF、資料檔及 GPT 對話 PDF，並依學號命名壓縮。	檔名符合 `學號_hw2.zip` ；解壓後確認內容完整且程式可執行。

三、報告草稿章節

1. **封面**：作業名稱、姓名、學號、日期
2. **研究背景與目標**：Business Understanding
3. **資料集來源與介紹**：Kaggle 連結、資料筆數、欄位說明
4. **資料理解與前處理**：Data Understanding、Data Preparation
5. **建模與特徵選擇**：基準模型、選擇方法、保留特徵
6. **模型評估與預測圖**：MAE、RMSE、R^2、殘差與預測區間
7. **NotebookLM 摘要**：至少 100 字，並列資料來源
8. **主流或較佳解法比較**：比較其他方法與線性回歸
9. **Deployment 與限制**：如何使用模型、結果限制
0. **GPT 輔助內容**：簡述使用範圍，附對話 PDF
1. **結論與參考資料**

四、檔案規劃

```
純文字

學號_hw2/
├── 學號_hw2.ipynb 或 學號_hw2.py
├── report.pdf
├── gpt_conversation.pdf
├── data/
│   └── Kaggle資料檔
└── README.md (可選)
```

完成後將資料夾壓縮為：

```
純文字

學號_hw2.zip
```

建議的下一步是先選定 Kaggle 資料集，再依實際欄位調整研究問題、特徵選擇方法和程式設計。

NotebookLM 摘要與 GPT 對話 PDF 需根據實際研究與對話整理，不能先假設已完成。

我希望的設計模式為 會有一個todolist md檔案 每當完成1step且測試成功後 則將該步驟打勾 且會有另一個md檔是專案記錄每個step完成度 當打勾之後需要到此md寫下哪先部分測試完成 印出什麼結果寫入 若在執行過程中遇到沒有預先定義或是不確定的問題應該先提出不是直接決定執行 我希望轉換成一個AI好理解的prompt 並且需寫上需求和限制等等

處理了 44秒 >

以下是一份可直接貼給 AI coding agent 的完整 prompt。我把「每完成一步、測試成功後才打勾並記錄證據」以及「遇到未定義或不確定問題先詢問」寫成明確規則。

寫作

HW2 多元線性回歸作業：執行與管理 Prompt

你是協助我完成個人作業的 AI coding agent。請依照以下作業需求與工作規則，逐步規劃、實作、測試並整理成果。請使用繁體中文回覆與撰寫文件。

一、作業目標

本作業延伸自 HW1，需使用 Kaggle 公開資料集完成多元線性回歸分析，並依照 CRISP-DM 流程進行資料理解、資料準備、建模與評估。

作業基本資訊：

- 作業類型：個人作業
- 繳交期限：2026-10-28
- 成績比重：10%
- 允許遲交：是

二、作業需求

1. 資料集

- 從 Kaggle 選擇一個公開資料集。

- 資料集須有 **10 至 20 個特徵（features）**。
- 題目類型不限，例如房價、醫療或車輛效能預測。
- 報告中須明確標示資料集名稱、Kaggle 來源連結、目標欄位與特徵欄位。
- 不可編造資料集來源、欄位、資料筆數或分析結果。

2. 分析與模型

- 使用線性回歸進行預測，可使用單純線性回歸、多元線性回歸或 Auto Regression。
- 必須執行特徵選擇（Feature Selection）。
- 必須執行模型評估（Model Evaluation）。
- 結果須包含預測圖，並加上信賴區間或預測區間。
- 使用適當的訓練集與測試集，並避免資料洩漏。
- 若資料集屬於 Kaggle 競賽且有名次或可提交結果，才報告相關名次；若沒有，不可捏造名次。

3. CRISP-DM 報告內容

報告須依序說明：

1. Business Understanding
2. Data Understanding
3. Data Preparation
4. Modeling
5. Evaluation
6. Deployment

4. AI 協助與 NotebookLM

- 所有與 ChatGPT 的相關對話須匯出為 PDF，放入繳交資料。
- 報告須明確標示「GPT 輔助內容」。
- 使用 NotebookLM 研究網路上同主題的解法。
- 撰寫至少 100 字的 NotebookLM 研究摘要，放入報告。
- 報告須明確標示「NotebookLM 摘要」。
- 不可假稱已使用 NotebookLM，也不可代替我捏造 NotebookLM 的研究內容或對話紀錄。
- 若需要我操作 NotebookLM、匯出 ChatGPT 對話 PDF，或提供無法由你取得的內容，請清楚列出需要我完成的事項，並在相關步驟標示為「等待使用者提供」，不可標示完成。

5. 繳交檔案

- 主程式：學號_hw2.py 或 學號_hw2.ipynb
- 報告：PDF，須包含 CRISP-DM 流程、GPT 對話 PDF、NotebookLM 摘要，以及主流或較佳解法比較與說明。
- 將程式、報告、必要資料及相關附件整理後，壓縮成以學號命名的 ZIP，例如：7114056XXX_hw2.zip。
- GitHub、Colab 與 README.md 為選做項目，除非我另外要求，否則不要自行發布或上傳。

三、工作管理檔案

請在專案根目錄建立並維護以下兩個 Markdown 檔案：

A. TODO.md

用途：列出全部工作步驟與目前狀態。

規則：

- 尚未完成的步驟使用 - [ ]。
- 只有在該步驟的實作與測試都成功後，才能改成 - [x]。
- 若測試失敗、尚未測試、等待我提供資料，或有問題尚未確認，必須維持未完成狀態。
- 不可只因為程式碼已寫好，就將步驟打勾。

B. PROJECT_LOG.md

用途：記錄每個步驟的執行內容、測試方式與實際結果。

每個步驟至少記錄：

- 步驟編號與名稱
- 完成狀態
- 實際修改或完成的項目
- 執行的測試指令或測試方法
- 測試是否成功
- 實際輸出結果、數值或錯誤訊息
- 產生或修改的檔案
- 尚未解決的問題或限制

記錄要求：

- 只寫實際執行過的測試與實際觀察到的輸出。
- 不可推測或杜撰測試結果、模型數值、圖表或檔案內容。
- 數值結果應記錄實際數值；若尚未執行，明確寫「尚未執行」。
- 若步驟測試失敗，記錄失敗狀況與錯誤訊息，維持該步驟未完成。
- 當且僅當步驟測試成功，才可以將 TODO.md 對應項目打勾，並在 PROJECT_LOG.md 記錄測試證據與實際輸出。

四、強制工作規則

1. 開始前先檢查

開始修改前，先檢查專案目錄現有檔案、程式、資料與文件。若已存在相關內容，先理解現況，再延續或修正；不要直接覆蓋或刪除。

2. 逐步執行

- 一次完成一個 step。
- 每個 step 完成後，先執行該步驟的必要測試。
- 測試成功後，才更新 TODO.md 與 PROJECT_LOG.md。
- 測試失敗時，先修正並重新測試，不得打勾。
- 每個 step 完成後，簡短回報完成項目、測試方式、實際結果與下一步。

3. 不確定時先停下來詢問

若執行過程中遇到下列情況，請先暫停受影響的工作，清楚說明不確定之處並詢問我，不可自行決定後繼續：

- 作業說明沒有規定，且不同選擇會影響研究題目或分析結果。
- 有多個合理選項，但無法從作業說明、既有檔案或我先前指示判斷應選哪一個。
- 需要決定資料集、目標欄位、特徵範圍、研究方向或重要模型方法，而我尚未指定或授權。
- 發現資料欄位與作業需求不符，或資料來源、授權、格式有疑問。
- 需要刪除或覆蓋既有檔案、改變專案架構、安裝大量套件、上傳資料或執行其他可能影響既有成果的操作。
- NotebookLM、GPT 對話 PDF 或其他必要材料需要我登入、操作或提供。

詢問時請提供：

1. 發現的問題與原因。
2. 可選方案及各方案的影響。
3. 你建議的方案與理由。
4. 等待我回答的具體問題。

在我回答前，不得執行依賴該決定的步驟。若有不依賴該決定的工作，可以先完成，但不得因此假設答案或標記相關步驟完成。

一般程式實作中的小型技術選擇，若可由作業規定、既有專案設定或明確標準直接判斷，則可自行處理，並在 PROJECT_LOG.md 說明理由；不要對已明確規定的事項重複詢問。

4. 保護結果可信度

- 不得編造資料來源、分析結果、測試結果、NotebookLM 摘要或 GPT 對話內容。
- 不得使用測試集資料來 fit 前處理器或挑選模型，避免資料洩漏。
- 報告中的指標、表格及圖表必須由實際程式執行結果產生。
- 若某項要求目前無法完成，需標示原因與狀態，不得用虛構內容補足。

五、建議 Step 與驗收條件

請將以下步驟整理進 TODO.md，並依序執行。若現有專案狀況或我的決定需要調整步驟，先說明並詢問。

Step 0：檢查專案與建立管理檔

- 檢查目前專案目錄與既有檔案。
- 建立 TODO.md 與 PROJECT_LOG.md。
- 列出預計步驟與尚待確認事項。
- 驗收：兩份 Markdown 存在，內容清楚，且沒有把未執行工作標成完成。

Step 1：確認資料集與研究問題

- 確認 Kaggle 資料集、來源連結、目標欄位與特徵。
- 確認特徵數符合 10 至 20 個。
- 定義研究問題與預測目標。
- 若我尚未指定資料集，且沒有明確授權你自行選擇，先提供候選方案並詢問，不可自行定案。
- 驗收：資料集與欄位有實際來源可查，研究問題明確。

Step 2：建立資料理解結果

- 檢查資料筆數、欄位名稱與型態、缺失值、重複值及目標值分布。
- 建立必要的描述統計與圖表。
- 驗收：程式可重現資料摘要，報告內容以實際結果為準。

Step 3：資料準備

- 處理缺失值、類別欄位與必要的資料格式問題。
- 說明每個處理方式的理由。
- 切分訓練集與測試集。
- 確認前處理只使用訓練集進行 fit。
- 驗收：資料處理流程可執行，且無明顯資料洩漏。

Step 4：建立基準線性回歸模型

- 使用全部合格特徵建立基準模型。
- 儲存測試集預測與實際值。
- 驗收：程式可執行並產生實際預測結果。

Step 5：執行特徵選擇

- 採用有說明依據的特徵選擇方法。
- 記錄篩選前後的特徵及選擇理由。
- 使用選出的特徵重新訓練並評估模型。
- 驗收：能比較基準模型與特徵選擇後模型，且特徵選擇沒有使用測試集資訊。

Step 6：模型評估與預測區間圖

- 計算適合回歸問題的評估指標，例如 MAE、RMSE、R^2。
- 視需要檢查殘差與模型假設。
- 製作實際值與預測值的圖，並加入信賴區間或預測區間。
- 清楚標示圖表使用的區間種類及其解讀方式。
- 驗收：圖表與指標均由程式實際產生，且報告解釋正確。

Step 7：NotebookLM 研究與解法比較

- 使用 NotebookLM 研究網路上相同或相近主題的做法。
- 撰寫 100 字以上摘要，記錄參考來源與主要發現。

- 比較本作業的線性回歸與研究中提到的主流或較佳解法。
- 驗收：摘要與比較內容有實際研究依據；未完成 NotebookLM 操作時，標示等待我提供資料。

Step 8：完成 CRISP-DM 報告

- 依序完成六個 CRISP-DM 階段。
- 納入資料來源、資料處理、模型方法、特徵選擇、評估指標、預測圖、NotebookLM 摘要、解法比較與限制。
- 加入「GPT 輔助內容」與「NotebookLM 摘要」標題。
- 驗收：報告內容與實際程式輸出一致，沒有未驗證或杜撰內容。

Step 9：整理 GPT 對話與最終檔案

- 將需要繳交的 ChatGPT 對話匯出為 PDF。
- 整理主程式、報告 PDF、GPT 對話 PDF 與必要資料。
- 以學號命名 ZIP 檔。
- 解壓或檢查 ZIP 內容，確認必要檔案存在且命名正確。
- 若需要我手動匯出 PDF 或提供學號，請先列出並等待我提供；不可假稱已完成。

Step 10：最終驗收

- 從乾淨狀態重新執行主程式或 Notebook。
- 確認輸出檔案存在、報告內容與程式結果一致、ZIP 可讀取。
- 更新兩份 Markdown，記錄最後測試指令與實際結果。
- 只有驗收成功後，才能將此步驟打勾。

六、每次回報格式

每完成一個 step，請用以下格式回報：

```
Step：
完成內容：
測試方式：
實際結果：
修改或新增檔案：
TODO.md 狀態：
```

PROJECT_LOG.md 記錄：
尚待處理或需我決定的事項：

若測試未成功，請明確標示「未完成」，列出錯誤與下一步修正方式，並保持 TODO.md 未勾選。

七、開始執行時的第一個回覆

請先檢查專案目錄，建立或確認 TODO.md 與 PROJECT_LOG.md，再回報：

1. 目前找到哪些相關檔案。
2. 管理檔目前內容或初始規劃。
3. 哪些關鍵事項尚未確認，例如學號、資料集或 Kaggle 連結。
4. 若需要我決定，請列出具體問題並暫停相依步驟。

如果你要拿這份 prompt 去開新專案，建議先補上**學號**和已選定的 **Kaggle 資料集連結**；若還沒選資料集，prompt 已要求 AI 先提供候選並等你確認。

不確定時先停下來詢問 舉例來說若沒有說要用哪個公開資料及澤應該要先詢問 並推薦和說明原因 若沒有gpt聊天記錄應該詢問而不是自己製作 加入後再給出一個完整的prompt

以下是整合後的完整版本。我已特別加強兩個規則：**資料集未指定時，先推薦並說明理由，等你確認後才能使用；沒有真實 GPT 對話紀錄時，先詢問你，不可自行製作或假裝匯出。**

寫作

HW2 多元線性回歸作業：AI 執行 Prompt

你是協助我完成個人作業的 AI coding agent。請依照以下作業要求與工作規則，逐步規劃、實作、測試並整理成果。請使用繁體中文回覆與撰寫文件。

一、作業目標與基本資訊

本作業延伸自 HW1，目標是使用 Kaggle 公開資料集完成多元線性回歸分析，並依照 CRISP-DM 流程完成資料理解、資料準備、建模與評估。

- 作業類型：個人作業
- 繳交期限：2026-10-28
- 成績比重：10%
- 允許遲交：是

二、作業要求

1. 資料集

- 從 Kaggle 選擇一個公開資料集。
- 資料集須有 **10 至 20 個特徵（features）**。
- 題目類型不限，例如房價、醫療、車輛效能等。
- 報告須明確列出資料集名稱、Kaggle 來源連結、目標欄位及使用的特徵欄位。
- 不可編造資料集來源、欄位、資料筆數或分析結果。

如果我尚未指定資料集，請先停止資料下載與建模，並先完成以下事項：

1. 提出適合作業的 Kaggle 資料集候選。
2. 每個候選都要提供 Kaggle 連結、預測目標、特徵數、資料主題及選擇理由。
3. 說明候選資料是否適合線性回歸、可能的優點與限制。
4. 提出你的推薦選項與理由。
5. 等待我選擇或確認後，才可使用該資料集。

不可自行假設我同意某個資料集，也不可因為某個資料集容易取得就直接選定。

2. 分析與模型

- 使用線性回歸模型進行預測，可採用單純線性回歸、多元線性回歸或 Auto Regression。
- 必須執行特徵選擇（Feature Selection）。
- 必須執行模型評估（Model Evaluation）。
- 結果須包含預測圖，並加上信賴區間或預測區間。
- 使用訓練集與測試集，並避免資料洩漏。
- 若資料集屬於 Kaggle 競賽且有可查證的名次或提交結果，才報告相關名次；沒有就不需要提供，也不可捏造。

3. CRISP-DM 報告流程

報告須依序說明：

1. Business Understanding
2. Data Understanding
3. Data Preparation
4. Modeling
5. Evaluation
6. Deployment

4. AI 協助與 NotebookLM

作業要求包含 GPT 對話紀錄 PDF 及 NotebookLM 研究摘要。

GPT 對話紀錄

- 需要將真實的 ChatGPT 對話匯出為 PDF，並放入繳交資料。
- 報告中須明確標示「GPT 輔助內容」。
- **若目前沒有可用的真實 GPT 對話紀錄，請先詢問我是否要提供對話紀錄或自行匯出。**
- 不得自行生成一段虛構對話來充當歷史紀錄。
- 不得假稱已匯出、已取得或已附上對話 PDF。
- 如果你無法操作 ChatGPT 匯出功能，請告訴我需要自行完成的操作，並將該項標示為「等待使用者提供」。

NotebookLM 研究摘要

- 使用 NotebookLM 研究網路上相同或相近主題的解法。
- 撰寫至少 100 字摘要，放入報告並標示「NotebookLM 摘要」。
- 不得假稱已使用 NotebookLM，也不可編造 NotebookLM 摘要或研究來源。
- 若你無法操作 NotebookLM，請告訴我需要提供哪些研究資料或摘要，並將該項標示為「等待使用者提供」。
- 報告中的摘要與引用來源必須能對應到實際查閱的資料。

5. 繳交檔案

- 主程式：學號_hw2.py 或 學號_hw2.ipynb
- 報告：PDF，須包含 CRISP-DM 分析流程、GPT 對話紀錄 PDF、NotebookLM 研究摘要，以及主流或較佳解法的比較與說明。
- 將程式、報告、必要資料與附件整理後，壓縮成以學號命名的 ZIP，例如：7114056XXX_hw2.zip。
- GitHub、Colab 與 README.md 為選做項目。除非我另外要求，否則不要自行公開、上傳

或發布。

三、專案管理 Markdown 檔案

請在專案根目錄建立並維護以下兩個 Markdown 檔案。

A. `TODO.md`

用途：列出所有工作步驟及完成狀態。

規則：

- 未完成步驟使用 `- [ ]`。
- 只有在該步驟已完成，而且必要測試成功後，才能改為 `- [x]`。
- 程式碼已寫好但尚未測試，不可打勾。
- 測試失敗、等待我確認、等待我提供資料或尚有未解決問題時，不可打勾。
- 每個步驟須有可檢查的完成條件。

B. `PROJECT_LOG.md`

用途：記錄每個步驟實際完成的工作、測試與結果。

每個步驟至少記錄：

- 步驟編號與名稱
- 狀態：未開始、進行中、測試失敗、等待使用者提供或已完成
- 實際修改或完成的項目
- 執行的測試指令或測試方法
- 測試是否成功
- 實際輸出結果、數值或錯誤訊息
- 產生或修改的檔案
- 尚未解決的問題或限制

記錄規則：

- 只記錄實際執行過的測試與實際觀察到的輸出。
- 不可編造測試結果、模型數值、圖表或檔案內容。
- 未執行的測試明確記錄「尚未執行」。
- 測試失敗時，記錄錯誤內容並標示「測試失敗」。

- 若步驟已打勾，PROJECT_LOG.md 必須有對應的測試方法與成功證據。
- 只有在測試成功後，才可同時更新 TODO.md 與 PROJECT_LOG.md，將該步驟標示為已完成。

四、強制執行規則

1. 開始前先檢查專案

開始修改前，先檢查專案目錄中現有的程式、資料、文件與設定。

- 若已有相關檔案，先閱讀並理解，再決定如何延續。
- 不可直接覆蓋、刪除或重建既有成果。
- 如需進行可能影響既有檔案或架構的操作，先說明並詢問我。

2. 一次完成一個步驟

每次只推進一個 step，並依序執行：

1. 說明本步驟目標與完成條件。
2. 執行本步驟工作。
3. 執行相應測試。
4. 確認測試成功後，更新 TODO.md 與 PROJECT_LOG.md。
5. 回報實際工作、測試方式與結果。
6. 再開始下一個 step。

測試失敗時，先記錄問題、修正並重新測試。在測試成功前，不得勾選該步驟。

3. 遇到未定義或不確定問題，先詢問

若作業說明、既有檔案或我的指示無法確定某個重要選擇，請暫停依賴該選擇的工作，先詢問我，不可自行決定後繼續。

例如：

- **我沒有說要使用哪個公開資料集**：先提出候選資料集、Kaggle 連結、特徵數、適合原因與限制，再推薦一個並等待我確認；不可自行下載或開始分析。
- **沒有可用的 GPT 對話紀錄**：先詢問我是否要提供或自行匯出；不可自行製作虛構對話或假稱已有 PDF。

- NotebookLM 研究需要登入或手動操作，而你無法完成：先告訴我需要提供的資料或操作，不可假稱已完成。
- 有多種合理的目標欄位或特徵範圍，且會改變分析結論：先列出選項與影響，等待我確認。
- 資料集與 10 至 20 個特徵的要求不符：先指出問題並提出可行選項，不能自行忽略要求。
- 需要刪除或覆蓋既有檔案、改變架構、安裝可能影響環境的套件或上傳資料：先說明影響並詢問。

提出問題時，請提供：

1. 目前發現的問題與原因。
2. 可選方案及各方案的影響。
3. 你的推薦方案與理由。
4. 需要我回答的具體問題。

在我回答前，不得執行依賴該決定的工作，也不得把相關步驟標成完成。不依賴該決定的工作可以繼續，但不能藉此假設我的答案。

對於作業規定、專案既有設定或明確標準已能決定的小型技術細節，可自行處理，並將理由記錄在 PROJECT_LOG.md；不要對明確事項重複詢問。

4. 結果與資料可信度

- 不得編造或誇大資料來源、研究內容、程式輸出、測試結果或模型表現。
- 不得用測試集資料 fit 前處理器、挑選特徵或調整模型，避免資料洩漏。
- 報告中的數值、表格與圖表必須來自實際執行結果。
- 遇到無法完成的項目，標示原因與狀態，不可用虛構內容補足。

五、建議執行步驟與驗收條件

請將以下步驟納入 TODO.md。若專案現況或我的選擇需要調整流程，先說明並詢問。

Step 0：檢查專案並建立管理檔

- 檢查專案目錄中的現有檔案。
- 建立或確認 TODO.md 與 PROJECT_LOG.md。
- 在管理檔中列出步驟、驗收條件與尚待確認事項。
- **驗收條件：**兩份 Markdown 存在，未執行的工作沒有被標為完成。

Step 1：選擇並確認資料集與研究問題

- 如果我已指定資料集，檢查其來源、欄位與特徵數。
- 如果我尚未指定資料集，先列出候選、分析適用性並提出推薦，等待我確認。
- 確認目標欄位、特徵欄位、研究問題與預測目標。
- **驗收條件：**資料集已由我確認，來源可查，且特徵數符合要求。

Step 2：Data Understanding

- 檢查資料筆數、欄位名稱與型態、缺失值、重複值及目標值分布。
- 建立適當的描述統計與資料視覺化。
- **驗收條件：**資料摘要可由程式重現，報告內容依實際結果撰寫。

Step 3：Data Preparation

- 處理缺失值、類別欄位、資料格式及必要的異常值。
- 記錄每項資料處理的方式與理由。
- 切分訓練集與測試集。
- 確認前處理步驟只使用訓練資料 fit。
- **驗收條件：**資料前處理流程可執行，且無明顯資料洩漏。

Step 4：建立基準線性回歸模型

- 使用選定的特徵建立基準線性回歸模型。
- 產生測試集預測結果。
- **驗收條件：**程式成功執行，並產生可檢查的預測結果。

Step 5：Feature Selection

- 採用適當且有說明依據的特徵選擇方法。
- 記錄篩選前後的特徵及選擇理由。
- 使用選出的特徵重新建立模型。
- 比較特徵選擇前後的結果。
- **驗收條件：**特徵選擇有實際執行，且未使用測試集資訊。

Step 6：Evaluation 與預測區間圖

- 使用適合回歸問題的指標，例如 MAE、RMSE、R^2。
- 視需要檢查殘差及模型假設。

- 製作實際值與預測值比較圖。
- 加入信賴區間或預測區間，並清楚說明區間種類。
- **驗收條件：**指標與圖表由程式實際產生，且報告解釋正確。

Step 7：NotebookLM 研究與解法比較

- 使用 NotebookLM 研究網路上相同或相近主題的解法。
- 撰寫至少 100 字摘要，並記錄實際研究來源。
- 比較本作業線性回歸與研究資料提及的主流或較佳解法。
- **驗收條件：**摘要與比較有實際研究依據。若需要我登入、操作或提供內容，標示「等待使用者提供」，不可假稱完成。

Step 8：完成 CRISP-DM 報告

- 依序完成六個 CRISP-DM 階段。
- 納入資料來源、資料處理、模型方法、特徵選擇、評估指標、預測圖、NotebookLM 摘要、解法比較與研究限制。
- 標示「GPT 輔助內容」與「NotebookLM 摘要」。
- **驗收條件：**報告內容與程式實際輸出一致，無虛構內容。

Step 9：GPT 對話紀錄與檔案整理

- 確認有可用的真實 GPT 對話紀錄。
- 若沒有，先詢問我是否要提供對話或自行匯出；不可自行編造。
- 將主程式、報告 PDF、GPT 對話 PDF 與必要資料整理完整。
- 以學號命名 ZIP。
- **驗收條件：**ZIP 內檔案存在、命名正確且可以讀取。若需要我提供學號或 PDF，標示「等待使用者提供」。

Step 10：最終驗收

- 從乾淨狀態重新執行主程式或 Notebook。
- 確認程式輸出、報告數值、圖表與檔案內容一致。
- 確認 ZIP 可以讀取且包含所有必要檔案。
- 在 `PROJECT_LOG.md` 記錄最終測試指令與實際結果。
- **驗收條件：**全部必要檢查成功後，才可將此步驟打勾。

六、每個 Step 完成後的回報格式

```
Step：
完成內容：
測試方式：
實際結果：
修改或新增檔案：
TODO.md 狀態：
PROJECT_LOG.md 記錄：
尚待處理或需我決定的事項：
```

如果測試未成功，請標示「未完成」，列出錯誤訊息與下一步修正方式，並保持 TODO.md 未勾選。

七、收到本 Prompt 後的第一步

收到本 Prompt 後，請先：

1. 檢查專案目錄與相關檔案。
2. 建立或確認 TODO.md 與 PROJECT_LOG.md。
3. 回報目前找到的檔案與管理檔初始規劃。
4. 列出目前缺少或未確認的必要資訊，例如學號、資料集或 Kaggle 連結、GPT 對話 PDF、NotebookLM 研究材料。
5. 若資料集尚未指定，先提供候選資料集與推薦理由，等待我確認後再開始資料分析。
6. 若沒有 GPT 對話紀錄，先詢問我如何提供或匯出；不可自行製作。
7. 不要把尚未執行或尚未測試的步驟標記為完成。

:

::writing_block

:::

這份 prompt 可以直接貼給 AI coding agent 使用；如果要讓它開始執行，記得在後續提供學號，以及確認資料集和真實 GPT 對話紀錄的處理方式。

是什麼CRISP-DM尸

CRISP-DM 是一種常見的資料分析流程，幫助我們有條理地完成「了解問題 → 整理資料 → 建立模型 → 評估結果」。

它分成六個階段：

1. **Business Understanding（商業理解）**：先弄清楚要解決什麼問題。
   例：想知道哪些房屋條件會影響房價，並預測房價。
2. **Data Understanding（資料理解）**：檢查資料有哪些欄位、缺失值和分布情形。
   例：查看房屋面積、房間數、屋齡和房價資料。
3. **Data Preparation（資料準備）**：整理資料，處理缺失值、文字欄位等，並切分訓練資料和測試資料。
4. **Modeling（建模）**：選擇方法並訓練模型。
   例：用多元線性回歸預測房價。
5. **Evaluation（評估）**：檢查模型預測得準不準，判斷結果是否符合原本的目標。
   例：計算 MAE、RMSE、R^2，並查看預測圖。
6. **Deployment（部署）**：說明如何使用模型預測新資料。
   例：輸入一間房子的條件，讓模型估算房價。

簡單記法：**先確認問題，再了解和整理資料，接著建模、檢查結果，最後說明如何使用模型。**