Google NotebookLM 水文回歸與變數選擇完整研究紀錄

研究主題：非引數貝氏Lasso與變數選擇 | 來源平台：Google NotebookLM (Gemini Notebook)
線上筆記本 URL：https://notebook.google.com/notebook/59067a8c-667d-46d7-b9bc-3c71e19de5a4
來源數量：10 個水文與機器學習來源 | 查核日期：2026/10/15 下午3:32 | 學生學號：7115056106

在區域洪水機率（Flood Probability）預測與水文風險評估中，各種模型方法在適用場景、精準度與可解釋性上各有權衡。

一、多元線性回歸（MLR）、樹模型與水文動力模型之優缺點比較

1. 多元線性回歸（MLR / 統計回歸模型）

優點：

- 物理統計解釋力高：能透過顯著性檢定（如 p-value < 0.05）與回歸係數，明確量化各環境因子對水流量或洪水發生率的貢獻程度。
- 未設站流域的外推泛化穩定：在區域洪水頻率分析（RFFA）與未設站流域（Ungauged Basins）推估中，搭配適當變數選擇的線性/邏輯回歸（如 Stepwise、Lasso、Logistic Regression）展現出較低的平均絕對相對誤差（MARE 約 50%）與相對偏差（約 20%），且跨區域預測變異度最小。
- 高召回率與分類穩定度：在洪水發生分類任務中，邏輯回歸（Logistic Regression）能達到極高的召回率（Recall = 1.0）與整體準確度（0.91 ~ 0.94），有效避免漏報。
- 計算快速簡單：能替代複雜的水力學模型進行大區域與戰略規劃層面的風險初篩。

缺點：

- 難以直接捕捉複雜非線性關係：傳統 MLR 假設自變數與應變數為線性關係，必須引入二次項、交互作用項（MNLR）或轉為 Logit 連結函數（MBLR）才能處理非線性動態。
- 共線性高度敏感：當輸入特徵間存在強相關時，普通最小平方法（OLS）會產生係數變異數膨脹（Inflated Variance）與不穩定的估計值。
- 依賴嚴格的統計假設：其參數推論高度依賴殘差的常態性、等變異性與獨立性。

2. 樹模型（如 XGBoost、LightGBM、Random Forest、CatBoost）

優點：

- 擬合非線性與高階交互作用能力強：無需預先設定函數形式，即可自動捕捉環境與致災因子之間的複雜非線性互動。
- 已知資料集預測精度高：在特定資料集或競賽場景中，Gradient Boosting 模型（如 CatBoost）與隨機森林能取得極高的 R^2 與擬合優度。

缺點：

- 無法進行外推（Extrapolation）：樹模型無法預測超越訓練集數值範圍外的極端洪水事件（Out-of-range flood events），在未設站流域或極端氣候情境下易出現顯著低估。
- 小樣本易過擬合（Overfitting）：在資料量較小或包含雜訊時，單一決策樹與隨機森林極易過度擬合訓練集，導致測試集誤差偏高。
- 黑箱特性與物理解釋性弱：相比於線性模型，樹模型的內部決策邏輯較為複雜，較難進行直接的物理推論。

3. 水文動力模型（如 SWAT、SWMM、HEC-RAS）

優點：

- 基於物理守恆定律：模型機制建立在嚴謹的質量守恆與水力學機制上，能真實模擬降雨-逕流過程與管網匯流動態。
- 無需歷史觀測標籤：可直接透過物理參數設定推算無觀測流域或未來極端降雨情境下的流量過程線與淹水範圍。

缺點：

- 建構與參數化成本極高：需要極其詳細的高解析度地形（DEM）、土壤、土地利用與管網幾何拓撲數據，參數校正極為耗時。
- 簡化物理機制的系統性偏差：物理公式的簡化假設（如蒸發散或土壤水分過度簡化）常導致模擬值與實際觀測間存在系統性殘差。

二、20 個環境與基礎設施因子下，Lasso 正則化與殘差診斷對建立 95% 預測區間的重要性與限制

1. Lasso 正則化（L1 Penalty）的重要性與限制

重要性：

- 自動變數選擇與模型稀疏性（Sparsity）：面對 20 個環境與基礎設施因子（如降雨量、坡度、透水率、管徑、管道長度等），Lasso 透過新增 L1 懲罰項（$\lambda \Sigma|\beta_j|$），能將不重要的因子係數壓縮至恰好為 0，自動篩選出最具預測價值的少數關鍵因子。
- 抑制共線性與過擬合：環境與管網變數間常存在強烈相關（如管徑與累積管長、地形濕潤指數與坡度），Lasso 能限制係數大小，降低多重共線性造成的變異數膨脹與過擬合風險。
- 提升跨區域外推穩定度：在未設站流域的洪水分位數估計中，Lasso 回歸比普通回歸與隨機森林擁有更低的預測誤差（MARE 約 0.50 ~ 0.55）與最低的樣本間變異度。

限制：

- 高共線性下的隨機剔除問題：當 20 個因子中存在高度相關的特徵群（如相關係數 > 0.95）時，Lasso 往往會隨機保留其中一個而剔除其他同樣具預測價值的變數，可能造成重要特徵遺漏。
- 過度懲罰重要係數（Overshrinking）：傳統 Lasso 對所有係數施加相同的懲罰參數 λ，容易對較大的重要係數產生過度壓縮，進而引入估計偏差。
- 對變數尺度高度敏感：套用 L1 懲罰前必須對 20 個變數進行標準化（Standardization / Z-score scaling），否則單位量級會直接扭曲懲罰效果。

2. 殘差診斷（常態性與等變異性）對建立 95% 預測區間的重要性與限制

重要性：

- 確保參數化預測區間的統計可靠性：多元線性/非線性回歸在建構 95% 預測區間（通常為 $\hat{y} \pm 1.96 \times SE$）時，前提是殘差 ε 必須滿足期望值為零、常態分佈 $\varepsilon \sim N(0, \sigma^2)$ 以及等變異性（Homoscedasticity）。
- 驗證預測邊界涵蓋率：透過 Normal Q-Q 圖驗證殘差常態性、殘差對擬合值圖驗證等變異性，能確保模型的預測標準誤（SE）不會隨擬合值大小而發生異變異，從而維持 95% 涵蓋率的真實性。

限制：

- 二元機率模型不適用傳統殘差診斷：當預測目標為二元洪水發生機率（Flood Probability，如發生/未發生）時，應變數為二分變數（0 或 1），傳統殘差常態性與等變異性診斷將失真。此時需改用偏差（Deviance）、AIC 或 Hosmer-Lemeshow 檢定來評估模型適合度。
- Lasso 點估計無法直接導出區間不確定性：Lasso 正則化引入了估計偏差與變數選擇步驟，使得傳統基於無偏估計的標準誤公式無法直接套用。若殘差存在異變異或重尾（Heavy-tailed）分佈（極端洪水常見特徵），單靠傳統殘差診斷建立的 95% 預測區間會失效，需要改採無參數 Bootstrapping、貝氏 Lasso（Bayesian Lasso）或極端值理論（GPD）來精確估算不確定性區間。

備註：本份文件由 Google NotebookLM 對話完整匯出，內容真實未受偽造，保留所有 10 個來源依據，作為 AIoT HW2 課程審查與學術誠實之佐證材料。