多元線性回歸預測紅酒品質：分析流程、假設與限制報告

Red Wine Quality Prediction using Multiple Linear Regression: Theoretical Framework & Experimental Roadmap

項目	內容說明	資料集與來源文獻
預測目標 (Target)	quality（葡萄酒感官品質評分，中位數 0–10 分）	UCI ML Repository / Cortez et al. (2009)
輸入特徵 (Features)	11 個連續型葡萄酒理化特徵（固定酸度、殘糖、酒精濃度等）	葡萄牙 Vinho Verde 紅酒資料集 (N = 1,599)
核心演算法	多元線性回歸（Multiple Linear Regression, MLR）	Wikipedia & Stat@Duke MLR 講義
比較模型	Lasso、Stepwise、SVM、ANN、Ordinal Regression	Zhou et al. (2024), arXiv Ordinal Pooling

一、 研究背景、資料內容與預測目標

1. 研究背景：本研究資料集源自葡萄牙西北部 Minho 地區的「綠酒」（Vinho Verde）認證檢測計畫。資料由葡萄牙綠酒委員會（CVRVV）於 2004 年至 2007 年間透過自動化 iLab 系統收集，旨在透過客觀理化檢測輔助品酒專家評估，建立計算機決策支援系統，以提高認證效率與品質控管。
2. 資料內容：紅酒資料集共包含 1,599 個樣本（另有白酒 4,898 個樣本）。包含 11 個連續型理化特徵：固定酸度 (fixed acidity)、揮發性酸度 (volatile acidity)、檸檬酸 (citric acid)、殘糖 (residual sugar)、氯化物 (chlorides)、游離二氧化硫 (free SO)、總二氧化硫 (total SO)、密度 (density)、pH 值、硫酸鹽 (sulphates) 及酒精濃度 (alcohol)。因隱私與物流考量無品牌、葡萄品種或價格。
3. 預測目標：預測目標為 quality，由至少 3 位品酒專家盲測給分並取中位數，原始量表為 0（極差）至 10（極佳）。紅酒實際資料分佈介於 3 到 8 分之間。

二、 多元線性回歸分析流程與特徵選擇方法

預測分析 5 大步驟流程：

1. 資料預處理與檢視：檢查缺失值，檢視 11 個特徵之分佈與極端值；進行特徵標準化，並切分訓練/測試集（如 80/20 切分或 5 折交叉驗證）。
2. 特徵選擇 (Variable Selection)：評估 11 個特徵之相對重要性，過濾冗餘變數。
3. 模型擬合 (Model Fitting)：建構回歸方程式 $y = \beta + \beta x + \ldots + \beta x$，以最小平方法 (OLS) 估計係數。
4. 殘差診斷 (Residual Diagnostics)：繪製殘差圖檢定線性、同變異數性、常態性與多重共線性 (VIF)。
5. 模型評估與區間預測：計算 MAE、RMSE 及 R^2 指標，並導出信賴區間與預測區間。

特徵選擇方法	核心概念與機制	優點 (Advantages)	限制與缺點 (Limitations)
Stepwise Regression (逐步回歸)	基於 F 檢定或 AIC/BIC 準則，透過向前新增或向後剔除逐步選擇變數。	搭配 BIC 能產生極精簡 (parsimonious) 模型，計算快速。	多次檢定致 Type-1 錯誤膨脹；易過擬合；高多重共線性時係數不穩定。
Lasso Regression (L1 正則化)	在 RSS 中加入 L1 懲罰項 λ Σ|β|，將小影響係數壓縮至零。	樣本內選擇精確度與樣本外穩定度較佳；λ (1SE 規則) 能提高模型精簡度。	特徵少時特異度低於 Stepwise BIC；面對高度相關變數會隨機選擇其一。
Sensitivity Analysis (敏感度分析)	固定其他特徵，變動單一特徵觀察預測輸出變化幅度 (MAD)。	直觀且可同時適用於線性與非線性模型 (如 SVM/ANN)。	在綠酒研究中平均僅能剔除約 0.9–1.8 個特徵，顯示理化特徵普遍具相關性。

三、 模型評估指標與線性回歸六大統計假設診斷

1. 回歸評估指標比較：
· MAE (平均絕對誤差)：$(1/N)\,\Sigma\,|y - y|$。對誤差給予線性懲罰，單位與目標相同，具直觀解釋性且對離群值較具魯棒性。
· RMSE (均方根誤差)：$\sqrt{[\,(1/N)\,\Sigma\,(y - y)^2\,]}$。對較大預測誤差賦予平方懲罰；若 RMSE 顯著大於 MAE，代表存在較大離群預測誤差。
· R^2 (判定係數)：衡量模型相較於平均值基準模型所能解釋之變異數比例（$R^2 \leq 1$）。無單位，衡量變異解釋力而非絕對誤差數值。

統計假設 (Assumption)	假設數學與統計意義	殘差診斷與檢測方法 (Diagnostics)
1. 參數線性 (Linearity)	特徵與目標變數間呈現線性組合關係	觀察 Residuals vs Fitted 圖，無明顯曲線或弧形圖案；偏殘差圖 (Component+Residual)
2. 滿秩/無完全共線性	變數間無完美線性關係，N > P	計算變異數膨脹因子 (VIF)，檢視特徵相關性矩陣 (Kyle Lang)
3. 特徵嚴格外生性	特徵與殘差項不相關 Cov(X, ε) = 0	檢視是否有遺漏變數偏誤 (Omitted Variable Bias)
4. 同變異數性	殘差變異數在所有擬合值下為常數 $Var(\varepsilon) = \sigma^2$	觀察 Residuals vs Fitted 或 Scale-Location 圖，散佈點應均勻無漏斗狀/喇叭狀
5. 誤差無自相關	不同觀測值間殘差獨立 $Cov(\varepsilon_i, \varepsilon_j) = 0$	時間序列檢視殘差自相關圖；分群資料檢視組內相關係數 (ICC)
6. 誤差常態分佈	殘差服從正態分佈 $\varepsilon \sim N(0, \sigma^2)$	常態 Q-Q 圖 (Normal Q-Q Plot) 檢驗點是否落在對角直線上；學生化殘差圖

2. 信賴區間 (CI) 與預測區間 (PI) 之概念差異：
· 信賴區間 (Confidence Interval, CI)：針對特定特徵條件下「平均目標值 E(y)」估計的不確定性範圍，區間較窄。
· 預測區間 (Prediction Interval, PI)：針對特定特徵條件下「單一未來葡萄酒觀測值 y」的不確定性範圍，額外加計個體隨機波動 (σ^2)，區間顯著較寬。
· 預測圖解讀：回歸線兩側緊鄰之窄帶為 95% CI；最外側寬邊界為 95% PI。當特徵偏離平均值 (x^*) 時，兩者區間均會呈喇叭狀向外擴張。

四、 套用離散順序評分之限制與模型方法比較

1. 使用線性回歸預測 quality 之四大理論限制：
① 預測連續小數：MLR 輸出為連續實數（如 5.62），而 quality 為離散整數，需人工設定容忍度 (如 T=0.5 四捨五入) 切分。
② 不符合感官非等距特性：MLR 預設評分間距相等（3到4分差距等於7到8分），但人類感官品質提升難度非線性。
③ 無邊界預測風險：MLR 值域為 $(-\infty, +\infty)$，極端特徵輸入時可能預測出小於 0 或大於 10 之非物理數值。
④ 違背殘差常態假設：quality 高度集中於 5、6 分，離散柱狀分佈導致殘差無法完全連續且服從常態分佈。

模型方法	適用情境	模型可解釋性	優缺點與實證比較 (Cortez et al. 2009)
多元線性回歸 (MLR)	假設變數間呈現線性關係，作基準模型	高：可直接讀取回歸係數 β	計算快。限制如前述；紅酒 T=0.5 準確率僅 59.1% (MAD 0.50)。
支持向量機 (SVM/SVR)	存在複雜非線性邊界與特徵交互作用	低（黑箱）：需靠敏感度分析	Cortez 實驗表現最佳（紅酒 T=0.5 準確率 62.4%，MAD 0.46）。訓練時間較長。
人工神經網路 (ANN)	複雜非線性資料建模	低（黑箱）：無法直觀解釋	表現與 MLR 接近（T=0.5 準確率 59.1%），訓練耗時且易陷局部最佳解。
順序回歸 (Ordinal Reg.)	專為具順序性之離散類別目標設計	高：提供門檻參數 α 與勝算比	尊重離散等級與非等距特性，不會產生無界小數；需要符合比例勝算假設。

五、 NotebookLM 研究摘要與學生個人作業實作指引

【NotebookLM 摘要章節文字（可直接複製入作業報告）】
本研究探討運用多元線性回歸（MLR）預測葡萄牙 Vinho Verde 地區紅酒品質評分（共 1,599 筆樣本、11 個理化特徵）之適用性。預測目標為多位專家盲測之 0–10 分中位數品質，資料分佈集中於中間等級。在特徵選擇上，Lasso 回歸透過 L1 正則化懲罰與交叉驗證，較逐步回歸（Stepwise）具備更穩定的樣本外預測與選擇準確度，而搭配 BIC 的逐步回歸則能提供極簡變數組合。模型效果由 MAE、RMSE 與 R^2 等指標評估。然而，將線性回歸套用於離散順序資料存在理論限制，包含輸出連續小數、無評分邊界約束，以及評分等級非等距與殘差非常態等問題。文獻比較顯示，支持向量機（SVM）在容忍度評估下之預測準確率優於線性回歸，而順序回歸模型則更能契合離散等級之統計特性。

實際引用來源名稱列表：
1. Modeling wine preferences by data mining from physicochemical properties - MIT CSAIL
2. Wine Quality - UCI Machine Learning Repository
3. Comparison of Lasso and Stepwise Regression in Psychological Data
4. Ordinal regression models made easy: A tutorial on parameter interpretation, data simulation and power analysis
5. Regression Assumptions & Diagnostics - Fundamental Techniques in Data Science with R - Kyle M. Lang
6. Classifier Pooling for Modern Ordinal Classification - arXiv

個人作業實作分工指引 (Personal Implementation Checklist)：
· 可直接引用文獻之內容：紅酒資料集背景、11 個特徵定義、Stepwise/Lasso 原理、MAE/RMSE/R^2 數學定義、線性回歸六大假設、CI/PI 定義及模型理論比較。
· 必須由您的程式實際執行後補充之數據與圖表：
1. 您的 Python/R 程式實際擬合出的回歸係數 (β) 與 p 值方程式；
2. 特徵選擇程式（Lasso λ 或 Stepwise BIC）實際篩選出的變數清單；
3. 您的模型在訓練集與測試集上的實測 MAE、RMSE 與 R^2 數值；
4. 實際繪製出之 Residuals vs Fitted 圖、Normal Q-Q 圖與計算之 VIF 數值；
5. 針對特徵樣本計算出的具體 95% CI 與 PI 數值區間。